Universidade de Brasília – UnB
Faculdade de Ciências e Tecnologias em Engenharia – FCTE
Engenharia de Software

# Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Autor: Euller Júlio da Silva, Gabriel Henrique Castelo Costa
Orientador: Hilmer Rodrigues Neri

Brasília, DF
2026



Folha de rosto

Euller Júlio da Silva, Gabriel Henrique Castelo Costa

# Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Orientador: Hilmer Rodrigues Neri

Coorientador: Vinicius de Carvalho Rispoli

Brasília, DF

2026

# Sumário


**1 INTRODUÇÃO . . . . . 4**
**1.1 Contexto . . . . . 4**
**1.2 Problema . . . . . 5**
**1.3 Questão de pesquisa . . . . . 6**
1.3.1 GQM adaptado . . . . . 6
1.3.2 Questão norteadora . . . . . 7
**1.4 Objetivos . . . . . 7**
1.4.1 Objetivo geral . . . . . 7
1.4.2 Objetivos específicos . . . . . 8
**1.5 Metodologia . . . . . 8**
1.5.1 Classificação do estudo . . . . . 8
1.5.2 Etapas e atividades da revisão . . . . . 9
1.5.3 Evidências da revisão e elementos do escopo e do planejamento . . . . . 9
**1.6 Organização do trabalho . . . . . 10**
**1.7 Cronograma e fluxo de atividades . . . . . 10**

**2 REFERENCIAL TEÓRICO . . . . . 12**
**2.1 Experimentação na engenharia de software . . . . . 12**
2.1.1 Experimento . . . . . 12
2.1.1.1 Definição do escopo . . . . . 13
2.1.1.2 Planejamento . . . . . 13
2.1.1.3 Operação . . . . . 13
2.1.1.4 Análise e interpretação . . . . . 14
2.1.1.5 Apresentação e documentação . . . . . 14
2.1.2 Revisão sistemática da literatura . . . . . 14
**2.2 Hanseníase e identificação de manifestações cutâneas . . . . . 14**
**2.3 Inteligência artificial e visão computacional . . . . . 15**
2.3.1 Aprendizado de máquina e aprendizado profundo . . . . . 15
2.3.2 Tarefas de análise de imagens . . . . . 15
**2.4 Métricas e dimensões de avaliação . . . . . 15**
2.4.1 Resultados de classificação . . . . . 15
2.4.2 Métricas relacionadas à questão de pesquisa . . . . . 16
**2.5 Avaliação e generalização dos modelos . . . . . 20**

**3 REVISÃO ESTRUTURADA DA LITERATURA . . . . . 21**
**3.1 Planejamento e protocolo . . . . . 21**

**3.2 Estruturação da estratégia de busca . . . 22**
3.2.1 Definição dos componentes PICOC e string de busca . . . 23
3.2.2 Prompt estruturado submetido à plataforma Consensus . . . 24
3.2.3 Consultas apresentadas pelo Consensus . . . 26
**3.3 Realização da busca e seleção dos artigos . . . 27**
3.3.1 Busca e identificação dos registros . . . 29
3.3.2 Critérios de seleção . . . 29
3.3.3 Triagem e seleção para leitura integral . . . 29
3.3.4 Extração e síntese das evidências . . . 32
**3.4 Resultados da revisão . . . 32**
3.4.1 Quais técnicas de visão computacional são utilizadas? . . . 35
3.4.2 Quais conjuntos de dados e populações são utilizados? . . . 36
3.4.3 Quais métodos e procedimentos de avaliação são empregados? . . . 37
3.4.4 Quais métricas e resultados são reportados? . . . 39
3.4.5 Como o desempenho varia entre grupos ou tons de pele? . . . 43
3.4.6 Quais modelos e abordagens de inteligência artificial são empregados? . . . 46
3.4.7 Como a generalização dos modelos é avaliada? . . . 47
3.4.8 Em quais veículos os estudos são publicados? . . . 48

**REFERÊNCIAS . . . 51**

**APÊNDICES 53**

**APÊNDICE A – REGISTROS ENCONTRADOS NA BUSCA . . . 54**

**APÊNDICE B – NOTAS PARA REVISÃO COM OS ORIENTADORES — FORA DO TEXTO DO CAPÍTULO . 63**
**B.1 Estrutura adotada e relação com os exemplos . . . 63**
**B.2 Pontos que precisam de decisão . . . 63**
**B.3 Mapa das afirmações e das fontes . . . 64**
**B.4 Situação do repositório consultado . . . 64**

# 1 Introdução

Este capítulo apresenta o contexto da aplicação de modelos de visão computacional à identificação de manifestações dermatológicas associadas à hanseníase. São delimitados o problema de pesquisa, a questão norteadora e os objetivos do trabalho, considerando a avaliação de desempenho na identificação de padrões associados à hanseníase em imagens de pele, no contexto de apoio à triagem na rede pública de saúde do Brasil.

## 1.1 Contexto

A hanseníase integra o grupo das doenças tropicais negligenciadas e constitui um desafio para a identificação oportuna de casos e o acompanhamento das pessoas afetadas. Em sua revisão da literatura, E01 destaca que o diagnóstico se baseia principalmente na avaliação clínica e que a semelhança com outras condições dermatológicas pode dificultar o reconhecimento da doença. Nesse contexto, a investigação de recursos computacionais de apoio à análise de manifestações cutâneas pode contribuir para ampliar as possibilidades de suporte aos profissionais de saúde, desde que sua avaliação considere as características da tarefa e da população de interesse.

A análise automatizada de imagens dermatológicas tem sido investigada por meio de técnicas de aprendizado de máquina e aprendizado profundo. E01 identificou 21 estudos sobre inteligência artificial no apoio ao diagnóstico da hanseníase e observou que a maior parte utilizava imagens de lesões cutâneas e tarefas de classificação multiclasse. A inclusão da hanseníase em sistemas voltados a diferentes doenças indica que os resultados dessas propostas devem ser interpretados tanto em relação ao conjunto de classes quanto ao reconhecimento específico da doença.

Entre os estudos experimentais, E24 desenvolveu uma abordagem baseada em MobileNetV2 para classificar imagens de eczema, sarampo, hanseníase e pele saudável, incorporando o modelo a um protótipo Android. E05, por sua vez, avaliou ResNet-50 e VGG-16 na classificação de cinco doenças tropicais negligenciadas com manifestações cutâneas. Em outra linha de investigação, E23 propôs um sistema baseado em YOLOv8 para localizar e classificar lesões de diferentes condições, incluindo hanseníase, com uso de mapas de saliência para apoiar a interpretação das predições. Esses trabalhos ilustram abordagens distintas de análise de imagens, com diferentes requisitos de dados, saídas e procedimentos de avaliação.

O campo também compreende tarefas relacionadas ao acompanhamento de manifestações e complicações da doença. E21 apresentou o CO2Wounds-V2, um conjunto

de fotografias de feridas crônicas de pacientes com hanseníase, acompanhado de experimentos de segmentação semântica. Nesse caso, a tarefa consiste em delimitar regiões de ferida nas imagens, e não em determinar se o paciente apresenta hanseníase. Essa distinção é necessária para organizar a literatura e evitar que medidas de segmentação sejam interpretadas como evidências de desempenho diagnóstico.

A caracterização das populações representadas nos dados também integra a avaliação dos modelos. E05 utilizou fotografias coletadas em Costa do Marfim e Gana, descrevendo a população como composta por pessoas de pele escura, com fototipos de Fitzpatrick IV ou superiores. O estudo oferece evidências diretamente relacionadas à análise de imagens de pele escura, mas não apresenta comparação de desempenho entre os diferentes fototipos. E23 também reconhece limitações na diversidade dos dados e aponta a ampliação da representação de pessoas com tons de pele mais escuros como uma direção de trabalho futuro.

Esses estudos motivam a investigação de como o desempenho dos modelos é definido, mensurado e interpretado. Para o presente trabalho, a avaliação compreende os resultados preditivos relativos à tarefa, os procedimentos empregados para obtê-los e as evidências disponíveis sobre sua aplicação a novos dados e a diferentes grupos de tom de pele. A utilização futura em apoio à triagem na rede pública de saúde do Brasil constitui o contexto de interesse da pesquisa, sem que os resultados computacionais sejam, por si só, considerados demonstração de efetividade clínica.

## 1.2 Problema

A existência de modelos capazes de reconhecer padrões em imagens não estabelece, isoladamente, sua adequação à identificação de manifestações de hanseníase em uma população específica. Os estudos analisados apresentam diferenças nas tarefas, nas classes de interesse, na composição dos conjuntos de dados e nas métricas utilizadas. Classificar uma imagem entre doenças, localizar uma lesão e segmentar uma ferida produzem resultados com significados distintos. Consequentemente, uma comparação baseada apenas nos maiores valores publicados pode desconsiderar diferenças essenciais entre os experimentos E05, E21, E23.

Além disso, medidas agregadas podem não representar adequadamente o desempenho referente à hanseníase. No estudo de E05, a Task 2 apresentou acurácias globais de 77% e 80% nos dois cenários avaliados. Entretanto, a leitura da diagonal correspondente à hanseníase nas matrizes de confusão indica proporções de classificação correta de 12% e 13%, respectivamente. Como as linhas representam a classe real, esses valores podem ser interpretados como sensibilidade por imagem para a classe hanseníase. O contraste evidencia a importância de examinar resultados específicos por doença, em vez de atribuir

à hanseníase o desempenho global do sistema.

A relação entre os resultados obtidos e os tons de pele constitui outra dimensão do problema. A presença de imagens de pele escura em um conjunto de dados não demonstra que o modelo apresente comportamento equivalente entre diferentes tons. No estudo de E05, a população é caracterizada por um intervalo de fototipos, mas não são fornecidos resultados separados por esses grupos. Já E23 reconhece limitações de representatividade e a necessidade de ampliar a diversidade dos dados. Essas observações sustentam a necessidade de examinar a caracterização populacional e a avaliação por grupos, sem permitir concluir, a partir dessas evidências isoladas, que todos os modelos tenham desempenho inferior em pele negra.

Também permanece necessário distinguir a avaliação computacional da avaliação em contexto assistencial. O desenvolvimento de um aplicativo ou a obtenção de resultados em conjuntos de imagens não comprova sua contribuição para o atendimento em serviços de saúde. Enquanto E24 apresenta um protótipo de aplicação móvel, E23 situa os estudos prospectivos com dermatologistas entre as atividades futuras. Assim, a relevância dessas propostas para a rede pública exige considerar o alcance e os limites dos procedimentos de validação relatados.

Diante desse cenário, o problema investigado consiste em compreender quais evidências e procedimentos permitem avaliar o desempenho de modelos de visão computacional na identificação de manifestações dermatológicas associadas à hanseníase, no contexto de apoio à triagem na rede pública de saúde do Brasil, considerando a tarefa realizada, as características dos dados e os limites de generalização dos resultados. A comparação entre tons de pele será examinada quando houver informações disponíveis, como uma dimensão complementar da avaliação. A revisão em andamento buscará sistematizar essas informações e identificar os aspectos que precisam ser considerados no planejamento de avaliações futuras.

## 1.3 Questão de pesquisa

### 1.3.1 GQM adaptado

O objetivo de análise foi organizado por meio de um GQM adaptado, que explicita o objeto, o propósito, o foco, o ponto de vista e o contexto da investigação. O quadro orienta a definição da questão de pesquisa e das medidas a serem extraídas dos estudos.

| Característica | Valor |
|---|---|
| **Analisar** | Modelos de visão computacional aplicados à identificação de manifestações dermatológicas. |
| **Com o propósito de** | Avaliar o desempenho dos modelos aplicados à identificação de padrões em imagens de pele. |
| **Com foco em** | Identificação de características patológicas de hanseníase. |
| **Do ponto de vista de** | Pesquisadores das áreas de Engenharia de Software e da área da saúde. |
| **No contexto de** | Apoio à triagem de hanseníase na rede pública de saúde do Brasil. |

### 1.3.2 Questão norteadora

A investigação é orientada pela seguinte questão:

> Como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

Nesta etapa, a questão será abordada por meio da identificação e análise das evidências apresentadas na literatura. Serão examinadas as tarefas realizadas, os modelos empregados, as características dos conjuntos de dados, os procedimentos de avaliação, as métricas e os resultados, bem como as informações disponíveis sobre tons de pele e generalização. A ausência de avaliação por grupo será registrada como uma limitação das evidências disponíveis, sem ser tomada como demonstração de equidade ou de desigualdade de desempenho.

## 1.4 Objetivos

### 1.4.1 Objetivo geral

Analisar a avaliação de desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, a partir da síntese das evidências da literatura, visando fundamentar seu uso em apoio à triagem na rede pública de saúde do Brasil.

### 1.4.2 Objetivos específicos

1. Caracterizar as tarefas, os modelos e as abordagens de visão computacional empregados na análise de manifestações dermatológicas associadas à hanseníase.
2. Identificar os conjuntos de dados utilizados, suas formas de aquisição e anotação e as informações disponíveis sobre as populações e os tons de pele representados.
3. Sistematizar os procedimentos de avaliação, as métricas e os resultados reportados, distinguindo medidas globais, resultados específicos de hanseníase e unidades de análise.
4. Examinar as evidências de generalização e de avaliação do desempenho entre grupos de tom de pele, quando disponíveis.
5. Identificar limitações e lacunas que fundamentem o planejamento de uma avaliação futura de modelos no contexto de apoio à triagem na rede pública de saúde do Brasil.

## 1.5 Metodologia

Este trabalho adota uma revisão estruturada da literatura para identificar e analisar evidências sobre a avaliação de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele. A Figura 1 apresenta o percurso da revisão, do problema de pesquisa à síntese das evidências.

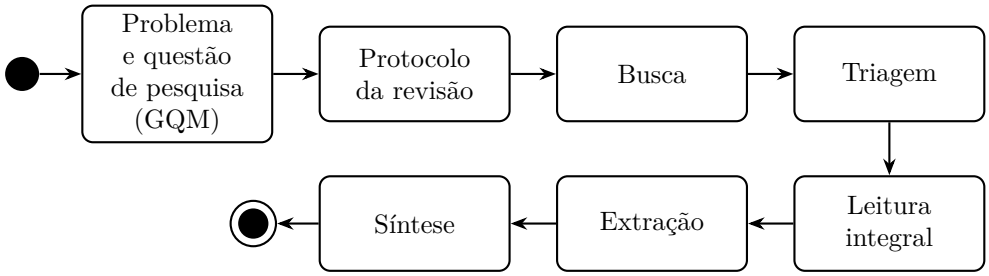



Figura 1 – Fluxo de atividades da revisão estruturada da literatura

Fonte: Elaboração própria.

### 1.5.1 Classificação do estudo

A classificação segue as dimensões do Capítulo 2 de Wohlin et al. (2024).

- **Finalidade descritiva** (WOHLIN et al., 2024, p. 11–13). A pesquisa descritiva descreve um fenômeno ou as características de um problema, e sua questão costuma começar com “o quê” ou “como” (WOHLIN et al., 2024, p. 12). A questão norteadora começa com “Como”, e os objetivos específicos 1 a 4 pedem caracterizar, identificar, sistematizar e examinar o que os estudos reportam.

- **Abordagem mista** (WOHLIN et al., 2024, p. 13). A extração reúne dados quantitativos (como número de imagens e métricas) e qualitativos (como tarefa, modelo e população). O Capítulo 3 combina contagens e tabelas com síntese descritiva.
- **Coleta por estudo de literatura estruturado** (WOHLIN et al., 2024, p. 16–17). A revisão tem questões de pesquisa, protocolo, estratégia de busca, critérios explícitos de seleção e formulário de extração, características que Kitchenham e Charters (2007, p. 4) apontam como diferenciais da revisão sistemática em relação à revisão convencional.
- **Análise descritiva e por classificação** (WOHLIN et al., 2024, p. 18). Os estudos são resumidos por contagens e tabelas e classificados por tarefa, modelo e procedimento de avaliação.

### 1.5.2 Etapas e atividades da revisão

A Tabela 1 lista as atividades realizadas na revisão e indica onde cada uma é apresentada.

Tabela 1 – Atividades realizadas na revisão estruturada

| **Atividade** | **Descrição** | **Onde está** |
|---|---|---|
| Problema e questão de pesquisa | Definição do problema, da questão norteadora (GQM adaptado) e dos objetivos | Capítulo 1 |
| Protocolo da revisão | Questões de pesquisa, estratégia de busca (PICOC), critérios de seleção e formulário de extração | Capítulo 3, seções “Planejamento e protocolo” e “Estruturação da estratégia de busca”; subseções “Critérios de seleção” e “Extração e síntese das evidências”; Figura 4 |
| Busca | Execução da busca e identificação dos registros | Capítulo 3, seção “Realização da busca e seleção dos artigos” |
| Triagem | Seleção por título e resumo, com os critérios do protocolo | Mesma seção; Figura 5 |
| Leitura integral | Leitura dos textos completos e confirmação da elegibilidade | Mesma seção |
| Extração | Preenchimento do formulário de extração dos estudos incluídos | Subseção “Extração e síntese das evidências” |
| Síntese | Síntese das evidências por questão de pesquisa | Seção “Resultados da revisão” |

Fonte: Elaboração própria.

### 1.5.3 Evidências da revisão e elementos do escopo e do planejamento

As evidências reunidas na revisão estruturada (Capítulo 3) organizam-se em consonância com as etapas de definição do escopo (*Scoping*, Capítulo 8) e de planejamento (*Planning*, Capítulo 9) do processo experimental de Wohlin et al. (2024), apresentado no Capítulo 2 (Figura 2):

- **Definição do escopo (*Scoping*, Capítulo 8)** (WOHLIN et al., 2024, p. 109–114): o escopo é formalizado por um modelo de objetivo estruturado em cinco elementos fundamentais: objeto de estudo, propósito, foco de qualidade, perspectiva e contexto (WOHLIN et al., 2024, p. 109–110). No presente trabalho, o modelo GQM adaptado (Quadro da Seção 1.3) cumpre essa função, delimitando os modelos de visão computacional (objeto) voltados a avaliar o desempenho diagnóstico (propósito), focando a identificação de manifestações da hanseníase (foco), sob a perspectiva de pesquisadores e da atenção à saúde, no contexto da triagem na rede pública do Brasil.
- **Planejamento experimental (*Planning*, Capítulo 9)** (WOHLIN et al., 2024, p. 115–144): o planejamento operacionaliza o escopo em sete dimensões: seleção do contexto (Seção 9.1), formulação de hipóteses (Seção 9.2), seleção de variáveis dependentes e independentes (Seção 9.3), seleção de sujeitos e populações (Seção 9.4), desenho experimental (Seção 9.5), instrumentação (Seção 9.6) e avaliação de ameaças à validade (Seções 9.7 e 9.8).

A Tabela 2 relaciona cada um desses elementos ao que a revisão reúne e aos limites das evidências identificadas na literatura. A correspondência dá-se por analogia: os sujeitos descritos por Wohlin correspondem aqui aos conjuntos de dados e às amostras demográficas de imagens clínicas de lesões, enquanto os objetos experimentais correspondem aos modelos e algoritmos de visão computacional sob avaliação.

## 1.6 Organização do trabalho

Este trabalho está organizado em três capítulos. O primeiro apresenta o contexto, o problema de pesquisa, a questão norteadora, os objetivos e a metodologia. O segundo reúne os fundamentos sobre pesquisa empírica, hanseníase, visão computacional e avaliação de modelos. O terceiro apresenta a revisão estruturada da literatura: o planejamento e o protocolo, a estratégia de busca, a seleção dos estudos, a extração e a síntese das evidências e os resultados, organizados pelas questões de pesquisa. Ao final, são apresentadas as referências e os apêndices.

## 1.7 Cronograma e fluxo de atividades

Esta seção apresenta as atividades realizadas, em forma de fluxo na Figura 1.

- **Definição do problema, da questão de pesquisa e dos objetivos:** formulação do problema e da questão norteadora, com o GQM adaptado, e dos objetivos geral e específicos.

Tabela 2 – Elementos do escopo e do planejamento experimental e evidências da revisão

| **Elemento (seção; página)** | **O que a revisão reúne** | **Limite das evidências** |
|---|---|---|
| Escopo (8.1; p. 109–110) | GQM adaptado: objeto, propósito, foco, perspectiva e contexto | "Foco" e "contexto" descrevem domínio e cenário de uso |
| Contexto e sujeitos (9.1 e 9.4; p. 115 e 118) | Contexto do GQM (rede pública de saúde do Brasil); conjuntos de dados e populações usados nos estudos | Poucos estudos caracterizam o tom de pele da base |
| Variáveis (9.3; p. 118) | Modelos e abordagens identificados; métricas e procedimentos reportados | Em dois estudos, o desempenho para a hanseníase é bem inferior ao indicador global ou ao Top-5 (Subseção 3.4.4) |
| Desenho (9.5; p. 119) | Procedimentos de avaliação dos estudos (divisão dos dados e validação) | A maior parte dos estudos que desenvolvem modelos não informa a unidade da divisão dos dados, e poucos testam em outra base (Subseção 3.4.3) |
| Validade (9.7 e 9.8; p. 128 a 138) | Lacunas da evidência (separação por paciente, generalização e tom de pele) | Nenhum estudo com dados reporta, no texto principal, desempenho por tom de pele (Subseção 3.4.5) |

Fonte: Elaboração própria, com os elementos dos capítulos 8 e 9 de Wohlin et al. (2024).

- **Elaboração do protocolo da revisão:** definição das questões de pesquisa, da estratégia de busca (PICOC), dos critérios de inclusão e exclusão e do formulário de extração.
- **Busca dos registros:** execução da busca e identificação dos registros.
- **Triagem:** seleção por título e resumo, com os critérios do protocolo.
- **Leitura integral:** leitura dos textos completos e confirmação da elegibilidade.
- **Extração:** preenchimento do formulário de extração dos estudos incluídos.
- **Síntese:** síntese das evidências por questão de pesquisa.

O fluxo de seleção e os resultados são apresentados no Capítulo 3.

# 2 Referencial teórico

Neste capítulo são apresentados os conceitos que fundamentam a investigação. Inicialmente, são abordadas a pesquisa empírica em engenharia de software e a revisão sistemática da literatura. Em seguida, são apresentados aspectos da hanseníase, da aplicação de aprendizado de máquina a imagens de pele e das medidas usadas na avaliação dos modelos.

## 2.1 Experimentação na engenharia de software

A pesquisa empírica utiliza observações e dados para investigar fenômenos, avaliar propostas e fundamentar conclusões. Na engenharia de software, as estratégias empíricas incluem experimentos, estudos de caso e estudos secundários de literatura, cada qual com objetivos e procedimentos próprios (WOHLIN et al., 2024). A escolha entre essas estratégias depende da questão investigada e das evidências necessárias para respondê-la.

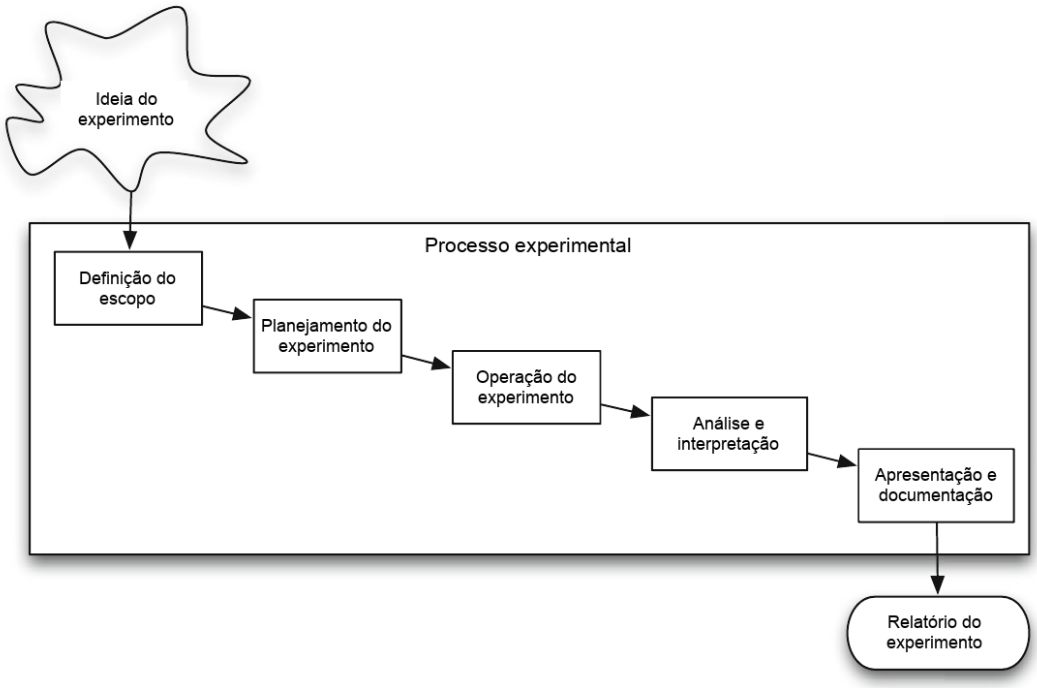
Um experimento controlado envolve a definição de fatores, tratamentos e medidas para investigar seus efeitos sob condições estabelecidas. Já uma revisão sistemática é um estudo secundário, no qual as evidências de outros trabalhos são identificadas e analisadas a partir de um processo documentado (WOHLIN et al., 2024, p. 51–56). Neste TCC, a revisão busca reunir informações sobre avaliações de modelos; sua realização não constitui, por si só, um experimento controlado ou uma validação clínica.

### 2.1.1 Experimento

Um experimento é empregado para investigar questões por meio de observações sob condições planejadas. Sua definição envolve, entre outros elementos, o objeto estudado, os tratamentos ou fatores considerados e as medidas usadas para observar seus efeitos. A organização do processo contribui para que as condições da investigação e os limites de interpretação sejam explicitados (WOHLIN et al., 2024, p. 79–82). Esses conceitos são apresentados como fundamentação para o trabalho e não indicam que um experimento já foi executado.

A Figura 2 apresenta uma visão geral do processo experimental proposto por Wohlin et al. (2024): definição do escopo, planejamento, operação, análise e interpretação, e apresentação e documentação. A figura ilustra o referencial metodológico; ela não representa um experimento já executado neste TCC.

Figura 2 – Visão geral do processo experimental




Fonte: Adaptado de Wohlin et al. (2024, p. 80, Figura 6.4).

#### 2.1.1.1 Definição do escopo

A definição do escopo delimita o objeto, o propósito, o foco de qualidade, a perspectiva e o contexto do estudo. Esses elementos orientam a pergunta que se pretende responder e as decisões das etapas seguintes. O GQM adaptado apresentado na introdução explicita esses componentes para o objetivo desta pesquisa (WOHLIN et al., 2024, p. 80).

#### 2.1.1.2 Planejamento

No planejamento são especificados o contexto da investigação, as variáveis, as hipóteses quando aplicáveis, o desenho e os instrumentos de medição. Também são examinadas possíveis ameaças à validade. Em uma avaliação de modelos de visão computacional, essas decisões poderiam envolver a caracterização dos dados, a definição das tarefas e a escolha das métricas; o desenho efetivo de uma avaliação futura ainda depende dos resultados da revisão (WOHLIN et al., 2024, p. 80–82).

#### 2.1.1.3 Operação

A operação corresponde à preparação e à execução do procedimento planejado, incluindo a coleta e a verificação dos dados produzidos. Seu registro permite relacionar os resultados às condições em que foram obtidos. Nesta etapa do TCC, a operação de um

experimento com modelos não foi estabelecida (WOHLIN et al., 2024).

#### 2.1.1.4 Análise e interpretação

Após a obtenção dos dados, a análise organiza as medidas e examina os resultados em relação às questões formuladas. A interpretação deve considerar as características dos dados e as ameaças à validade, evitando estender conclusões além das condições de avaliação (WOHLIN et al., 2024).

#### 2.1.1.5 Apresentação e documentação

O relato reúne o objetivo, o procedimento, as medidas, os resultados e as limitações, permitindo que outras pessoas compreendam e examinem o estudo. A documentação também dá suporte à comparação com investigações posteriores (WOHLIN et al., 2024).

### 2.1.2 Revisão sistemática da literatura

Uma revisão sistemática parte de questões de pesquisa e de um protocolo que orienta a busca, a seleção, a avaliação e a síntese dos estudos. Entre os elementos a registrar estão as fontes e estratégias de busca, os critérios de seleção e os procedimentos de extração de dados (KITCHENHAM; CHARTERS, 2007; WOHLIN et al., 2024). A descrição dessas decisões permite examinar o alcance e as limitações do conjunto de estudos identificado.

No presente trabalho, a revisão é empregada para compreender como modelos aplicados a imagens de pele relacionadas à hanseníase são avaliados. O protocolo e o andamento de sua execução são apresentados no Capítulo 3.

## 2.2 Hanseníase e identificação de manifestações cutâneas

A hanseníase pode apresentar manifestações na pele e comprometimento de nervos periféricos. Segundo a World Health Organization (2018), entre os sinais usados para o diagnóstico estão a perda de sensibilidade em uma mancha cutânea, alterações em nervos periféricos associadas à perda de sensibilidade e a presença de bacilos em exame de esfregaço cutâneo. Portanto, uma fotografia de pele representa somente parte das informações consideradas na avaliação clínica.

No contexto desta pesquisa, a análise computacional de imagens é tratada como possível apoio à triagem. Seu desempenho em uma base de imagens não demonstra, isoladamente, que o sistema possa estabelecer um diagnóstico ou melhorar o atendimento em um serviço de saúde. Por isso, é necessário relacionar os resultados reportados à tarefa realizada, aos dados utilizados e à forma de validação E01.

## 2.3 Inteligência artificial e visão computacional

### 2.3.1 Aprendizado de máquina e aprendizado profundo

A visão computacional compreende métodos capazes de extrair e analisar informações de imagens. No aprendizado de máquina, modelos são ajustados a partir de dados para executar uma tarefa; no aprendizado profundo, redes com múltiplas camadas aprendem representações em diferentes níveis. Redes neurais convolucionais são uma das abordagens empregadas na análise de imagens (LECUN; BENGIO; HINTON, 2015).

### 2.3.2 Tarefas de análise de imagens

As aplicações à hanseníase diferem quanto à tarefa e ao resultado produzido. Na classificação, o modelo atribui uma categoria à imagem; na detecção, identifica e localiza objetos ou lesões; na segmentação, associa regiões ou pixels a classes de interesse. Essas saídas respondem a perguntas diferentes e devem ser avaliadas com medidas apropriadas à tarefa E05, E21, E23.

Por exemplo, E05 investigou a classificação de doenças tropicais com manifestações cutâneas, enquanto E21 estudou a segmentação de feridas em imagens de pessoas com hanseníase. Delimitar uma ferida e identificar a doença em uma imagem são objetivos distintos; assim, um resultado de segmentação não deve ser apresentado como medida de diagnóstico da hanseníase.

## 2.4 Métricas e dimensões de avaliação

As métricas serão extraídas conforme a tarefa e o protocolo de cada estudo. Não se exige que todos os artigos apresentem todas as medidas. Métricas ausentes serão registradas como não reportadas; cálculos adicionais somente serão realizados quando houver dados suficientes, com identificação explícita de que foram derivados nesta revisão.

### 2.4.1 Resultados de classificação

Para classificação binária, deve-se definir previamente o que constitui a classe positiva e o diagnóstico/rótulo de referência. Em modelos multiclasse, a hanseníase pode ser analisada como classe positiva frente às demais classes (um contra todos). As definições abaixo se referem à unidade avaliada — por exemplo, imagem — e não implicam automaticamente diagnóstico por paciente.

| Resultado | Significado |
|---|---|
| **TP — True Positive** | A unidade pertence à classe positiva segundo a referência e o modelo a classifica como positiva. |
| **TN — True Negative** | A unidade pertence à classe negativa segundo a referência e o modelo a classifica como negativa. |
| **FP — False Positive** | A unidade pertence à classe negativa segundo a referência, mas o modelo a classifica como positiva. |
| **FN — False Negative** | A unidade pertence à classe positiva segundo a referência, mas o modelo a classifica como negativa. |

A classe positiva pode representar hanseníase ou uma manifestação definida no protocolo do estudo. Essas tarefas devem ser distinguidas: reconhecer uma ferida em paciente com hanseníase não equivale a diagnosticar a doença.

### 2.4.2 Métricas relacionadas à questão de pesquisa

| ID | Dimensão do desempenho | Métrica | Descrição e operacionalização |
|---|---|---|---|
| M1 | Classificação | **Sensibilidade — Sensitivity (SEN/Recall)** | Proporção de positivos corretamente identificados: **SEN = TP / (TP + FN)**. |
| M2 | Classificação | **Especificidade — Specificity (SPE)** | Proporção de negativos corretamente identificados: **SPE = TN / (TN + FP)**. |

| ID | Dimensão do desempenho | Métrica | Descrição e operacionalização |
|---|---|---|---|
| M3 | Classificação | **Precisão — Precision (PRE)** | Proporção de predições positivas que correspondem a positivos de referência: **PRE = TP / (TP + FP)**. |
| M4 | Classificação | **F1-score** | Média harmônica entre precisão e sensibilidade, considerando o efeito de falsos positivos e falsos negativos: **F1 = 2 × PRE × SEN / (PRE + SEN)**, ou **2TP / (2TP + FP + FN)**. |
| M5 | Classificação geral | **Acurácia — Accuracy (ACC)** | Proporção total de classificações corretas: **ACC = (TP + TN) / (TP + TN + FP + FN)**, na formulação binária. Para multiclasse, usar acertos totais / unidades totais. |

| ID | Dimensão do desempenho | Métrica | Descrição e operacionalização |
|---|---|---|---|
| M6 | Equidade do desempenho | **Diferença de desempenho entre grupos** | Comparação da mesma métrica entre grupos de tons de pele, quando disponível. Para dois grupos A e B: $\Delta$ = **métrica(A)** − **métrica(B)**, com grupos e direção identificados. Registrar tamanhos dos grupos, condições de avaliação e incerteza, quando reportados. |
| M7 | Generalização | **Variação de desempenho entre datasets** | Comparação da mesma métrica entre avaliações em dados de distribuição semelhante à de treinamento e dados de distribuição diferente: **gap** = **métrica(ID)** − **métrica(OOD)**, quando o desenho permitir. Registrar se houve adaptação ou retreinamento e se tarefa/classes são comparáveis. |

| ID | Dimensão do desempenho | Métrica | Descrição e operacionalização |
|---|---|---|---|
| M8 | Segmentação / sobreposição espacial | **Intersection over Union (IoU)** | Interseção dividida pela união das regiões prevista P e de referência G: **IoU = área(P ∩ G) / área(P ∪ G)**. Em máscaras binárias: **IoU = TP_pixel / (TP_pixel + FP_pixel + FN_pixel)**. Registrar mIoU separadamente quando houver média entre classes. |
| M9 | Detecção / segmentação por instância | **Mean Average Precision (mAP)** | Média dos valores de AP das classes consideradas; AP resume a curva precisão–recall segundo a convenção do benchmark. Registrar o critério de correspondência e o limiar de IoU: por exemplo, **mAP@0,50** ou **mAP@0,50:0,95**. Distinguir AP de caixas e AP de máscaras. |

**IoU e mAP não são métricas exclusivas de segmentação.** Em detecção, IoU mede sobreposição de caixas e pode determinar a correspondência entre predição e referência; mAP resume o desempenho das detecções. Na segmentação semântica, IoU/mIoU

mede sobreposição de máscaras por classe. Na segmentação por instância, também se utiliza AP/mAP calculada sobre máscaras. A documentação de avaliação COCO explicita essa distinção entre caixas e máscaras (COCO, ).

**Critérios de interpretação:** registrar se a unidade é paciente, imagem, objeto ou pixel; separar resultados específicos de hanseníase de médias globais; identificar médias macro, micro ou ponderadas; registrar denominadores nulos como indefinidos ou conforme a convenção explicitada no estudo. Diferenças entre métricas expressas em porcentagem devem ser apresentadas em pontos percentuais. M6 e M7 são dimensões de comparação, não métricas únicas universalmente definidas. Desempenhos de modelos diferentes em bases diferentes não isolam o efeito da mudança de distribuição.

O conjunto de métricas funciona como orientação para extração, não como lista fechada. Medidas adicionais reportadas pelos artigos, como MCC, devem ser registradas com sua definição e contexto. A análise de equidade não será restrição de elegibilidade dos artigos e não será presumida quando não houver resultados por grupo.

## 2.5 Avaliação e generalização dos modelos

A avaliação de um modelo depende do desenho do estudo e da relação entre os dados usados no desenvolvimento e aqueles usados na avaliação. Além do valor de uma métrica, é necessário identificar o conjunto avaliado, a unidade de análise e as classes consideradas. Em uma aplicação multiclasse, por exemplo, uma medida global não descreve necessariamente o desempenho para cada doença E05.

A generalização diz respeito ao comportamento do modelo em dados diferentes dos utilizados no seu desenvolvimento. Evidências obtidas em uma população ou conjunto específico devem ser interpretadas considerando suas condições de aquisição e composição. Para a análise por tons de pele, é necessário verificar se as características dos grupos são descritas e se as medidas são apresentadas separadamente; a simples presença de um grupo nas imagens não demonstra desempenho equivalente entre grupos E05, E23. Esses aspectos orientam a extração das evidências na revisão.

# 3 Revisão estruturada da literatura

A revisão de literatura foi planejada para identificar e analisar evidências sobre a avaliação de modelos de visão computacional aplicados a manifestações cutâneas associadas à hanseníase. A definição de uma questão, de um protocolo, de critérios de seleção e de procedimentos de extração e síntese é coerente com as orientações de Kitchenham e Charters (2007) para revisões sistemáticas em engenharia de software. O capítulo 4 de Wohlin et al. (2024, p. 51–56) apresenta a revisão sistemática como estudo secundário e organiza seu processo em planejamento, condução e relato. A obra fundamenta a definição de questões e critérios, a documentação da busca, a seleção e a extração orientada pelas questões de pesquisa. O procedimento adotado nesta revisão é descrito a seguir; suas etapas não devem ser interpretadas como a execução de um experimento controlado.

## 3.1 Planejamento e protocolo

O objetivo, o protocolo e os critérios foram organizados no Evidentia. A questão principal é: como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

As questões secundárias desdobram a questão principal em aspectos necessários à avaliação dos modelos: técnicas e abordagens utilizadas, dados e populações, procedimentos, métricas, desempenho entre grupos e generalização. A identificação dos veículos de publicação complementa a caracterização dos estudos. Conforme Kitchenham e Charters (2007), as questões de pesquisa orientam a definição dos dados a serem extraídos e sintetizados na revisão. A investigação foi detalhada nas seguintes questões secundárias:

1. Quais técnicas de visão computacional são usadas para identificar manifestações dermatológicas associadas à hanseníase?
2. Quais conjuntos de dados e populações são utilizados no desenvolvimento e na avaliação dos modelos?
3. Quais métodos e procedimentos são usados para avaliar o desempenho e quais resultados são relatados?
4. Quais métricas são usadas na avaliação e quais resultados são relatados?
5. Como o desempenho varia entre diferentes grupos ou tons de pele?

6. Quais modelos e abordagens de inteligência artificial são utilizados para identificar as manifestações dermatológicas associadas à doença?

7. Como a capacidade de generalização é avaliada, especialmente em conjuntos diferentes dos usados no treinamento?

8. Em que tipo de veículo o artigo foi publicado, como periódico ou conferência?

## 3.2 Estruturação da estratégia de busca

Para estruturar a estratégia de busca da revisão, adotou-se o modelo PICOC (*Population, Intervention, Comparison, Outcome, Context*) (KITCHENHAM; CHARTERS, 2007), que adapta a formulação clínica clássica do PICO (PAI et al., 2004) às particularidades da engenharia de software e dos sistemas computacionais aplicados à saúde. Na condução desta revisão, os componentes do PICOC foram definidos na ordem canônica do protocolo:

1. **População (*Population*)**: compreende a população tecnológica e metodológica sob investigação, representada por termos de visão computacional, inteligência artificial, redes neurais e aprendizado de máquina e profundo;

2. **Intervenção (*Intervention*)**: compreende os modelos, arquiteturas e algoritmos específicos de aprendizado de máquina empregados na análise e processamento das imagens cutâneas (tais como redes neurais convolucionais, *Transformers* e modelos de segmentação);

3. **Comparação (*Comparison*)**: **não aplicável**. Diferentemente de ensaios clínicos com grupos de controle fixos, esta revisão sistemática possui finalidade exploratória e descritiva, voltada a mapear de forma abrangente o estado da arte e todas as abordagens existentes de visão computacional voltadas à hanseníase. Dessa forma, a busca não foi condicionada a um grupo de controle, linha de base comparativa ou algoritmo específico de referência, acolhendo quaisquer configurações reportadas nos estudos primários;

4. **Resultado (*Outcome*)**: abrange os termos associados à avaliação empírica de desempenho, métricas quantitativas diagnósticas (como acurácia, sensibilidade, especificidade, precisão, revocação e área sob a curva ROC) e tarefas de detecção, classificação ou segmentação;

5. **Contexto (*Context*)**: delimita o domínio temático e clínico da aplicação, abrangendo a hanseníase (*leprosy, Hansen's disease*) e a análise dermatológica de lesões cutâneas.

As perguntas de pesquisa e a relação completa de termos, incluindo sinônimos e operadores de truncamento, foram consolidadas no *prompt* estruturado submetido à plataforma Consensus, apresentado na Subseção 3.2.2 (Quadro 3.1).

A Figura 3 apresenta a representação conceitual clássica do modelo PICO de Pai et al. (2004), originalmente concebida no contexto de revisões sistemáticas em saúde. Nela, os componentes de *population/patient*, *intervention*, *comparison* e *outcome* são ilustrados como círculos cujas interseções concentram os estudos mais relevantes da busca. Para manter a coerência terminológica com o modelo PICOC adotado nesta revisão, o termo original em língua inglesa (*patient*) foi traduzido e adaptado como **População**. O modelo PICOC estende essa formulação clássica ao incorporar formalmente o componente de **Contexto**. No procedimento deste trabalho, a busca orientou-se pelas facetas de População, Intervenção, Resultado e Contexto, explicitando-se o componente de Comparação como não aplicável; a figura ilustra o modelo conceitual PICO e não afirma que uma busca booleana estrita idêntica à esquematizada foi executada.

Figura 3 – Representação dos componentes PICO para uma estratégia de busca




Fonte: Adaptado de Pai et al. (2004, p. 89, Figura 3).

### 3.2.1 Definição dos componentes PICOC e string de busca

A formulação da estratégia de busca orientou-se pela adaptação dos elementos do modelo PICOC (*Population, Intervention, Comparison, Outcome, Context*) (PAI et al., 2004; KITCHENHAM; CHARTERS, 2007), permitindo delimitar termos centrais e sinônimos relevantes para recuperar estudos que investigam a aplicação de visão computacional e inteligência artificial no diagnóstico da hanseníase. A Tabela 3 detalha os termos centrais e os operadores de expansão semântica definidos para cada faceta do pro-

tocolo na ordem do modelo PICOC, formalizando a não aplicabilidade do componente de Comparação.

Tabela 3 – Componentes do modelo PICOC adaptado e termos de busca

| **Elemento** | **Termo Central** | **Sinônimos e Termos Relacionados** |
|---|---|---|
| **População** (*Population*) | *Computer Vision* / IA | *artificial intelligence*, *CNN*, *convolutional neural network**, *deep learning*, *machine learning*, *neural network** |
| **Intervenção** (*Intervention*) | Modelos de Aprendizado | *ResNet**, *DenseNet**, *EfficientNet**, *U-Net*, *UNet*, *Attention U-Net*, *Vision Transformer**, *ViT*, *ConvNeXt**, *Swin Transformer**, *transfer learning*, *supervised learning* |
| **Comparação** (*Comparison*) | Não aplicável | Não aplicável ao escopo da revisão (mapeamento abrangente sem restrição a grupo de controle ou modelo de referência específico) |
| **Resultado** (*Outcome*) | Desempenho e Métricas | *accuracy*, *AUC*, *ROC-AUC*, *sensitivity*, *specificity*, *precision*, *recall*, *F1-score*, *detection*, *diagnosis*, *evaluation*, *segmentation* |
| **Contexto** (*Context*) | Hanseníase | *leprosy*, *Hansen disease*, *Hansen's disease*, *hanseniasis*, *skin lesion classification*, *skin lesion segmentation* |

Fonte: Autores.

A partir do mapeamento dos componentes, a string de busca foi estruturada aplicando o operador lógico booleano `OR` entre os termos e sinônimos no interior de cada dimensão temática, e o operador booleano `AND` para conectar as quatro facetas fundamentais do protocolo (*População* `AND` *Intervenção* `AND` *Resultado* `AND` *Contexto*). A consulta booleana estruturada é apresentada a seguir:

```
( "Computer Vision"OR "artificial intelligence"OR "CNN"OR "convolutional neural
network*"OR "deep learning"OR "machine learning"OR "neural network*")
AND
( "ResNet*"OR "DenseNet*"OR "EfficientNet*"OR "U-Net"OR "UNet"OR "Vision
Transformer*"OR "ViT"OR "transfer learning"OR "supervised learning"OR "Few-shot")
AND
( "accuracy"OR "AUC"OR "sensitivity"OR "specificity"OR "precision"OR "recall"OR
"F1-score"OR "ROC-AUC"OR "evaluation"OR "detection"OR "segmentation")
AND
( "leprosy"OR "Hansen disease"OR "Hansen's disease"OR "hanseniasis"OR "skin
lesion classification"OR "skin lesion segmentation")
```

### 3.2.2 Prompt estruturado submetido à plataforma Consensus

Diferentemente dos motores de busca acadêmicos convencionais baseados exclusivamente na correspondência estrita de operadores booleanos, a plataforma Consensus

emprega inteligência artificial para recuperação semântica em grafos de citações e literatura biomédica. Por essa razão, a formulação submetida à ferramenta integrou a questão norteadora principal, as oito perguntas secundárias da revisão e a totalidade dos termos e sinônimos delimitados na matriz PICOC em um *prompt* estruturado em língua inglesa.

O Quadro 3.1 reproduz integralmente a solicitação submetida à plataforma Consensus, preservando a sintaxe original, a estrutura das facetas conceituais e os operadores de truncamento aplicados aos termos técnicos.

Quadro 3.1 – Prompt estruturado em linguagem natural submetido à plataforma Consensus

```
find articles for the following components of my systematic research.
main research Question:
How can we evaluate the performance of computer vision models applied to identifying patterns
    associated with leprosy in skin images, within the context of the Brazilian public health
    system?
secondary questions:
What computer vision techniques are used to identify dermatological manifestations associated
    with leprosy?
What datasets and populations are used in the development and evaluation of these models?
What methods and procedures are used to evaluate the performance of these models, and what
    results are reported?
What metrics are used to evaluate the performance of these models, and what results are
    reported?
How does the performance of the models vary between different groups or skin tones?
What artificial intelligence models and approaches are used to identify dermatological
    manifestations associated with leprosy?
How is the generalization capacity of the models evaluated, especially when using datasets
    different from those used in training?
In what type of publication venue was the article published? (journal, conference)

PICOC:
Keyword and Synonyms
Population:
Computer Vision
artificial intelligence
CNN
convolutional neural network*
deep learning
machine learning
neural network*
Context:
leprosy
Hansen disease
hanseniasis
Hansen's disease
skin lesion classification
skin lesion segmentation

Intervention:
Machine Learning Models
Attention U-Net
capsule network*
ConvNeXt*
```

```
DenseNet*
EfficientNet*
MedSAM
multi-task learning
ResNet*
ResUNet
SAM3
Segment Anything Model
self-supervised learning
semi-supervised learning
supervised learning
Swin Transformer*
transfer learning
U-Net
UNet
unsupervised learning
Vision Transformer*
ViT

Outcome:
performance
accuracy
AUC
classification
detection
diagnosis
evaluation
F1 score
F1-score
identification
precision
recall
recognition
ROC-AUC
segmentation
sensitivity
specificity
```

**Fonte:** Autores.

### 3.2.3 Consultas apresentadas pelo Consensus

Na busca de 25 de setembro de 2026, o Consensus apresentou uma sequência de consultas em quatro rodadas. A Tabela 4 reproduz os textos e indicadores exibidos. Esses indicadores são saídas internas da ferramenta e não correspondem, por si só, a contagens auditadas de estudos únicos triados pela dupla.

Tabela 4 – Consultas e indicadores apresentados pelo Consensus

| Rodada | Consulta | Indicador |
|---|---|---|
| 1 | deep learning convolutional neural network leprosy Hansen disease skin lesion classification detection diagnosis | 95,3 mil |
| 1 | U-Net ResNet EfficientNet Vision Transformer skin lesion segmentation leprosy hanseniasis dermatological pattern recognition | 2,3 mil |

| Rodada | Consulta | Indicador |
|---|---|---|
| 1 | machine learning model performance evaluation accuracy AUC F1 sensitivity specificity leprosy skin image diagnosis | 63,5 mil |
| 1 | skin tone fairness demographic subgroup performance dermatology AI model external validation generalization cross-dataset | 67,4 mil |
| 2 | leprosy skin image dataset Brazil public health AI diagnosis computer vision | 26,2 mil |
| 2 | transfer learning self-supervised semi-supervised learning skin neglected tropical disease leprosy image classification | 36,6 mil |
| 2 | WHO skin neglected tropical diseases mobile application telemedicine leprosy detection low-resource settings | 63,4 mil |
| 3 | explainability XAI Grad-CAM interpretable AI leprosy neglected tropical disease skin lesion diagnosis | 1,6 mil |
| 3 | histopathological image analysis acid-fast bacilli detection deep learning leprosy nerve biopsy microscopy | 17,6 mil |
| 4 | leprosy skin image dataset multimodal clinical metadata paucibacillary multibacillary classification AI model | 3 mil |
| 4 | reporting standards quality assessment QUADAS CONSORT-AI CLEAR dermatology AI model evaluation systematic review | 47,8 mil |

A pesquisa na *Consensus* foi feita no modo *Deep*, com 19 etapas. A plataforma descreve *Retrieved* de 425,4 mil como o total de trabalhos encontrados nas buscas; *Eligible* de mil como os trabalhos considerados relevantes após a deduplicação da ferramenta; e *Included* de 100 como os trabalhos selecionados pela ferramenta para a análise final. Essas descrições não esclarecem integralmente os critérios e procedimentos internos utilizados.

Após a segunda rodada, o histórico indica uma expansão por grafo de citações a partir de dez trabalhos iniciais, com 662 trabalhos associados; após a terceira, indica a leitura de 12 resumos; antes da síntese, registra a leitura de resumos e PDFs de 100 trabalhos. A busca também foi ampliada para temas relacionados, como dermatologia geral, equidade, saúde móvel, microscopia, histopatologia e diretrizes de relato. A presença de uma referência na saída da ferramenta não significa que ela atenda aos critérios da revisão. Os 100 registros retornados pelo Consensus foram salvos pelos autores e compuseram, juntamente com os registros obtidos na busca complementar pelo Claude, a base inicial submetida à deduplicação e à triagem.

## 3.3 Realização da busca e seleção dos artigos

Para conferir rigor metodológico, reprodutibilidade e transparência à revisão estruturada da literatura, o processo de identificação, deduplicação, triagem por título e resumo, avaliação de elegibilidade e extração foi conduzido por meio de um fluxo de trabalho assistido por ferramentas de inteligência artificial especializadas, articuladas sob contínuo julgamento crítico e validação por pares da dupla de pesquisadores.

A Figura 4 ilustra o fluxo metodológico integrado, evidenciando as seis etapas da revisão, os volumes documentais em cada transição e a atuação específica de cada ferramenta de apoio (*Consensus*, *Claude*, *JevReviewer* e *Evidentia Review*).

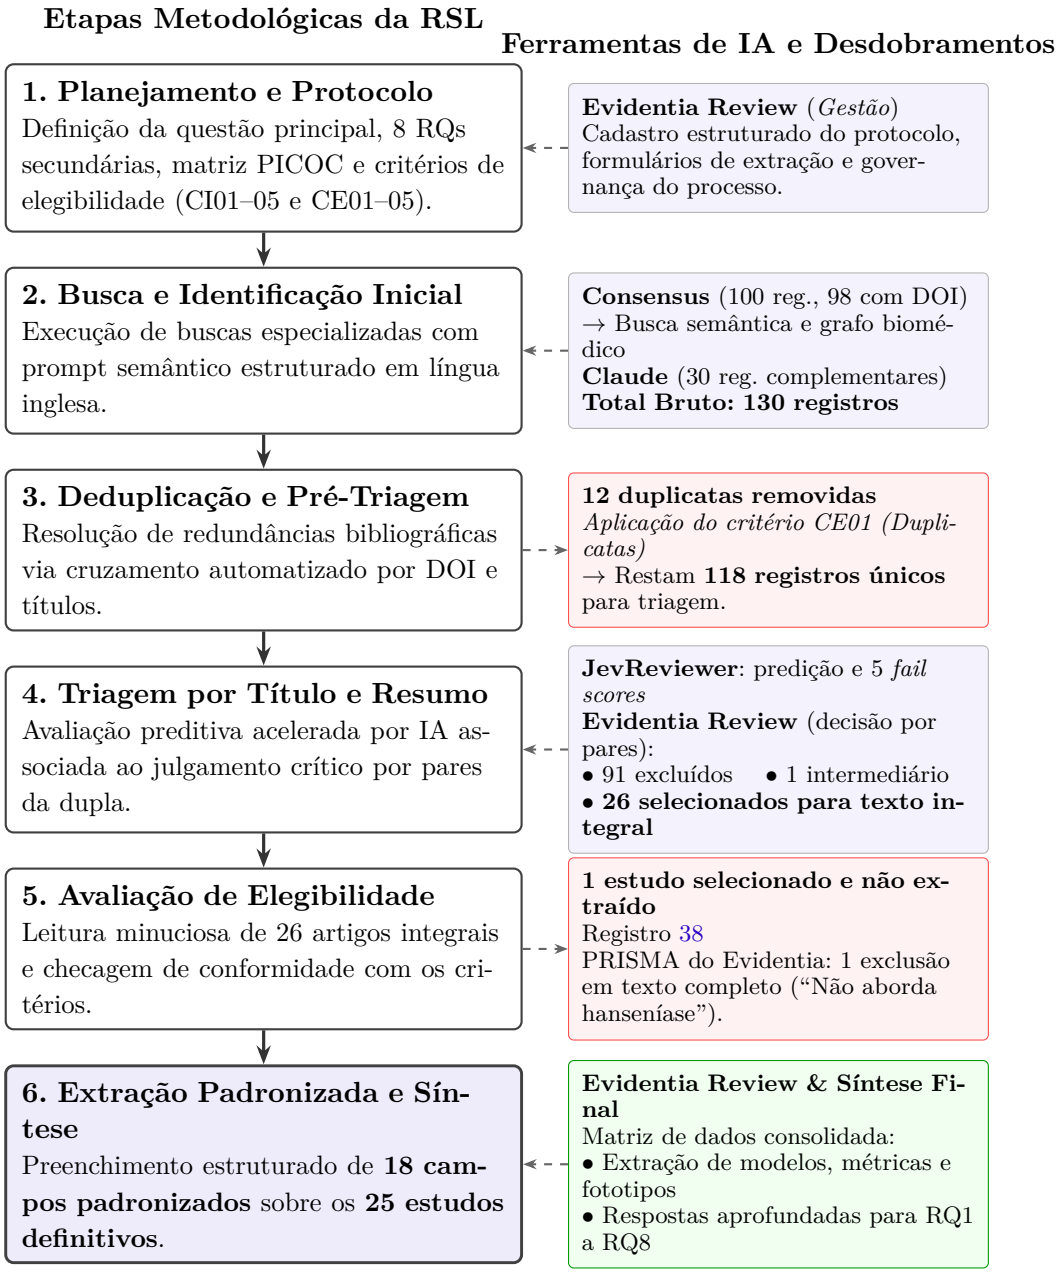



Figura 4 – Fluxo metodológico da Revisão Estruturada da Literatura assistido por ferramentas de inteligência artificial

Fonte: Autores.

### 3.3.1 Busca e identificação dos registros

O protocolo da revisão foi organizado no Evidentia a partir da questão de pesquisa e dos componentes do PICOC. Esses elementos foram utilizados em uma solicitação em inglês ao Consensus, sem a inclusão dos critérios de seleção no texto do *prompt*. Em 25 de setembro de 2026, a ferramenta retornou uma lista de 100 referências, que foi salva pelos autores, das quais 98 tinham DOI informado. Foi registrada também uma busca complementar por meio do Claude, da qual foram reunidas 30 referências. A data, o *prompt*, o modelo, a configuração e a lista completa dessa busca complementar ainda precisam ser confirmados. Embora o protocolo também registre a Scopus como fonte, não há comprovação de uma busca separada nessa base na etapa descrita.

As duas listas somaram 130 registros e, após a remoção de duplicatas, permaneceram 118 para triagem. A diferença entre esses totais corresponde a 12 registros removidos; entretanto, os pares considerados duplicados e o procedimento usado para identificá-los ainda não foram integralmente documentados. O conjunto bibliográfico disponível contém 129 entradas. Na comparação com os 118 registros triados, onze entradas não aparecem no conjunto de triagem e apresentam o mesmo DOI de outras entradas nele representadas. Essa comparação permite identificar 11 pares de registros com DOI coincidente, mas não identifica um eventual décimo segundo registro removido nem comprova, isoladamente, quando cada par foi deduplicado. A diferença entre as 129 entradas identificadas e os 130 registros informados no relato permanece a esclarecer. Os indicadores internos apresentados pelo Consensus não foram tratados como quantidades auditadas de estudos únicos examinados pelos pesquisadores. Após a reunião dos registros do Consensus e do Claude e a deduplicação, o Jev apoiou a classificação preliminar e os autores registraram as decisões de triagem no Evidentia, como descrito na subseção seguinte.

### 3.3.2 Critérios de seleção

Os critérios de inclusão foram: disponibilidade do texto completo (CI01); uso de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar manifestações cutâneas humanas associadas à hanseníase (CI02); relato ou síntese de evidências de avaliação de métodos de inteligência artificial para hanseníase, incluindo experimentos, testes, validação ou comparação de desempenho (CI03); uso, análise ou revisão de fotografias clínicas ou imagens dermatoscópicas de lesões cutâneas humanas associadas à hanseníase (CI04); e inclusão da hanseníase entre as condições avaliadas em trabalhos que abordam múltiplas doenças (CI05). A formulação preservada do CI03 foi recebida truncada após “resultados de estu”; o trecho descrito acima resume apenas a parte legível e sua redação integral deve ser confirmada. Os critérios abrangem estudos primários e revisões, que devem ser distinguidos durante a extração.

Foram informados os seguintes critérios de exclusão: registro duplicado de artigo já considerado (CE01); publicação anterior a 2020 (CE02); texto completo em idioma diferente de inglês ou português (CE03); uso exclusivo de inteligência artificial generativa como intervenção (CE04); e ausência de abordagem da hanseníase (CE05). A verificação de disponibilidade e idioma do texto completo pode depender de consulta além do título e do resumo, enquanto data e duplicidade também dependem dos metadados.

### 3.3.3 Triagem e seleção para leitura integral

O Jev Reviewer foi utilizado como apoio à classificação preliminar dos 118 registros. Para cada registro, suas sugestões são acompanhadas de valores associados ao não atendimento de cinco critérios:

1. Abordar a hanseníase como condição investigada ou avaliada, isoladamente ou entre outras doenças; uma menção apenas introdutória não atende a esse critério.
2. Utilizar fotografias clínicas ou imagens dermatoscópicas de manifestações cutâneas humanas associadas à hanseníase, ou revisar estudos que utilizam essas imagens.
3. Aplicar ou analisar métodos de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar essas manifestações nas imagens, incluindo revisões dessas aplicações.
4. Relatar ou sintetizar evidências de avaliação desses métodos, como experimentos, testes, validação, comparação de desempenho ou resultados de estudos.
5. Não se limitar exclusivamente à inteligência artificial generativa como intervenção.

Esses cinco critérios descrevem o que foi avaliado pelo Jev; eles não substituem os critérios gerais de inclusão e exclusão da revisão. Os valores de `fails` acompanham a avaliação automatizada e não registram, por si sós, a justificativa da decisão dos pesquisadores. Após a classificação preliminar, a dupla relatou ter revisado os registros por título e resumo, com as decisões registradas no Evidentia. A documentação não esclarece se ambos avaliaram todos os registros de maneira independente. A avaliação por dois ou mais pesquisadores, ao menos para uma amostra, é recomendada por Wohlin et al. (2024, p. 55); essa recomendação não demonstra que ela foi executada neste trabalho.

As sugestões do Jev para os 118 registros foram: duas de inclusão, 15 incertas e 101 de exclusão. O cruzamento por título entre as sugestões e as decisões do Evidentia identificou correspondência para todos os registros. Entre os 26 com situação de inclusão no Evidentia, dois tinham sugestão de inclusão do Jev, 11 tinham sugestão incerta e 13 tinham sugestão de exclusão. Entre os 91 excluídos no Evidentia, 87 tinham sugestão de exclusão e quatro tinham sugestão incerta. O registro restante, classificado como intermediário no Evidentia, tinha sugestão de exclusão pelo Jev. Assim, as sugestões automáticas são distintas das decisões de triagem. A data de execução, o modelo, a configuração completa e a versão da ferramenta não foram identificados; os cinco critérios exibidos acima, por sua vez, estão registrados nas avaliações disponíveis.

Os estados intermediários da triagem registram, em uma etapa, 12 inclusões, 32 exclusões, 15 decisões intermediárias e 59 registros sem decisão. Em outro estado foram observadas 19 inclusões, 40 exclusões e os mesmos 59 registros sem decisão; as 15 decisões intermediárias passaram a sete inclusões e oito exclusões. As datas das decisões preenchidas indicam 28 de setembro de 2026, mas não registram horário de cada decisão. Esses estados intermediários não devem ser confundidos com o resultado consolidado descrito a seguir.

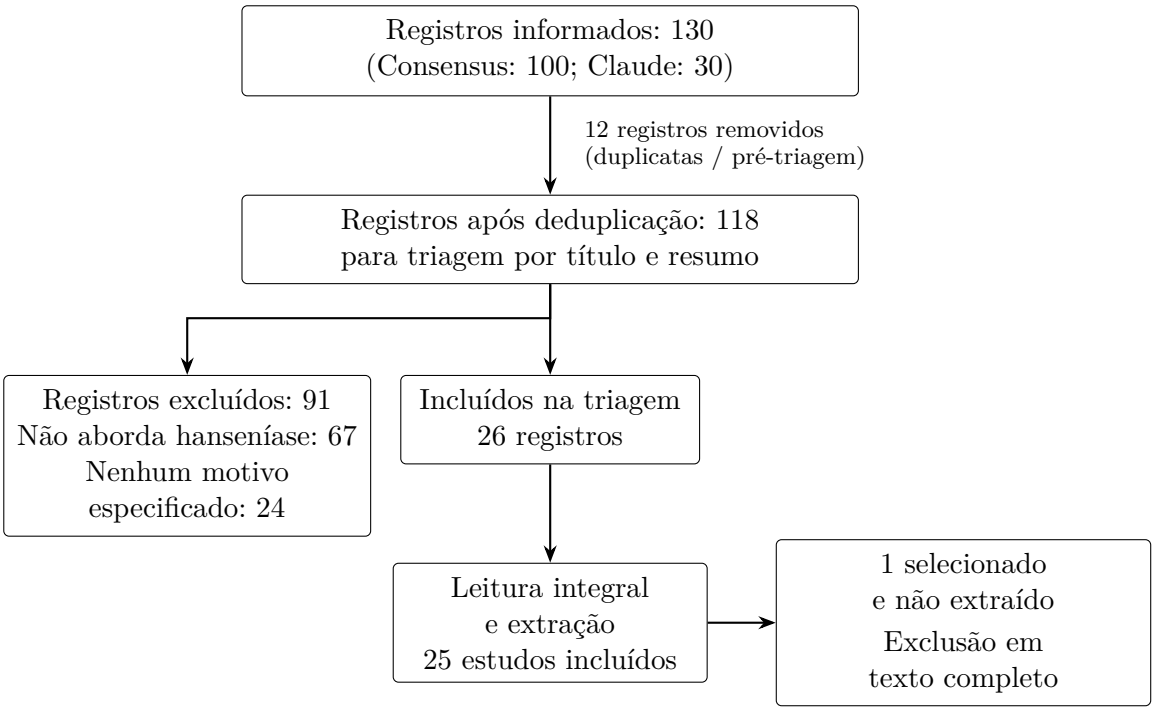
No Evidentia, 91 registros apresentam decisão de exclusão, 26 de inclusão e uma decisão intermediária, totalizando 118 registros (Tabela 12, Apêndice A). Esse último registro, *Leprosy Screening Based on Artificial Intelligence: Development of a Cross-Platform App* (registro 9), apresenta duas decisões individuais de exclusão, mas sua decisão consolidada foi registrada manualmente como intermediária. Em outro registro, *Leprosy lesion recognition using convolutional neural networks* (registro 90), houve uma decisão individual de inclusão e uma de exclusão; o conflito foi resolvido manualmente com decisão consolidada de exclusão. Os demais 116 registros possuem decisão consolidada automática, segundo o campo correspondente no Evidentia. Essa classificação descreve o mecanismo de consolidação registrado pelo sistema e não identifica uma revisão independente por ambos os pesquisadores para cada artigo.

A decomposição 91 exclusões, 26 inclusões e uma decisão intermediária esclarece a diferença observada no registro anterior: 118 menos 26 é 92, mas esse resultado reúne os 91 excluídos e o registro intermediário. Assim, não se deve representar a diferença de 92 como 92 exclusões. Os 26 registros com

situação de inclusão na triagem constituíram o conjunto encaminhado à leitura integral. Após a análise aprofundada dos textos completos e verificação dos critérios de elegibilidade no formulário de extração, 25 estudos foram confirmados e integralmente extraídos. O registro 38 está entre os 26 e não consta da extração final. As fontes registram coisas diferentes a seu respeito: o relatório PRISMA do Evidentia (03/11/2026) registra uma exclusão em texto completo, com o motivo "Não aborda hanseníase"; o título do artigo trata de imagens dermatológicas geradas por inteligência artificial; e as planilhas de triagem não registram motivo de exclusão para esse registro (decisão de inclusão).

A Figura 5 sintetiza as quantidades descritas nesta seção; os 118 registros e sua situação estão listados na Tabela 12 (Apêndice A). A indicação de 12 registros removidos corresponde à diferença entre 130 e 118, decorrente da deduplicação das fontes de identificação. O processo culminou na seleção definitiva de 25 estudos para extração e síntese. Segundo o relatório PRISMA do Evidentia, dos 91 registros excluídos por título e resumo, 67 têm o motivo "Não aborda hanseníase" e 24 não têm motivo registrado; as planilhas de triagem não registram o motivo de cada exclusão.

Figura 5 – Fluxo de identificação, triagem e inclusão dos estudos




Fonte: Autores.

O formulário de extração no sistema Evidentia reúne os 25 estudos incluídos definitivamente após a leitura integral e verificação de elegibilidade, com todos os seus 18 campos padronizados integralmente preenchidos. Entre os 26 registros pré-selecionados na triagem, o estudo *AI-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study* (registro 38) não integrou a extração final; o relatório PRISMA do Evidentia registra uma exclusão em texto completo, com o motivo "Não aborda hanseníase", e as planilhas de triagem não registram motivo de exclusão por registro.

Quanto à rastreabilidade do processo de seleção, os motivos de exclusão constam apenas de forma agregada no relatório PRISMA do Evidentia: dos 91 registros excluídos por título e resumo, 67 com o motivo "Não aborda hanseníase" e 24 sem motivo registrado; as planilhas de triagem não registram

Tabela 5 – Quantidades documentadas na identificação, triagem e inclusão dos estudos

| Etapa ou registro | Quantidade |
|---|---|
| Referências informadas do Consensus | 100 |
| Referências informadas do Claude | 30 |
| Registros reunidos | 130 |
| Registros removidos na pré-triagem (duplicatas) | 12 |
| Registros submetidos à triagem no Evidentia | 118 |
| Excluídos na triagem por título e resumo | 91 |
| Incluídos na triagem para leitura integral | 26 |
| Decisão intermediária (avaliada e resolvida) | 1 |
| Selecionado para leitura integral e não extraído | 1 |
| Estudos incluídos definitivamente com extração completa | 25 |

Fonte: Autores.

o motivo de cada exclusão. Com a resolução das divergências e a conclusão da leitura aprofundada, consolidou-se o conjunto definitivo de 25 estudos que subsidiam as análises empíricas desta monografia.

### 3.3.4 Extração e síntese das evidências

Conforme Wohlin et al. (2024, p. 55–56), o formulário de extração deve ser orientado pelas questões de pesquisa e permitir o registro das características dos estudos e dos dados necessários à síntese. Neste trabalho, o formulário foi organizado para registrar título, autores, ano, fonte, tipo de estudo e veículo, além das respostas detalhadas às questões da revisão: técnicas de visão computacional, bases de dados, características das populações, manifestações cutâneas, quantidade de imagens, métodos e procedimentos de avaliação, métricas, resultados obtidos, informações sobre tons de pele, modelos de inteligência artificial, avaliação de generalização, métodos de validação e limitações relatadas. A extração completa dos 25 estudos permitiu correlacionar sistematicamente cada achado com as páginas e tabelas de origem, distinguindo rigorosamente estudos primários e revisões para evitar atribuições indevidas de métricas secundárias.

A síntese apresentada a seguir distingue formalmente as tarefas de classificação diagnóstica, detecção e segmentação de feridas, bem como compara os desempenhos globais multiclasse com os resultados específicos obtidos para hanseníase. As lacunas documentadas a respeito da ausência de estratificação por tons de pele e as limitações de validação externa em bases independentes evidenciam a relevância científica do tema e balizam a discussão sobre a viabilidade e os riscos de implantação dessas ferramentas no SUS.

## 3.4 Resultados da revisão

Esta seção apresenta a síntese qualitativa e quantitativa das evidências extraídas dos 25 estudos primários e secundários incluídos definitivamente na revisão estruturada da literatura. Os dados foram extraídos a partir de formulário estruturado no Evidentia Review, composto por 18 campos padronizados, permitindo responder detalhadamente a cada uma das questões secundárias de pesquisa estabelecidas no protocolo.

Os estudos incluídos são referidos nesta monografia por identificador (ID), de E01 a E25, que remete, por hiperligação, à linha correspondente da Tabela 6, onde constam autores, ano, título, veículo, tipo de veículo, grupo e DOI. Os registros da triagem que não integram os 25 estudos incluídos são referidos por identificador numérico de 1 a 118 (por exemplo, registro 9), que remete à Tabela 12 (Apêndice A), com a totalidade dos 118 registros encontrados na busca e suas respectivas situações.

Tabela 6 – Estudos incluídos na revisão (n = 25), com identificador (ID). Grupos: A, desenvolve e avalia modelo; B, validação externa de modelo de terceiros; C, protocolo; D, revisão, perspectiva ou editorial

| ID | Autores | Ano | Título | Veículo | Tipo | Gr. | DOI |
|---|---|---|---|---|---|---|---|
| E01 | FERNANDES, J. R. N. et al. | 2024 | Artificial Intelligence on Diagnostic Aid of Leprosy: A Systematic Literature Review | Journal of Clinical Medicine | Revista | D | 10.3390/jcm13010180 |
| E02 | ANDRADE, H. G. V. de et al. | 2025 | On the usage of artificial intelligence in leprosy care: A systematic literature review | PLOS Computational Biology | Revista | D | 10.1371/journal.pcbi.1012550 |
| E03 | DEPS, P. D. et al. | 2024 | The potential role of artificial intelligence in the clinical management of Hansen's disease (leprosy) | Frontiers in Medicine | Revista | D | 10.3389/fmed.2024.1338598 |
| E04 | DEPS, P. et al. | 2026 | Independent assessment of the WHO Skin Neglected Tropical Diseases application for leprosy detection | Revista Panamericana de Salud Pública | Revista | B | 10.26633/RPSP.2026.40 |
| E05 | YOTSU, R. R. et al. | 2023 | Deep learning for AI-based diagnosis of skin-related neglected tropical diseases: A pilot study | PLOS Neglected Tropical Diseases | Revista | A | 10.1371/journal.pntd.0011230 |
| E06 | JITENDRA, R. et al. | 2024 | Deep Semantic Segmentation Assisted Region-of-Interest Sensitive Deep Spatio-Textural Feature Learning Framework for Leprosy Detection and Classification | SN Computer Science | Revista | A | 10.1007/s42979-024-03054-2 |
| E07 | STEYVE, N. et al. | 2022 | Optimized real-time diagnosis of neglected tropical diseases by automatic recognition of skin lesions | Informatics in Medicine Unlocked | Revista | A | 10.1016/j.imu.2022.101078 |
| E08 | VARGAS-CLAVIJO, M. et al. | 2025 | Evaluating Advanced Machine Learning Models for Histopathological Diagnosis of Hansen Disease | The American Journal of Dermatopathology | Revista | A | 10.1097/dad.0000000000002875 |

*continua na próxima página*

*Tabela 6 (continuação)*

| ID | Autores | Ano | Título | Veículo | Tipo | Gr. | DOI |
|---|---|---|---|---|---|---|---|
| E09 | GOSWAMI, A.; VERMA, S.; MARAK, A. | 2026 | Unveiling leprosy through machines: a review of artificial intelligence in a neglected tropical disease | Portuguese Journal of Dermatology and Venereology | Revista | D | 10.24875/PJDV.25000080 |
| E10 | PRAYITNO, B.; TRIYANTO, E. | 2026 | Utilization of digital health in the screening, diagnosis, and management of Morbus Hansen | Malahayati International Journal of Nursing and Health Science | Revista | D | 10.33024/minh.v9i4.3415 |
| E11 | SALL, D. et al. | 2025 | Potential of the World Health Organization's Skin NTDs App to Support and Improve the Detection of Skin-Related Neglected Tropical Diseases: Protocol for a Performance Evaluation and Feasibility Study in Senegal | JMIR Research Protocols | Revista | C | 10.2196/69420 |
| E12 | AHIKPA, E. D.; HIMABINDU, K. | 2025 | A Machine Learning-Based Diagnosis of Leprosy: Study | 2025 IEEE International Conference on Emerging Trends in Computing and Communication (ETCOM) | Conferência | D | 10.1109/ETCOM66606.2025.11436464 |
| E13 | BARBIERI, R. R. et al. | 2022 | Reimagining leprosy elimination with AI analysis of a combination of skin lesion images with demographic and clinical data | The Lancet Regional Health – Americas | Revista | A | 10.1016/j.lana.2022.100192 |
| E14 | BAWEJA, A. K.; ADITYA, S.; KANCHANA, M. | 2023 | Leprosy Diagnosis using Explainable Artificial Intelligence Techniques | 2023 International Conference on Sustainable Computing and Data Communication Systems (ICSCDS) | Conferência | A | 10.1109/ICSCDS56580.2023.10104958 |
| E15 | PONS, J. S. et al. | 2026 | The World Health Organization skin neglected tropical diseases app: A dynamic capacity-building training tool enhanced with artificial intelligence | Journal of Investigative Dermatology | Revista | A | 10.1016/j.jid.2026.03.043 |
| E16 | INNOCENT, D. C. et al. | 2026 | Explainable AI for differential diagnosis of skin-manifesting neglected tropical diseases (NTDS) in darker skin tones | BMC Artificial Intelligence | Revista | D | 10.1186/s44398-026-00033-w |

*continua na próxima página*

*Tabela 6 (continuação)*

| ID | Autores | Ano | Título | Veículo | Tipo | Gr. | DOI |
|---|---|---|---|---|---|---|---|
| E17 | BEESETTY, R. et al. | 2023 | Leprosy Skin Lesion Detection: An AI Approach Using Few Shot Learning in a Small Clinical Dataset | Indian Journal of Leprosy | Revista | A | não informado na fonte |
| E18 | JITENDRA, R. et al. | 2024 | Heuristic Segmentation Assisted Deep-Spatial Feature Learning Model for Leprosy Detection | SN Computer Science | Revista | A | 10.1007/s42979-024-03053-3 |
| E19 | GAWALI, C. J.; SUBBULAKSHMI, S. | 2024 | Enhancing Diagnosis of Infectious Skin Disease: A Professional Approach using Deep Learning for Leprosy Detection | 2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT) | Conferência | A | 10.1109/ICCCNT61001.2024.10725616 |
| E20 | YOTSU, R. R. et al. | 2025 | Harnessing artificial intelligence for skin-related neglected tropical diseases (skin NTDs): opportunities, challenges and future directions | International Health | Revista | D | 10.1093/inthealth/ihaf068 |
| E21 | SANCHEZ, K. et al. | 2024 | Co2Wounds-V2: Extended Chronic Wounds Dataset from Leprosy Patients | 2024 IEEE International Conference on Image Processing (ICIP) | Conferência | A | 10.1109/ICIP51287.2024.10647641 |
| E22 | MEHTA, J. et al. | 2026 | Integrative Image Processing Framework for Enhanced Detection of Leprosy-Associated Chronic Wounds | The International Journal of Lower Extremity Wounds | Revista | A | 10.1177/15347346251412645 |
| E23 | EITA, M. A.; RIZK, H. | 2025 | A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology | Engineering Applications of Artificial Intelligence | Revista | A | 10.1016/j.engappai.2025.111594 |
| E24 | JAIKISHORE, C. N.; UDUTALAPALLY, V.; DAS, D. | 2021 | AI Driven Edge Device for Screening Skin Lesion and Its Severity in Peripheral Communities | 2021 IEEE 18th India Council International Conference (INDICON) | Conferência | A | 10.1109/INDICON52576.2021.9691666 |
| E25 | BANERJEE, A. et al. | 2024 | Skin Diseases Detection Using LBP and WLD: An Ensembling Approach | SN Computer Science | Revista | A | 10.1007/s42979-023-02395-8 |

Fonte: Autores.

### 3.4.1 Quais técnicas de visão computacional são utilizadas?

A análise dos 25 estudos incluídos demonstra que as técnicas de visão computacional empregadas no contexto da hanseníase organizam-se ao longo de quatro etapas principais do fluxo de processamento

de imagens: pré-processamento, delimitação de regiões de interesse (segmentação), extração de atributos para classificação e explicabilidade visual.

No pré-processamento, identifica-se o predomínio de operações voltadas à atenuação da variabilidade de captura fotográfica em cenários ambulatoriais e comunitários. Destacam-se o redimensionamento padronizado (comumente para matrizes de $224 \times 224$ pixels em conformidade com as entradas de redes convolucionais pré-treinadas no ImageNet E15), equalização de contraste, filtragem adaptativa de ruídos e conversão para escala de cinza acompanhada de limiarização automática de Otsu E07. Observa-se ainda o recurso frequente ao recorte manual da lesão (*cropping*) e à anonimização por mascaramento seletivo E04, E25.

Para a tarefa de segmentação, a literatura divide-se entre abordagens semânticas profundas e métodos heurísticos clássicos. Enquanto estudos de feridas crônicas e sequelas neuropáticas utilizam arquiteturas baseadas em U-Net, DeepLabV3+ e SegNet para mapear bordas e classificar tecidos de granulação, esfacelo e necrose E21, E22, trabalhos voltados a lesões cutâneas ativas empregam agrupamento por *Fuzzy C-Means* otimizado pelo algoritmo do vaga-lume (*Firefly Algorithm*) E18; operações morfológicas de dilatação e erosão aparecem em E07.

Na etapa de extração e classificação, coexistem métodos tradicionais e modelos profundos. Um estudo exploratório aplica descritores manuais de textura, como *Local Binary Patterns* (LBP) e *Weber Local Descriptor* (WLD), fusionados a um classificador SVM multinível E25, e a revisão E12 relata, entre os estudos que revisa, o uso de SVM e de *Random Forest*. Contudo, o aprendizado profundo consolida-se como a abordagem hegemônica: destacam-se redes convolucionais como ResNet-50 E05, E13, VGG-16 E05, E19, MobileNetV2 E24 e Inception E13. Observa-se também a adoção de sistemas em cascata de dois estágios para diferenciação hierárquica entre dermatoses tropicais negligenciadas E04, E15 e a conversão de um modelo leve (MobileNetV2) para TensorFlow Lite, executado em aplicativo Android em dispositivo periférico (*edge computing*) E24.

Por fim, parte dos estudos incorpora técnicas de inteligência artificial explicável (XAI): mapas de saliência (*saliency maps*) em um detector YOLOv8n E23, e mapas de sensibilidade por oclusão e Grad-CAM em uma rede convolucional de quatro camadas E14; a revisão de E16 discute esses métodos e as pontuações de confiança. Essas técnicas buscam tornar interpretáveis as regiões salientes da lesão responsáveis pela decisão algorítmica, reforçando a viabilidade de integração das ferramentas como auxílio diagnóstico na atenção primária à saúde.

### 3.4.2 Quais conjuntos de dados e populações são utilizados?

A caracterização dos conjuntos de dados nos 25 estudos incluídos evidencia um volume acumulado superior a 89.000 imagens, divididas entre grandes iniciativas institucionais globais e conjuntos clínicos especializados desenvolvidos em centros de referência de países endêmicos.

No cenário internacional, destaca-se o repositório organizado no âmbito da Organização Mundial da Saúde (OMS) para o aplicativo WHO Skin NTDs E15, que reúne 74.806 imagens (5.760 de doenças tropicais negligenciadas cutâneas, 16.577 de outras doenças de pele, do *Fitzpatrick 17k*, 2.469 de pele sã, recortadas de imagens dessas doenças, e 50.000 imagens que não são de pele, selecionadas do ImageNet). Em contraste com bases genéricas, os estudos primários concentram-se em coletas clínicas locais realizadas nos principais polos endêmicos mundiais:

- **Brasil:** destaca-se a base pública *AI4Leprosy* E13, composta por 1.226 fotografias padronizadas em múltiplas escalas (panorâmica, close e borda) de 222 pacientes atendidos na Fundação Oswaldo Cruz (Fiocruz/RJ), além do banco de imagens clínicas usado na validação externa independente

do aplicativo da OMS E04, com 423 imagens de 208 casos de hanseníase confirmados, coletadas por especialistas entre 1996 e 2024.

- **Índia:** conjuntos expressivos são reportados no *Sivananda Rehabilitation Home* E17, com 1.931 fotografias multimodais (luz convencional, polarizada e dispositivos móveis) de 151 pacientes, e no banco *JUCMATER/Skindb.v1* E25, contendo 876 imagens de 141 indivíduos da *School of Tropical Medicine* de Calcutá.
- **África Subsaariana:** coletas de campo na Costa do Marfim e em Gana E05 totalizam 1.709 imagens de 506 pacientes, obtidas em condições de campo e em clínicas rurais, enquanto coletas em Camarões E07 reúnem 1.054 imagens focadas na diferenciação entre hanseníase, úlcera de Buruli e leishmaniose cutânea.
- **América Latina e feridas crônicas:** o conjunto aberto *Co2Wounds-V2* E21, E22 contribui com 764 imagens de úlceras crônicas plantares e sequelas neuropáticas de 96 pacientes colombianos, enquanto um estudo colombiano de histopatologia reúne 106 lâminas coradas por hematoxilina e eosina (55 pacientes e 51 controles), com 640 microfotografias E08.

Quanto às manifestações dermatológicas, os conjuntos contemplam o espectro clínico completo da doença: manchas hipocrômicas com alteração de sensibilidade, placas eritematosas infiltradas (formas tuberculoides e dimorfas), tubérculos e infiltrações difusas (forma virchowiana), além de úlceras neuropáticas crônicas. Um fator determinante observado é a inclusão de afecções mimetizadoras para treino e teste de especificidade diagnóstica, como leishmaniose tegumentar, tinha corporal, pitiríase versicolor, eczema e vitiligo.

Não obstante a abrangência geográfica, a revisão identifica um gargalo metodológico crítico: a escassez de registro individual do tom de pele. Apenas três dos 16 estudos com dados descrevem o tom de pele da base, e só dois trazem distribuição por fototipo ou faixa de tom (Subseção 3.4.5). Entre os estudos com dados, E04 registra também o sexo e a faixa etária das imagens (Tabela 1 do artigo). A falta de registro do tom de pele na maioria dos estudos dificulta auditorias algorítmicas de viés e restringe a comprovação da eficácia dos modelos quando transportados para a população multiétnica atendida pelo Sistema Único de Saúde (SUS).

### 3.4.3 Quais métodos e procedimentos de avaliação são empregados?

Os procedimentos de avaliação foram levantados nos 15 estudos que desenvolvem e avaliam um modelo (Tabela 7). Os outros 10 estudos incluídos são oito revisões, perspectivas ou editorial, um protocolo sem resultados E11 e a validação externa de um modelo pré-treinado E04, e não entram nessas contagens. Dos 15 estudos, 13 usam partição *hold-out* (por imagem, por paciente ou herdada do conjunto de dados), um divide as imagens por classes disjuntas E17 e um não descreve a divisão E07. A validação cruzada $k$-fold com $k$ declarado aparece em apenas um dos 15 E13, que combina *hold-out* por paciente com 5-*fold* nos pacientes de desenvolvimento; dois dos 13 *hold-out* citam também validação cruzada interna, sem declarar $k$.

Quanto à unidade de particionamento, apenas 2 dos 15 estudos declaram a separação por paciente E05, E13; os outros 13 não informam, e nenhum deles declara não a ter adotado, de modo que a falta de informação não equivale à ausência de separação. Em sete dos 13 a divisão descrita é feita sobre imagens (seis estudos) ou microfotografias (um) E08, E14, E15, E19, E23, E24, E25; em E25 e em E15 a unidade é inferida, pois os artigos descrevem apenas a proporção da divisão.

Quando múltiplas fotografias de um mesmo paciente são distribuídas aleatoriamente entre os conjuntos de treino e teste, ocorre vazamento de informação (*data leakage*), fazendo com que atributos

contextuais (como iluminação de fundo, tonalidade de pele do indivíduo e artefatos de câmera) facilitem o reconhecimento e resultem em desempenhos artificialmente otimistas. Esse risco não pode ser descartado nos 13 estudos que não informam a unidade da divisão.

Tabela 7 – Procedimento de avaliação e separação por paciente nos 15 estudos que desenvolvem e avaliam um modelo

| **Estudo** | **Unidade da divisão** | **Procedimento** | **Separação por paciente** |
|---|---|---|---|
| E05 | Paciente | *Hold-out* aleatório treino/teste, com $k$ de 30 a 70%; sem $k$-fold; sem teste externo descrito | Adotada (sem sobreposição de pacientes) |
| E13 | Paciente (teste) | *Hold-out* de 182/40 pacientes e 5-*fold* nos 182; o modelo de interpretação usa 10-*fold* repetido no conjunto completo (222), incluindo os 40 de teste; sem teste externo | Adotada no *hold-out* de teste (40 pacientes); unidade das dobras do 5-*fold* não detalhada no texto principal |
| E06 | Não informada | 70% treino e 30% *out-of-bag*, com validação cruzada sem $k$ declarado; ordem entre ampliação e partição não informada | Não informada |
| E18 | Não informada | 80% treino e 20% validação cruzada interna (sem $k$ declarado); provável sobreposição da base de 220/450 imagens com E06 | Não informada |
| E07 | Não informada | Divisão não descrita | Não informada |
| E08 | Microfotografia | *Hold-out* 80/20; sem $k$-fold; sem teste externo | Não informada |
| E19 | Imagem | Treino, validação e teste declarados como 1476/62/62 (soma 1.600, divergente do total informado de 1.476); sem teste externo | Não informada |
| E14 | Imagem (sorteio aleatório) | *Hold-out* 80:20; sem $k$-fold; ordem entre ampliação e divisão não especificada | Não informada |
| E15 | Imagem (inferida) | *Hold-out* estratificado 75/15/10; remoção de duplicatas por similaridade visual antes da divisão; sem teste externo | Não informada |
| E17 | Classe | Classes disjuntas (9 de treino e 7 de teste) e 320 tarefas episódicas; sem $k$-fold; sem teste externo | Não informada (divisão por classe) |
| E25 | Imagem (inferida) | *Hold-out* 4:1; partição utilizada no *grid search* de $C$ e $\gamma$ não detalhada | Não informada |

Tabela 7 – Procedimento de avaliação e separação por paciente (continuação)

| **Estudo** | **Unidade da divisão** | **Procedimento** | **Separação por paciente** |
|---|---|---|---|
| E21 | Não informada | *Hold-out* 485/122/157 (teste sem rótulos no repositório público); partição avaliada na Tabela 1 não explicitada | Não informada |
| E22 | Não informada | Mesmo *hold-out* 485/122/157; sem $k$-fold; métricas de teste reportadas embora o subconjunto de teste seja citado como não anotado | Não informada |
| E23 | Imagem aumentada | *Hold-out* 85/10/5 sobre o conjunto já ampliado; teste também em outra base | Não informada |
| E24 | Imagem | *Hold-out* 80/20 (1.220/304 imagens); aplicação de aumento de dados no teste não informada | Não informada |

Fonte: Elaboração própria a partir dos artigos incluídos (denominador 15). "Não informada" indica que o artigo não declara o procedimento; não equivale a "não adotada" (nenhum dos 15 declara não adotar). "Inferida": o artigo descreve só a proporção da divisão, e a unidade foi deduzida.

Outro achado é a escassez de avaliação em base distinta da usada no desenvolvimento: entre os 15 estudos, apenas um testa o modelo também em outra base E23, e os outros 14 avaliam o modelo somente na própria base. Fora dessa contagem, a exceção mais relevante no conjunto selecionado é a validação externa independente conduzida por E04, que submeteu o classificador pré-treinado da OMS a uma avaliação retrospectiva com 423 imagens de 208 casos de hanseníase de um banco de imagens clínicas coletadas entre 1996 e 2024.

### 3.4.4 Quais métricas e resultados são reportados?

Esta seção separa as métricas utilizadas por estudo (Tabela 8) dos valores reportados (Tabelas 9 e 10), organizados por tarefa: classificação, detecção e segmentação. Os valores não são comparáveis entre estudos, pois bases de dados, tarefas e procedimentos de avaliação diferem. Nos estudos de classificação, a acurácia é a métrica mais presente, acompanhada, conforme o estudo, de sensibilidade (*recall*), especificidade, precisão, escore $F_1$ e área sob a curva ROC (AUC). A detecção é avaliada por precisão, *recall*, $F_1$ e mAP E23, e a segmentação por mIoU ou IoU e $F_1$ E21, E22; nos dois estudos em que a segmentação é apenas uma etapa do *pipeline*, não há métrica de segmentação reportada. Valores ausentes estão indicados nas tabelas.

Tabela 8 – Métricas utilizadas por estudo (sem os valores reportados)

| **Estudo** | **Tarefa** | **Métricas utilizadas** |
|---|---|---|
| E05 | Classificação | Acurácia Top-1 e MCC; sem sensibilidade, especificidade, F1 nem Grad-CAM |
| E13 | Classificação | Acurácia, AUC, sensibilidade e especificidade |

Tabela 8 – Métricas utilizadas por estudo (continuação)

| **Estudo** | **Tarefa** | **Métricas utilizadas** |
|---|---|---|
| E06 | Classificação (segmentação como etapa) | Acurácia, precisão, *recall* e F-score; nenhuma métrica de segmentação |
| E18 | Classificação (segmentação como etapa) | Acurácia, precisão, *recall* e F-score (sensibilidade e especificidade só na introdução) |
| E07 | Classificação | Acurácia, especificidade, F-score, *recall*, coluna "precisão/sensibilidade" e tempo |
| E08 | Classificação | Acurácia, sensibilidade, especificidade, matriz de confusão e ROC |
| E19 | Classificação | Precisão, *recall* e F1; acurácia de treino e de validação |
| E14 | Classificação | Matriz de confusão, precisão, *recall*, F1, acurácia e ROC/AUC (AUC sem valor numérico) |
| E15 | Classificação | Sensibilidade, especificidade, acurácia, precisão, F1 e *top-k* |
| E17 | Classificação (*few-shot*) | Acurácia episódica; sensibilidade e especificidade (um contra todos) |
| E25 | Classificação | Apenas acurácia |
| E24 | Classificação | Acurácia, precisão, *recall*, F1 e perda; sem especificidade. O tamanho do modelo (cerca de 14 MB) é reportado; latência de inferência e uso de memória não foram medidos |
| E23 | Detecção | Precisão, *recall*, F1, mAP@50 e mAP@50-95; sem acurácia, AUC, ECE nem Brier |
| E21 | Segmentação | mIoU, F1, acurácia de pixel, precisão e *recall* |
| E22 | Segmentação | Precisão, *recall*, F1, IoU e acurácia |
| E04 | Avaliação de modelo pré-treinado | Sensibilidade Top-1 a Top-5 |

Fonte: Elaboração própria a partir dos artigos incluídos.

Tabela 9 – Resultados reportados nos estudos de classificação (valores literais dos artigos; não comparáveis entre linhas)

| **Estudo** | **Resultado reportado** | **Escopo** | **Valores ausentes** |
|---|---|---|---|
| E05 | Top-1 de 76,61 a 84,63% (Tabela 2, $k$ de 30 a 70%). Classe hanseníase: acerto de 12,0% e 13,0% (Fig. 1, Tarefa 2) | Global; hanseníase | Sensibilidade e especificidade não calculadas |

Tabela 9 – Resultados reportados nos estudos de classificação (continuação)

| **Estudo** | **Resultado reportado** | **Escopo** | **Valores ausentes** |
|---|---|---|---|
| E13 | Só imagem (ResNet-50, *close-up*, validação cruzada): acurácia 0,6660 e AUC 0,7456. Teste em 40 pacientes, *elastic-net* com saídas do Modelo 2 e informações do paciente (sem saídas de imagem): acurácia 90%, AUC 96,46%, sensibilidade 89 e especificidade 91; floresta aleatória só com informações do paciente: AUC 98,74% | Binário, nível de paciente | Erros-padrão no teste: $\pm 0,047$ (acurácia), $\pm 0,074$ (sensibilidade) e $\pm 0,061$ (especificidade) |
| E06 | RF com atributo híbrido: acurácia 97,24% (resumo: 97,20% e 97,80%), precisão 99,69, *recall* 95,82 e F 0,98. O valor 95,45% é o da árvore de decisão com o atributo híbrido | Binário | Número de imagens normais não informado |
| E18 | Híbrido GLCM+AlexNet: acurácia 96,6%, precisão 99,7, *recall* 95,8 e F 0,9771. Possível sobreposição de base com E06 | Binário | Número de imagens normais não informado |
| E07 | BHO-SVM: acurácia 96, especificidade 94, F-score 89, *recall* 90 e precisão/sensibilidade 92 (Tabela 2) | Global, 3 doenças | Nenhum valor isolado para hanseníase; pacientes não informados |
| E08 | ANN: acurácia 70%, sensibilidade 74%, especificidade 65%; DT 67/59/78; LR 65/55/78; SVM 61/47/80 (Tabela 3); AUC da ANN 0,71. RF: o texto traz 63/63/71 e a Tabela 3, 0,66/0,63/0,71 (inconsistência interna do artigo) | Binário (histopatologia) | — |
| E19 | EfficientNet B0: precisão 0,9138, *recall* 0,9298 e F1 0,9217 (Tabela I); acurácia de treino 0,95 e de validação 0,90. O resumo chama 0,9138 de "acurácia", divergindo da Tabela I | Binário | Acurácia de teste |
| E14 | LeprosyNet: acurácia 0,98, precisão 0,975, *recall* 0,98 e F1 0,975. Classe hanseníase (gráfico da Fig. 8): precisão 0,99, *recall* 0,97 e F1 0,98 | Global; hanseníase | AUC sem valor numérico; imagens e pacientes não informados |

Tabela 9 – Resultados reportados nos estudos de classificação (continuação)

| **Estudo** | **Resultado reportado** | **Escopo** | **Valores ausentes** |
|---|---|---|---|
| E15 | Global, top-1/top-5: sensibilidade 80,4/99,8, especificidade 98,7/62,4, acurácia 97,7/66,6. Hanseníase ($n = 41$), top-1/top-5: sensibilidade 87,8/97,6, especificidade 95,7/35,6, precisão 61,10/10,34 | Global; hanseníase | Média macro global entre 12 NTDs; métricas específicas de hanseníase com $n = 41$ (Tabela 2) |
| E17 | 2-*way* 1-*shot*: acurácia 73,13% (resumo: 73,12%; texto: 73,0%); sensibilidade/especificidade 72,39/73,66 (2-*way*) e 69,33/77,65 (3-*way*) | Hanseníase × demais | Proporção treino/teste |
| E25 | Acurácia 91,3793% (cogriWeberLBP e Multi-SVM); melhor CNN: 89 (ResNet101) | Global, 4 classes | Sensibilidade e especificidade |
| E24 | SkinLesion Net: acurácia de teste 94,32% (4 classes). Os 91% são da SeverityNet, que não inclui hanseníase | Global | Especificidade |
| E04 (validação externa) | Sensibilidade Top-5 84,9% (359/423); 87,2% nas lesões clássicas e 69,6% nas reacionais ou atípicas. Top-1: 46,9% (clássicas) e 30,4% (reacionais ou atípicas), por subconjunto; o artigo não traz Top-1 global | Só hanseníase | Especificidade, VPP, VPN e acurácia não calculáveis (só casos confirmados) |

Fonte: Elaboração própria a partir dos artigos incluídos.

Essa dispersão e heterogeneidade de resultados foi investigada sistematicamente na revisão de E02, que compilou o desempenho e as limitações reportadas pelos principais trabalhos primários da literatura, conforme sintetizado na Tabela 11.

Entretanto, a síntese quantitativa evidencia uma dicotomia fundamental entre acurácia laboratorial e eficácia diagnóstica real. Enquanto estudos primários relatam frequentemente valores superiores a 90% em testes internos fechados (acurácia de 98% em E14; precisão de 0,9138 e *recall* de 0,9298 em E19), a avaliação pormenorizada das matrizes de confusão demonstra que a acurácia global tende a mascarar taxas inaceitáveis de falso-negativo para hanseníase:

1. Na validação externa independente de E04, a sensibilidade Top-5 do aplicativo da OMS para hanseníase foi de 84,9% (359 de 423 imagens), mas a sensibilidade Top-1 foi de 46,9% nas lesões clássicas e de 30,4% nas lesões reacionais ou atípicas, calculadas por subconjunto; o artigo não traz Top-1 global nem especificidade.
2. No estudo piloto multicêntrico na Costa do Marfim e em Gana E05, a acurácia Top-1 situou-se entre 76,61% e 84,63%, mas a classe hanseníase teve taxa de acerto de apenas 12,0% a 13,0% (Tarefa 2).

Tabela 10 – Resultados reportados nos estudos de detecção e de segmentação

| **Estudo** | **Tarefa** | **Resultado reportado** | **Observação** |
|---|---|---|---|
| E23 | Detecção (YOLOv8n), 6 classes | Teste: P 90,4, R 85,6, F1 87,9 e mAP50 91,2. Em outra base: P 74,1, R 78,2, F1 76,0 e mAP50 82,4 | Inconsistência interna: texto cita mAP@0,5 = 0,858 e tabela reporta 91,2%; o artigo não lista as classes da segunda base |
| E21 | Segmentação binária (ferida × fundo) | Melhor mIoU 70,13 (U-Net/SegFormer; F1 79,26). DeepLabV3+/ResNet-101: mIoU 66,88 e F1 76,55 | Partição avaliada na Tabela 1 não discriminada (teste público é não anotado) |
| E22 | Segmentação binária | Teste: IoU 86,50 e F1 92,50. Validação: IoU 87,09 e F1 93,10 | Métricas de teste reportadas apesar de o subconjunto de teste ser citado como não anotado |

Fonte: Elaboração própria a partir dos artigos incluídos. Em E06 e em E18 a segmentação é etapa do *pipeline* e não há métrica de segmentação reportada.

3. No estudo *AI4Leprosy* E13, o modelo baseado exclusivamente em fotografias alcançou acurácia de 66,6% (AUC de 74,56%) em validação cruzada nos pacientes de desenvolvimento. No teste com 40 pacientes, a floresta aleatória que usa apenas as informações do paciente teve a maior AUC (98,74%); os autores escolheram, por causa do tamanho pequeno da amostra, a regressão logística *elastic-net* com as saídas do Modelo 2 (atributos clínicos da lesão) e as informações do paciente, mais simples e interpretável, que teve acurácia de 90% e AUC de 96,46%. O modelo escolhido não usa saídas do modelo de imagens.

Em dois dos estudos, o desempenho para a hanseníase (acerto da classe em E05; Top-1 em E04) foi bem inferior ao indicador global ou ao Top-5, o que ilustra que um indicador global pode esconder o desempenho para a doença, sem permitir uma conclusão geral. Em cenários de atenção primária no SUS, valores de acerto ou de sensibilidade inferiores a 50% para a hanseníase implicariam risco crítico de descarte indevido de casos ativos, postergando o tratamento com poliquimioterapia (PQT) e favorecendo a progressão de incapacidades físicas e a manutenção da cadeia de transmissão. A Figura 6 apresenta os valores literais reportados nos artigos: a acurácia de testes internos, de um lado, e a sensibilidade em avaliações externas ou na classe hanseníase, de outro. Os valores não são comparáveis entre estudos, pois bases, tarefas e procedimentos diferem.

### 3.4.5 Como o desempenho varia entre grupos ou tons de pele?

As questões relativas à caracterização do tom de pele (RQ5) e à comparação de desempenho entre diferentes fototipos cutâneos (RQ6) constituem o núcleo investigativo central deste trabalho. A síntese dos 25 estudos incluídos mostra uma lacuna empírica: nenhum dos 16 estudos com dados reporta,

Tabela 11 – Comparação de modelos de inteligência artificial para hanseníase e limitações relatadas (adaptado de E02, com valores conferidos nos artigos originais)

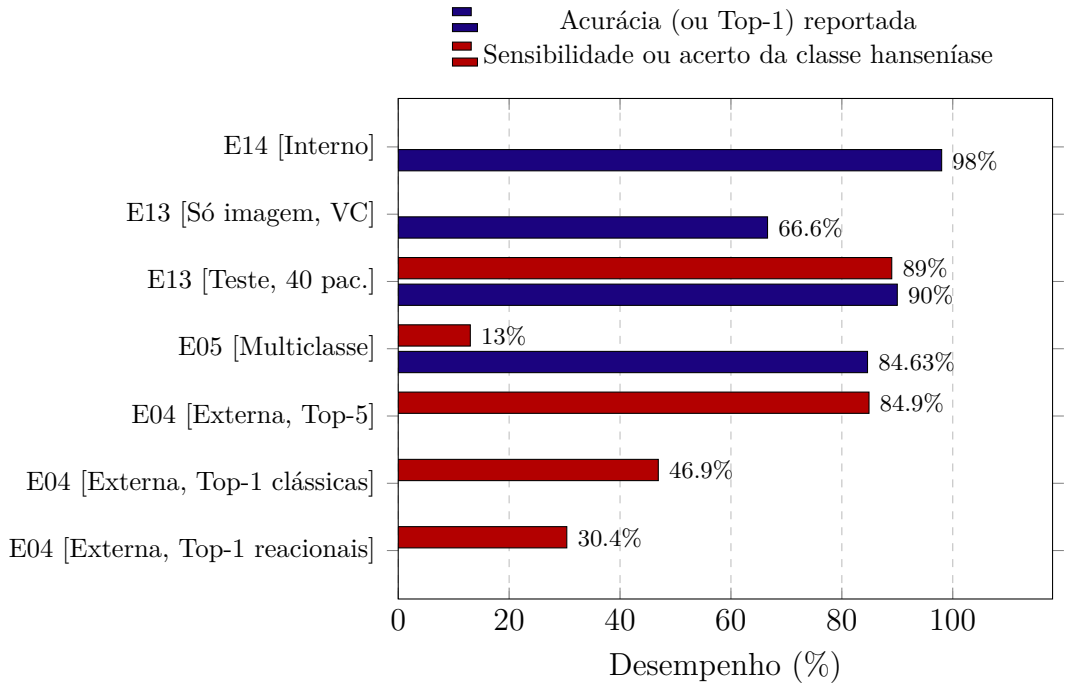
| **Estudo Primário** | **Problema Abordado** | **Melhor Métrica** | **Escopo** | **Limitação Reportada** |
|---|---|---|---|---|
| E14 | Classificação binária | Acurácia (98,0%) | Global | Necessita validação em múltiplos contextos clínicos. |
| E13 | Classificação binária | Acurácia (90%) e AUC (96,46%), teste em 40 pacientes | Nível de paciente | Requer bases mais diversas para generalização segura. |
| E07 | Multiclasse (NTDs) | Acurácia (96,0%) | Global, 3 doenças | Alta demanda computacional de processamento. |
| E24 | Multiclasse | Acurácia (94,32%) | Global, 4 classes | Aumento de dados pode introduzir vieses artificiais. |
| Registro 9 | Classificação binária (dados tabulares) | Acurácia (93,38%) | Dados tabulares (SINAN) | Inconsistências na base de dados utilizada. |
| E25 | Multiclasse | Acurácia (91,4%) | Global, 4 classes | Necessita validação entre diferentes regiões geográficas. |
| E17 | Multiclasse (*few-shot*) | Acurácia (73,13%) | Hanseníase × demais | Amostra restrita sujeita a viés de representatividade. |

Fonte: Adaptado de E02; valores conferidos nos artigos originais, exceto o registro 9, estudo de dados tabulares do SINAN, cujo valor (93,38%) foi conferido em E02 e não no artigo original.

no texto principal, desempenho por tom de pele, e só três descrevem o tom de pele da base.

No que tange à caracterização do tom de pele (RQ5), três dos 16 estudos com dados descrevem a base, em níveis diferentes. E15 categoriza as imagens de treino em peles claras (4%, fototipos I-II), moderadas (26%, III-IV) e escuras (70%, V-VI) (Tabela 3 do artigo). E04 registra o fototipo de Fitzpatrick de 411 das 423 imagens (Tabela 1 do artigo; o fototipo I não foi observado): nas lesões clássicas (subconjunto 1, 362 das 367 imagens com metadados), 1,1% de fototipo II, 52,5% de III, 18,5% de IV, 16,6% de V e 11,3% de VI; no subconjunto de reações e formas atípicas (n = 56), 7,1% de II, 64,3% de III, 8,9% de IV, 0% de V e 7,1% de VI, com 12,5% sem registro. E05 apenas afirma que todas as imagens são de populações africanas de pele escura, com fototipo IV ou superior, sem apresentar a distribuição. Os outros 13 estudos com dados não informam o tom de pele: cinco mencionam diversidade, limitação ou um campo de registro de tom sem apresentar dados E06, E13, E17, E18, E23, e oito não o mencionam no texto principal E07, E08, E14, E19, E21, E22, E24, E25. No *AI4Leprosy* E13, os autores descrevem imagens com "diversidade de manifestações clínicas e tipos de pele", obtidas em um centro de referência nacional que recebe pacientes de todo o Brasil, sem escala nem distribuição por tom. "Não informa" indica que o texto principal não traz dado utilizável de tom de pele e não equivale a "não avalia", pois figuras e suplementos não foram examinados.

Figura 6 – Acurácia reportada em testes internos e sensibilidade reportada para hanseníase em avaliações externas ou por classe



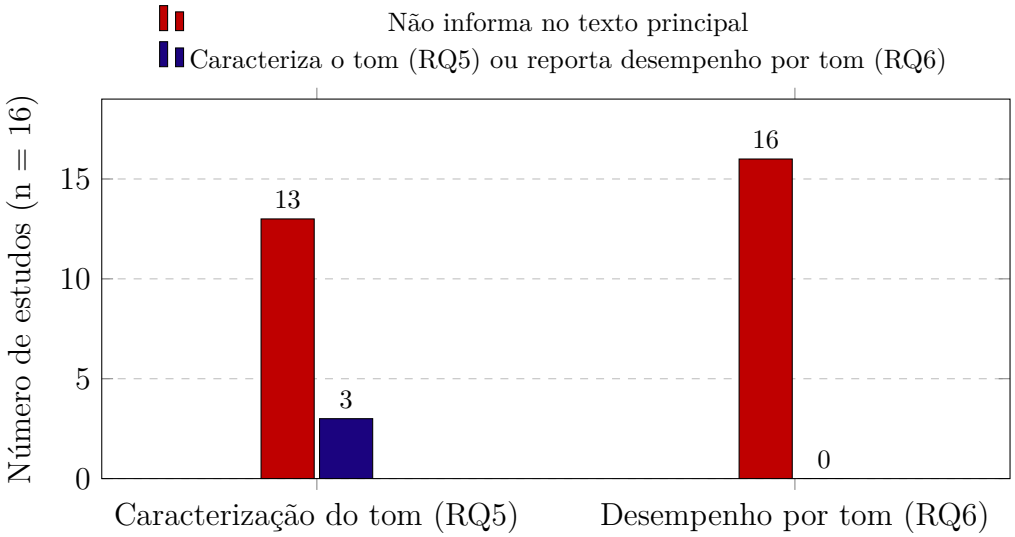

Fonte: Autores, com os valores literais dos artigos (Tabela 9). Barra ausente indica valor não reportado ou não verificado. E05: maior Top-1 (faixa de 76,61 a 84,63%) e maior acerto da classe hanseníase (faixa de 12,0 a 13,0%). E04: Top-1 por subconjunto, sem valor global. E19 não aparece por não reportar acurácia de teste. VC: validação cruzada.

Quanto à variação do desempenho entre tons de pele (RQ6), nenhum dos 16 estudos com dados reporta, no texto principal, métrica de acurácia, sensibilidade ou erro estratificada por tom de pele ou fototipo; figuras e suplementos, como o de E13, não foram examinados. Mesmo nos estudos que caracterizam o tom da base, o desempenho é apresentado de outra forma. E15 reporta o teste por doença, sem separar por faixa de tom, e reconhece que 96% das imagens são de tom moderado ou escuro e que o banco pode não ter o desempenho esperado em pacientes de pele clara. E04 reporta o desempenho por subconjunto (lesões clássicas, 87,2% no Top-5, e reações ou formas atípicas, 69,6%), cujas composições de fototipo diferem; os autores indicam que essa composição pode ter influenciado os resultados, de modo que a diferença está confundida com o tipo de lesão. Como a não informação do desempenho por tom não equivale à sua ausência, a conclusão sustentada é que a evidência necessária não está disponível nos textos principais dos estudos incluídos.

Esse vácuo de evidências contrasta com a revisão de E16, que, ao sintetizar outros estudos, relata que modelos de aprendizado profundo, embora frequentemente acima de 85% de acurácia em dermatologia, apresentam de forma consistente pior desempenho em tons de pele escuros, com reduções de até 20%, e discute o predomínio de tons mais claros nas bases usadas no desenvolvimento. Trata-se de afirmação de revisão sobre outros estudos, e não de resultado dos estudos incluídos nesta revisão. Em doenças que cursam com manchas hipocrômicas ou placas eritematosas, é possível que a leitura de contraste entre a lesão e o tecido perilesional sádio dependa da pigmentação basal do paciente, hipótese que os estudos incluídos não testam. A ausência de resultados estratificados nos textos principais impede assegurar que os sistemas computacionais atuais operem de forma justa e segura na rede pública de saúde do Brasil, justificando a urgência de protocolos de avaliação equitativos no SUS. A Figura 7 resume,

para os 16 estudos com dados, quantos caracterizam o tom de pele da base (RQ5) e quantos reportam desempenho por tom nos textos principais (RQ6).

Figura 7 – Caracterização do tom de pele (RQ5) e desempenho estratificado por tom (RQ6) nos 16 estudos com dados




Fonte: Autores, a partir da leitura dos textos principais dos 16 estudos com dados (15 que desenvolvem modelo e a validação externa de E04); figuras e suplementos não foram examinados. "Não informa" não equivale a "não avalia". Em RQ5, três estudos caracterizam o tom da base em níveis diferentes: E15 e E04 com distribuição, e E05 apenas pela afirmação de fototipo IV ou superior.

### 3.4.6 Quais modelos e abordagens de inteligência artificial são empregados?

A análise qualitativa e quantitativa dos 25 estudos incluídos revela uma expressiva evolução metodológica nas arquiteturas computacionais aplicadas ao enfrentamento da hanseníase e demais dermatoses negligenciadas. Em vez de uma única solução hegemônica, identifica-se a coexistência de abordagens clássicas de aprendizado de máquina supervisionado e arquiteturas profundas de ponta, categorizadas em seis grandes famílias:

1. **Redes Neurais Convolucionais Profundas com Transferência de Aprendizado:** Constituem a espinha dorsal da maioria dos estudos de classificação baseados em fotografias clínicas. Destacam-se a ResNet-50 E05, E13, a VGG-16 E05, E19, a Inception-v4 E13 e a DenseNet-121 E15. No projeto global da Organização Mundial da Saúde (*WHO Skin NTDs App*), a DenseNet-121 pré-treinada atua em um esquema hierárquico em cascata de dois estágios: o primeiro discrimina se a imagem corresponde a uma dermatose negligenciada e o segundo classifica a lesão entre 12 categorias específicas de NTDs cutâneas E04, E11, E15.
2. **Arquiteturas Otimizadas para Dispositivos Periféricos (*Edge Computing* e Aplicações Móveis):** Visando viabilizar a triagem em comunidades periféricas, a MobileNetV2 foi ajustada e convertida para TensorFlow Lite, resultando em um modelo de cerca de 14 MB executado em aplicativo Android E24, em linha com o que o editorial E20 discute sobre aplicações móveis de inteligência artificial no ponto de atendimento.
3. **Modelos Dedicados e Aprendizado com Poucos Exemplos (*Few-Shot Learning*):** Para contornar a escassez crônica de dados primários rotulados, foram desenvolvidas arquiteturas sob

medida, como a *LeprosyNet* E14, baseada em quatro camadas convolucionais com blocos de normalização em lote (*batch normalization*) e otimizador Adam. Complementarmente, E17 aplicou uma rede siamesa com aprendizado por pares, camada de norma L2 e perda contrastiva (*few-shot learning*), demonstrando capacidade preditiva promissora mesmo quando treinada em coleção clínica de tamanho muito restrito.

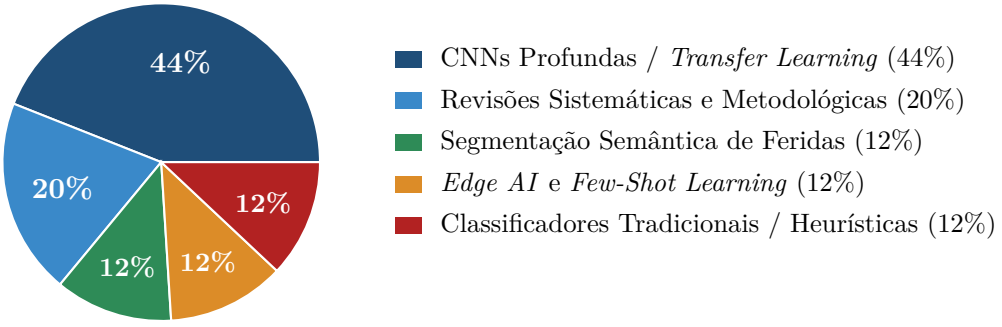
4. **Arquiteturas de Segmentação Semântica e Mecanismos de Atenção:** Para a mensuração objetiva de úlceras plantares e lesões atróficas hansênicas, destacam-se o *framework* CO-WinF, baseado em U-Net com atenção guiada por gradiente (*gradient-driven attention*) E22, e a DeepLabV3+ aplicada à segmentação binária entre ferida e fundo E21. Na segmentação baseada em agrupamento adaptativo, E18 integrou algoritmos de *Fuzzy C-Means* otimizados pelo algoritmo do vaga-lume (*Firefly Algorithm*).

5. **Modelos Clássicos e Otimização Heurística:** Máquinas de Vetores de Suporte (SVM) combinadas com algoritmos de otimização bioinspirados, como o algoritmo do Buraco Negro (*Black Hole Algorithm*) E07, Random Forest e XGBoost continuam sendo empregados com sucesso em conjuntos de dados tabulares, descritores histopatológicos de biópsias E08 e na extração combinada de atributos texturais manuais com LBP (*Local Binary Patterns*) e WLD (*Weber Local Descriptor*) E25.

6. **Modelos Multimodais e Inteligência Artificial Confiável (*Explainable AI*):** Reconhecendo os limites do diagnóstico estritamente visual, a iniciativa AI4Leprosy E13 desenvolveu modelos híbridos que combinam extratores convolucionais profundos com regressores logísticos penalizados (*elastic-net*) alimentados por variáveis clínicas e anamnese do paciente. Quanto à explicabilidade, E23 associou mapas de saliência (*saliency maps*) a um detector YOLOv8n de lesões cutâneas, e a revisão de E16 discute mapas de saliência, Grad-CAM e pontuações de confiança como técnicas para interpretar as decisões do modelo em peles escuras.

A Figura 8 resume visualmente a distribuição proporcional das famílias e abordagens de inteligência artificial identificadas entre os 25 estudos analisados, evidenciando a predominância de modelos de aprendizagem profunda baseados em convoluções.

Figura 8 – Distribuição proporcional das famílias de modelos de inteligência artificial nos 25 estudos




Fonte: Autores.

### 3.4.7 Como a generalização dos modelos é avaliada?

A avaliação crítica da generalização dos modelos representa um dos achados mais determinantes da presente revisão sistemática, evidenciando uma lacuna estrutural entre os desempenhos computacionais

reportados em laboratório e a capacidade real de implantação clínica no Sistema Único de Saúde (SUS):

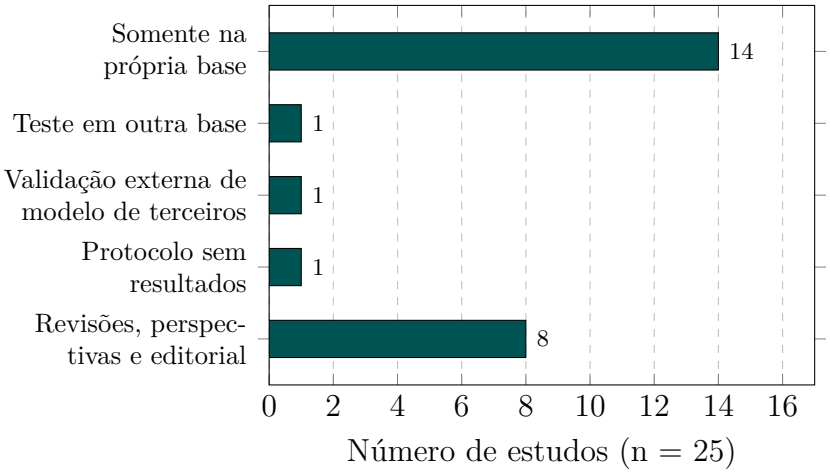
1. **Hegemonia de Avaliações Internas:** Em 14 dos 15 estudos que desenvolvem e avaliam um modelo (Tabela 7), como E08, E14, E18, E19, E25, a validação dos modelos é conduzida unicamente por divisões internas da mesma base de dados (*hold-out*, divisão por classes ou validação cruzada interna); apenas um estudo E23 testa o modelo também em outra base. Nesse desenho, treino e teste vêm da mesma coleta, o que impede avaliar o desempenho em outras condições de captura e pode mascarar fragilidades de sobreajuste (*overfitting*).
2. **Vazamento de Dados por Falta de Separação Estrita por Paciente:** A partição aleatória no nível de imagem (*image-level split*), em vez de uma separação estrita por paciente (*patient-level split*), é um risco de vazamento que não pode ser descartado: entre os 15 estudos que desenvolvem e avaliam um modelo, 13 não informam a unidade da separação (Tabela 7). Quando imagens de diferentes ângulos ou aproximações da mesma lesão pertencem simultaneamente aos conjuntos de treinamento e teste, o modelo decora artefatos de fundo e texturas superficiais do indivíduo, inflando artificialmente as métricas de acurácia.
3. **Validação Externa Independente do Aplicativo da OMS:** A única validação externa independente de um modelo pré-treinado reportada nos estudos incluídos foi conduzida por E04 com um banco de imagens clínicas de hanseníase coletadas entre 1996 e 2024. Ao submeter 423 imagens de 208 casos de hanseníase ao aplicativo da Organização Mundial da Saúde E15, o classificador alcançou sensibilidade Top-5 de 84,9% (359 de 423 imagens). A sensibilidade Top-1 foi de 46,9% nas lesões clássicas e de 30,4% nas lesões reacionais ou atípicas, calculadas por subconjunto, sem valor global reportado, o que mostra que o resultado depende do número de predições consideradas.
4. **Contribuição das Imagens e das Informações Clínicas (AI4Leprosy):** Em um único estudo E13, no teste com 40 pacientes, os modelos construídos só com as informações do paciente ou com as saídas do Modelo 2 (atributos clínicos da lesão) tiveram AUC superior a 90%, enquanto as saídas do modelo de imagens, isoladas, tiveram AUC próxima de 70%; para a floresta aleatória e o XGBoost, os autores relatam pouco benefício em acrescentar as saídas dos Modelos 1 e 2 às informações do paciente. A acurácia de 66,6% do modelo de imagens vem de validação cruzada nos 182 pacientes de desenvolvimento, e a de 90% do modelo final vem do teste de 40 pacientes; os procedimentos são distintos e os valores não são comparáveis diretamente. Por se tratar de um único estudo, com 40 pacientes de teste, não é possível concluir sobre um limite de desempenho da generalização fotográfica.
5. **Ausência de Resultados de Aplicação em Serviço de Saúde:** Entre os 16 estudos com dados, nenhum reporta resultados de aplicação em serviço de saúde: as avaliações usam bancos de imagens pré-coletados, a validação externa de E04 é retrospectiva, e E15 trata a validação externa e a clínica como trabalho futuro. O único estudo que planeja avaliar o aplicativo da OMS em pacientes é o protocolo de E11 no Senegal, ainda sem resultados.

A Figura 9 ilustra a distribuição dos 25 estudos incluídos quanto à abordagem de validação empregada: 14 avaliam o modelo somente na própria base, um testa também em outra base, um valida externamente um modelo de terceiros, um é protocolo sem resultados e oito são revisões, perspectivas ou editorial.

### 3.4.8 Em quais veículos os estudos são publicados?

A distribuição dos 25 estudos incluídos quanto ao veículo de disseminação científica evidencia uma clara preponderância de periódicos indexados de alto fator de impacto sobre anais de congressos,

Figura 9 – Distribuição dos 25 estudos por abordagem de validação do modelo




Fonte: Autores. Dos 15 estudos que desenvolvem modelo, 14 avaliam somente na própria base e um testa também em outra base E23; a validação externa de modelo de terceiros é a de E04; E11 é um protocolo sem resultados; os oito restantes são seis revisões, uma perspectiva e um editorial.

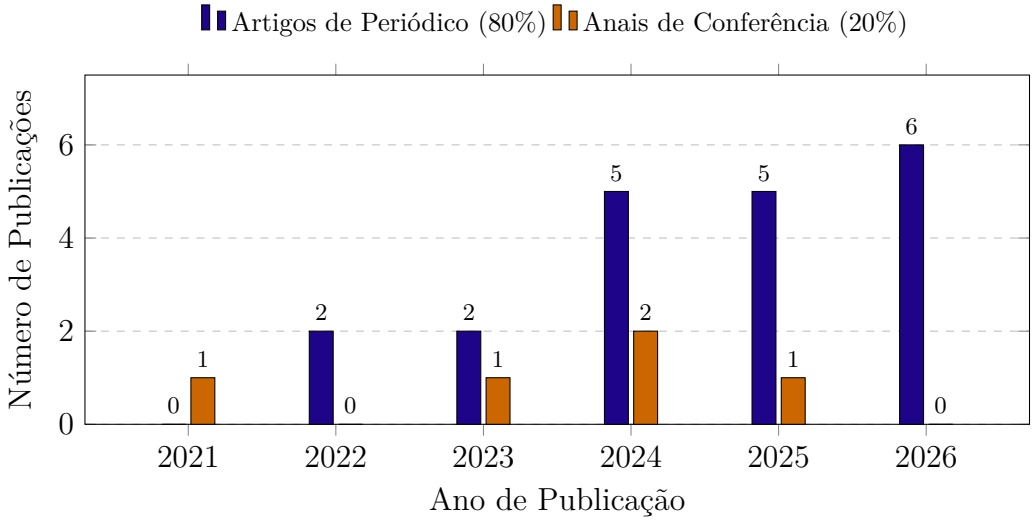
além de demonstrar um notável caráter interdisciplinar entre as ciências da computação, a dermatologia e a saúde pública global:

- **Periódicos Científicos (*Journals*):** Totalizam 20 dos 25 estudos selecionados (80,0% do corpo amostral). Essa concentração reflete o amadurecimento científico da temática e a necessidade de validação metodológica rigorosa por pares. Entre os periódicos da área médica, dermatológica e de saúde pública internacional, incluem-se veículos de prestígio como *The Lancet Regional Health – Americas* E13, *PLOS Neglected Tropical Diseases* E05, *Revista Panamericana de Salud Pública* E04, *Journal of Investigative Dermatology* E15, *International Health* E20, *Frontiers in Medicine* E03, *The American Journal of Dermatopathology* E08, *Indian Journal of Leprosy* E17, *Portuguese Journal of Dermatology and Venereology* E09, *Journal of Clinical Medicine* E01, *JMIR Research Protocols* E11 e *Malahayati International Journal of Nursing and Health Science* E10. No domínio da computação aplicada e bioinformática médica, destacam-se *PLOS Computational Biology* E02, *Engineering Applications of Artificial Intelligence* E23, *BMC Artificial Intelligence* E16, *Informatics in Medicine Unlocked* E07, *SN Computer Science* E06, E18, E25 e *The International Journal of Lower Extremity Wounds* E22.
- **Anais de Conferências Internacionais (*Conference Proceedings*):** Correspondem aos 5 estudos restantes (20,0% da seleção), congregando trabalhos focados no desenvolvimento experimental rápido de novos modelos, segmentação de imagem e soluções de *hardware* embarcado para a atenção periférica. Destacam-se eventos chancelados pelo IEEE: *IEEE International Conference on Image Processing* (ICIP) E21, *IEEE India Council International Conference* (INDICON) E24, *IEEE International Conference on Computing, Communication and Networking Technologies* (ICCCNT) E19, *IEEE International Conference on Emerging Trends in Computing and Communication* (ETCOM) E12 e a *International Conference on Sustainable Computing and Data Communication Systems* (ICSCDS) E14.

Por ano de publicação (Tabela 6), há 1 estudo em 2021 (conferência), 2 em 2022 (revistas), 3 em 2023 (2 revistas e 1 conferência), 7 em 2024 (5 revistas e 2 conferências), 6 em 2025 (5 revistas e 1 conferência) e 6 em 2026 (todos em revistas). Entre 2021 e 2023, 4 dos 6 estudos foram publicados em

revistas e 2 em anais de conferências; entre 2024 e 2026, 16 dos 19 em revistas e 3 em anais. A Figura 10 apresenta essas contagens, com o ano impresso no PDF de cada artigo.

Figura 10 – Evolução temporal e distribuição dos 25 estudos por tipo de veículo de publicação (2021–2026)




Fonte: Autores.

# Referências


AHIKPA, E. D.; HIMABINDU, K. A machine learning-based diagnosis of leprosy: Study. In: *2025 IEEE International Conference on Emerging Trends in Computing and Communication (ETCOM)*. IEEE, 2025. p. 1–5. Disponível em: <https://doi.org/10.1109/ETCOM66606.2025.11436464>.

ANDRADE, H. G. V. d. et al. On the usage of artificial intelligence in leprosy care: A systematic literature review. *PLOS Computational Biology*, v. 21, n. 6, p. e1012550, 2025.

BANERJEE, A. et al. Skin diseases detection using LBP and WLD: An ensembling approach. *SN Computer Science*, v. 5, n. 1, p. 72, 2024.

BARBIERI, R. R. et al. Reimagining leprosy elimination with AI analysis of a combination of skin lesion images with demographic and clinical data. *The Lancet Regional Health – Americas*, v. 9, p. 100192, 2022.

BAWEJA, A. K.; ADITYA, S.; KANCHANA, M. Leprosy diagnosis using explainable artificial intelligence techniques. In: *2023 International Conference on Sustainable Computing and Data Communication Systems (ICSCDS)*. [S.l.]: IEEE, 2023. p. 551–556.

BAWEJA, H. S.; PARHAR, T. Leprosy lesion recognition using convolutional neural networks. In: *2016 International Conference on Machine Learning and Cybernetics (ICMLC)*. IEEE, 2016. p. 141–145. Disponível em: <https://doi.org/10.1109/ICMLC.2016.7860891>.

BEESETTY, R. et al. Leprosy skin lesion detection: An AI approach using few shot learning in a small clinical dataset. *Indian Journal of Leprosy*, v. 95, p. 89–102, 2023.

COCO. *Detection Evaluation*. Documentação técnica do benchmark. Disponível em: <https://cocodataset.org/dataset/detection-eval.htm>. Acesso em: 15 out. 2026. Citado na página 20.

DEPS, P. et al. Independent assessment of the WHO skin neglected tropical diseases application for leprosy detection. *Revista Panamericana de Salud Pública*, v. 50, p. e40, 2026.

DEPS, P. D. et al. The potential role of artificial intelligence in the clinical management of Hansen's disease (leprosy). *Frontiers in Medicine*, v. 11, p. 1338598, 2024.

EITA, M. A.; RIZK, H. A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology. *Engineering Applications of Artificial Intelligence*, v. 159, p. 111594, 2025. Disponível em: <https://doi.org/10.1016/j.engappai.2025.111594>.

FERNANDES, J. R. N. et al. Artificial intelligence on diagnostic aid of leprosy: A systematic literature review. *Journal of Clinical Medicine*, v. 13, n. 1, p. 180, 2024. Disponível em: <https://doi.org/10.3390/jcm13010180>.

GAWALI, C. J.; SUBBULAKSHMI, S. Enhancing diagnosis of infectious skin disease: A professional approach using deep learning for leprosy detection. In: *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*. [S.l.]: IEEE, 2024. p. 1–7.

GOSWAMI, A.; VERMA, S.; MARAK, A. Unveiling leprosy through machines: a review of artificial intelligence in a neglected tropical disease. *Portuguese Journal of Dermatology and Venereology*, v. 84, n. 1, p. 11–18, 2026.

INNOCENT, D. C. et al. Explainable AI for differential diagnosis of skin-manifesting neglected tropical diseases (NTDs) in darker skin tones. *BMC Artificial Intelligence*, v. 2, p. 15, 2026.

JAIKISHORE, C. N.; UDUTALAPALLY, V.; DAS, D. Ai driven edge device for screening skin lesion and its severity in peripheral communities. In: *2021 IEEE 18th India Council International Conference (INDICON)*. IEEE, 2021. p. 1–6. Disponível em: <https://doi.org/10.1109/INDICON52576.2021.9691666>.

JITENDRA, R. et al. Deep semantic segmentation assisted region-of-interest sensitive deep spatio-textural feature learning framework for leprosy detection and classification. *SN Computer Science*, v. 5, p. 742, 2024.

JITENDRA, R. et al. Heuristic segmentation assisted deep-spatial feature learning model for leprosy detection. *SN Computer Science*, v. 5, p. 737, 2024.

JOERG, L. et al. Ai-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study. *Journal of the European Academy of Dermatology and Venereology*, v. 39, p. 2134–2141, 2025. Disponível em: <https://doi.org/10.1111/jdv.20849>.

KITCHENHAM, B.; CHARTERS, S. *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. [S.l.], 2007. Version 2.3. Disponível em: <https://www.cse.chalmers.se/~feldt/advice/kitchenham_2007_systematic_reviews_report_updated.pdf>. Citado 5 vezes nas páginas 9, 14, 21, 22 e 23.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>. Citado na página 15.

MEHTA, J. et al. Integrative image processing framework for enhanced detection of leprosy-associated chronic wounds. *The International Journal of Lower Extremity Wounds*, p. 1–12, 2026.

PAI, M. et al. Systematic reviews and meta-analyses: an illustrated, step-by-step guide. *The National Medical Journal of India*, v. 17, n. 2, p. 86–95, 2004. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/15141602/>. Citado 2 vezes nas páginas 22 e 23.

PONS, J. S. et al. The World Health Organization skin neglected tropical diseases app: A dynamic capacity-building training tool enhanced with artificial intelligence. *Journal of Investigative Dermatology*, 2026.

PRAYITNO, B.; TRIYANTO, E. Utilization of digital health in the screening, diagnosis, and management of Morbus Hansen. *Malahayati International Journal of Nursing and Health Science*, v. 9, n. 4, p. 628–636, 2026.

SALL, D. et al. Potential of the World Health Organization's Skin NTDs App to support and improve the detection of skin-related neglected tropical diseases: Protocol for a performance evaluation and feasibility study in Senegal. *JMIR Research Protocols*, v. 14, p. e69420, 2025.

SANCHEZ, K. et al. CO2Wounds-V2: Extended chronic wounds dataset from leprosy patients. In: *2024 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2024. p. 69–75. Disponível em: <https://doi.org/10.1109/ICIP51287.2024.10647641>.

SOUZA, M. L. M. d. et al. Leprosy screening based on artificial intelligence: Development of a cross-platform app. *JMIR mHealth and uHealth*, v. 9, n. 4, p. e23718, 2021. Disponível em: <https://doi.org/10.2196/23718>.

STEYVE, N. et al. Optimized real-time diagnosis of neglected tropical diseases by automatic recognition of skin lesions. *Informatics in Medicine Unlocked*, v. 33, p. 101078, 2022.

VARGAS-CLAVIJO, M. et al. Evaluating advanced machine learning models for histopathological diagnosis of Hansen disease. *American Journal of Dermatopathology*, v. 47, n. 4, p. 301–307, 2025.

WOHLIN, C. et al. *Experimentation in Software Engineering*. 2. ed. Berlin, Heidelberg: Springer, 2024. Disponível em: <https://doi.org/10.1007/978-3-662-69306-3>. Citado 10 vezes nas páginas 8, 9, 10, 11, 12, 13, 14, 21, 30 e 32.

World Health Organization. *WHO to publish first official guidelines on leprosy diagnosis, treatment and prevention*. 2018. Disponível em: <https://www.who.int/news/item/28-06-2018-who-to-publish-first-official-guidelines-on-leprosy-diagnosis-treatment-and-prevention>. Acesso em: 30 out. 2026. Citado na página 14.

YOTSU, R. R. et al. Deep learning for ai-based diagnosis of skin-related neglected tropical diseases: A pilot study. *PLOS Neglected Tropical Diseases*, v. 17, n. 8, p. e0011230, 2023. Disponível em: <https://doi.org/10.1371/journal.pntd.0011230>.

YOTSU, R. R. et al. Harnessing artificial intelligence for skin-related neglected tropical diseases (skin NTDs): opportunities, challenges and future directions. *International Health*, v. 17, p. 792–794, 2025.

# Apêndices

# APÊNDICE A – Registros encontrados na busca

Este apêndice lista os 118 registros que constam da etapa de busca e triagem, identificados sequencialmente de 1 a 118, com o identificador numérico (ID), o título, o ano, a fonte e a situação na triagem. Os registros que foram selecionados e confirmados para extração trazem também o identificador do estudo incluído (E01 a E25), que remete à Tabela 6. Dos 118 registros, 91 foram excluídos na triagem por título e resumo, 26 foram selecionados para leitura integral (25 incluídos e um excluído em texto completo) e um apresentou decisão intermediária.

Tabela 12 – Registros encontrados na busca (118 linhas das planilhas de triagem), com identificador (ID) e situação

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 1 | Artificial Intelligence on Diagnostic Aid of Leprosy: A Systematic Literature Review | 2024 | Journal of Clinical Medicine | incluído (E01) |
| 2 | On the usage of artificial intelligence in leprosy care: A systematic literature review | 2025 | PLOS Computational Biology | incluído (E02) |
| 3 | The potential role of artificial intelligence in the clinical management of Hansen's disease (leprosy) | 2024 | Frontiers in Medicine | incluído (E03) |
| 4 | Independent assessment of the WHO Skin Neglected Tropical Diseases application for leprosy detection | 2026 | Revista Panamericana de Salud Pública | incluído (E04) |
| 5 | Deep learning for AI-based diagnosis of skin-related neglected tropical diseases: A pilot study | 2023 | PLOS Neglected Tropical Diseases | incluído (E05) |
| 6 | Deep Semantic Segmentation Assisted Region-of-Interest Sensitive Deep Spatio-Textural Feature Learning Framework for Leprosy Detection and Classification | 2024 | SN Computer Science | incluído (E06) |
| 7 | Skin Lesion Segmentation Based on Vision Transformers and Convolutional Neural Networks—A Comparative Study | 2022 | Applied Sciences | excluído na triagem |
| 8 | Improving trust and confidence in medical skin lesion diagnosis through explainable deep learning | 2025 | International Journal of Data Science and Analytics | excluído na triagem |
| 9 | Leprosy Screening Based on Artificial Intelligence: Development of a Cross-Platform App | 2021 | JMIR mHealth and uHealth | decisão consolidada intermediária (M) |
| 10 | Systematic review of deep learning image analyses for the diagnosis and monitoring of skin disease | 2023 | npj Digital Medicine | excluído na triagem |
| 11 | Evaluating Machine Learning Models for Predicting Late Leprosy Diagnosis by Physical Disability Grade in Brazil (2018–2022) | 2025 | Tropical Medicine and Infectious Disease | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 12 | Assessment of Deep Learning Models for Cutaneous Leishmania Parasite Diagnosis Using Microscopic Images | 2023 | Diagnostics | excluído na triagem |
| 13 | Retrospective validation of MetaSystems' deep-learning-based digital microscopy platform with assistance compared to manual fluorescence microscopy for detection of mycobacteria | 2024 | Journal of Clinical Microbiology | excluído na triagem |
| 14 | Equity and Generalizability of Artificial Intelligence for Skin-Lesion Diagnosis Using Clinical, Dermoscopic, and Smartphone Images: A Systematic Review and Meta-Analysis | 2025 | Medicina | excluído na triagem |
| 15 | Artificial Intelligence for the Classification of Pigmented Skin Lesions in Populations with Skin of Color: A Systematic Review | 2023 | Dermatology | excluído na triagem |
| 16 | Improving Cross-Dataset Skin Lesion Segmentation with an Optimized U-Net++ Architecture | 2026 | 2026 IEEE 2nd International Conference on Quantum Photonics, Artificial Intelligence & Networking (QPAIN) | excluído na triagem |
| 17 | Concordance of randomised controlled trials for artificial intelligence interventions with the CONSORT-AI reporting guidelines | 2024 | Nature Communications | excluído na triagem |
| 18 | Quality assessment standards in artificial intelligence diagnostic accuracy systematic reviews: a meta-research study | 2022 | npj Digital Medicine | excluído na triagem |
| 19 | Reporting guidelines in medical artificial intelligence: a systematic review and meta-analysis | 2024 | Communications Medicine | excluído na triagem |
| 20 | Disparities in dermatology AI performance on a diverse, curated clinical image set | 2022 | Science Advances | excluído na triagem |
| 21 | Optimized real-time diagnosis of neglected tropical diseases by automatic recognition of skin lesions | 2022 | Informatics in Medicine Unlocked | incluído (E07) |
| 22 | Evaluating Advanced Machine Learning Models for Histopathological Diagnosis of Hansen Disease | 2025 | The American Journal of Dermatopathology | incluído (E08) |
| 23 | Machine learning methods to predict leprosy misdiagnosis in Yunnan Province, People's Republic of China | 2026 | Frontiers in Public Health | excluído na triagem |
| 24 | Unveiling leprosy through machines: a review of artificial intelligence in a neglected tropical disease | 2026 | Portuguese Journal of Dermatology and Venereology | incluído (E09) |
| 25 | An mHealth App (eSkinHealth) for Detecting and Managing Skin Diseases in Resource-Limited Settings: Mixed Methods Pilot Study | 2023 | JMIR Dermatology | excluído na triagem |
| 26 | Algorithm Design for a Cytokine Release Assay of Antigen-Specific In Vitro Stimuli of Circulating Leukocytes to Classify Leprosy Patients and Household Contacts | 2022 | Open Forum Infectious Diseases | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 27 | Enhancing Skin Lesion Diagnosis: Model Explainability Through Grad-CAM | 2026 | 2026 Second International Conference on Intelligent Systems for Communication, IoT and Security (ICISCoIS) | excluído na triagem |
| 28 | Deep learning–based detection of acid-fast bacilli in microscopy images: a systematic review | 2026 | American Journal of Clinical Pathology | excluído na triagem |
| 29 | Computer-Aided Bacillus Detection in Whole-Slide Pathological Images Using a Deep Convolutional Neural Network | 2020 | Applied Sciences | excluído na triagem |
| 30 | Cross-Dataset and Demographic Validation of Proposed Model (SkinNetX): Ensuring Robustness, Fairness, and Clinical Readiness in Automated Skin Cancer Diagnosis | 2025 | 2025 2nd International Conference on Advanced Computing and Emerging Technologies (ACET) | excluído na triagem |
| 31 | DSU-Net: Dual-Stage U-Net based on CNN and Transformer for skin lesion segmentation | 2025 | Biomedical Signal Processing and Control | excluído na triagem |
| 32 | A novel end-to-end deep convolutional neural network based skin lesion classification framework | 2024 | Expert Systems with Applications | excluído na triagem |
| 33 | Mapping and Quality Appraisal of Artificial Intelligence Preferential Reporting Checklists, Items, Guidelines, and Consensus in Healthcare: An Altmetric, Bibliometric, and Systematic Review | 2026 | International Journal of Dentistry | excluído na triagem |
| 34 | Reducing skin tone bias in dermatology AI via sketch-guided multimodal fusion | 2026 | Scientific Reports | excluído na triagem |
| 35 | Multi-Class Skin Lesion Classification Using a Lightweight Dynamic Kernel Deep-Learning-Based Convolutional Neural Network | 2022 | Diagnostics | excluído na triagem |
| 36 | Mobile Health Strategies to Tackle Skin Neglected Tropical Diseases With Recommendations From Innovative Experiences: Systematic Review | 2020 | JMIR mHealth and uHealth | excluído na triagem |
| 37 | Utilization of digital health in the screening, diagnosis, and management of Morbus Hansen | 2026 | Malahayati International Journal of Nursing and Health Science | incluído (E10) |
| 38 | AI -generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study | 2025 | Journal of the European Academy of Dermatology and Venereology | selecionado para leitura; ausente das 25 extrações |
| 39 | Self-supervised learning for medical image classification: a systematic review and implementation guidelines | 2023 | npj Digital Medicine | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 40 | The Development of a Mobile Application to Support Peripheral Health Workers to Diagnose and Treat People with Skin Diseases in Resource-Poor Settings | 2018 | Tropical Medicine and Infectious Disease | excluído na triagem |
| 41 | Adaptation and performance of a mobile application for early detection of cutaneous leishmaniasis | 2021 | PLOS Neglected Tropical Diseases | excluído na triagem |
| 42 | Potential of the World Health Organization's Skin NTDs App to Support and Improve the Detection of Skin-Related Neglected Tropical Diseases: Protocol for a Performance Evaluation and Feasibility Study in Senegal | 2025 | JMIR Research Protocols | incluído (E11) |
| 43 | Self-Supervised Learning to Increase the Performance of Skin Lesion Classification | 2020 | Electronics | excluído na triagem |
| 44 | GD03 Improving access to diagnosis and treatment of cutaneous neglected tropical diseases: a global health perspective | 2026 | British Journal of Dermatology | excluído na triagem |
| 45 | Framework for developing explainable artificial intelligence models for neglected tropical disease diagnosis in low-resource settings | 2026 | Frontiers in Digital Health | excluído na triagem |
| 46 | Quality of reporting of randomised controlled trials of artificial intelligence in healthcare: a systematic review | 2022 | BMJ Open | excluído na triagem |
| 47 | Evaluating the World Health Organization's SkinNTDs App as a Training Tool for Skin Neglected Tropical Diseases in Ghana and Kenya: Cross-Sectional Study | 2024 | Journal of Medical Internet Research | excluído na triagem |
| 48 | LSNet: a deep learning based method for skin lesion classification using limited samples and transfer learning | 2024 | Multimedia Tools and Applications | excluído na triagem |
| 49 | Combining Artificial Intelligence and Simplified Image Processing for the Automatic Detection of Mycobacterium tuberculosis in Acid-fast Stain: A Cross-institute Training and Validation Study | 2024 | American Journal of Surgical Pathology | excluído na triagem |
| 50 | Diagnosing skin neglected tropical diseases with the aid of digital health tools: A scoping review | 2024 | PLOS Digital Health | excluído na triagem |
| 51 | Artificial Intelligence and Precision Dermatology across Inflammation, Cancer, and Infection: A Review | 2026 | Asian Pacific Journal of Cancer Care | excluído na triagem |
| 52 | Leprosy | 1959 | Occupational Therapy: the Official Journal of the Association of Occupational Therapists | excluído na triagem |
| 53 | Use of a convolutional neural network for direct detection of acid-fast bacilli from clinical specimens | 2025 | Microbiology Spectrum | excluído na triagem |
| 54 | Disease Burden over Skin Tone: Decomposing the Dermatology-AI Generalization Gap | 2026 | não informado na fonte | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 55 | Deep Learning-Driven Skin Disease Detection and Classification System for Enhanced Medical Diagnosis | 2025 | 2025 1st International Conference on Advancement in Futuristic Technologies (ICAFT) | excluído na triagem |
| 56 | An Integrated Deep Learning Model with EfficientNet and ResNet for Accurate Multi-Class Skin Disease Classification | 2025 | Diagnostics | excluído na triagem |
| 57 | Differential diagnosis of acid-fast mycobacteria utilizing an artificial intelligence-based approach in histopathological analysis | 2026 | Diagnostic Pathology | excluído na triagem |
| 58 | Artificial intelligence in clinical medicine: a state-of-the-art overview of systematic reviews with methodological recommendations for improved reporting | 2025 | Frontiers in Digital Health | excluído na triagem |
| 59 | Evaluation of artificial intelligence-powered screening for sexually transmitted infections-related skin lesions using clinical images and metadata | 2024 | BMC Medicine | excluído na triagem |
| 60 | Adapting Large Language Models to Mitigate Skin Tone Biases in Clinical Dermatology Tasks: A Mixed-Methods Study | 2025 | não informado na fonte | excluído na triagem |
| 61 | A Machine Learning-Based Diagnosis of Leprosy: Study | 2025 | 2025 IEEE International Conference on Emerging Trends in Computing and Communication (ETCOM) | incluído (E12) |
| 62 | A Deep Learning Approach for Automated Skin Lesion Diagnosis with Explainable AI | 2026 | não informado na fonte | excluído na triagem |
| 63 | A multimodal transformer to fuse images and metadata for skin disease classification | 2023 | The Visual Computer | excluído na triagem |
| 64 | Reimagining leprosy elimination with AI analysis of a combination of skin lesion images with demographic and clinical data. | 2022 | Lancet regional health. Americas | incluído (E13) |
| 65 | Checklist for Evaluation of Image-Based Artificial Intelligence Reports in Dermatology: CLEAR Derm Consensus Guidelines From the International Skin Imaging Collaboration Artificial Intelligence Working Group. | 2022 | JAMA dermatology | excluído na triagem |
| 66 | External Validation of AI Models for Skin Diseases: A Systematic Review | 2025 | IEEE Access | excluído na triagem |
| 67 | Leprosy Diagnosis using Explainable Artificial Intelligence Techniques | 2023 | não informado na fonte | incluído (E14) |
| 68 | Meta-Transfer Derm-Diagnosis: Exploring Few-Shot Learning and Transfer Learning for Skin Disease Classification in Long-Tail Distribution. | 2026 | IEEE journal of biomedical and health informatics | excluído na triagem |
| 69 | Interpretable Deep Learning in Dermoscopy: An XAI-Driven Ensemble for Skin Lesion Diagnosis | 2026 | IEEE Access | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 70 | Lack of Transparency and Potential Bias in Artificial Intelligence Data Sets and Algorithms: A Scoping Review. | 2021 | JAMA dermatology | excluído na triagem |
| 71 | The World Health Organization skin neglected tropical diseases app: A dynamic capacity-building training tool enhanced with artificial intelligence. | 2026 | The Journal of investigative dermatology | incluído (E15) |
| 72 | Progressive Transfer Learning and Adversarial Domain Adaptation for Cross-Domain Skin Disease Classification. | 2019 | IEEE journal of biomedical and health informatics | excluído na triagem |
| 73 | Development and validation of a machine learning approach for screening new leprosy cases based on the leprosy suspicion questionnaire. | 2025 | Scientific reports | excluído na triagem |
| 74 | Performance Evaluation of No-Code Artificial Intelligence Models for the Detection of Acid-Fast Bacilli: A Comparative Analysis of Three Models. | 2024 | Cureus | excluído na triagem |
| 75 | Dermatologist-level classification of skin cancer with deep neural networks. | 2017 | Nature | excluído na triagem |
| 76 | Automated multi-class classification of skin lesions through deep convolutional neural network with dermoscopic images. | 2020 | Computerized medical imaging and graphics : the official journal of the Computerized Medical Imaging Society | excluído na triagem |
| 77 | SkinDisNet: A comprehensive dataset of clinical images and metadata for skin disease detection and classification. | 2025 | Data in brief | excluído na triagem |
| 78 | A novel integrated molecular and serological analysis method to predict new cases of leprosy amongst household contacts. | 2019 | PLoS neglected tropical diseases | excluído na triagem |
| 79 | Explainable AI for differential diagnosis of skin-manifesting neglected tropical diseases (NTDS) in darker skin tones | 2026 | BMC Artificial Intelligence | incluído (E16) |
| 80 | What is AI? Applications of artificial intelligence to dermatology. | 2020 | The British journal of dermatology | excluído na triagem |
| 81 | Deep Learning for Diagnostic Binary Classification of Multiple-Lesion Skin Diseases. | 2020 | Frontiers in medicine | excluído na triagem |
| 82 | EIU-Net: Enhanced feature extraction and improved skip connections in U-Net for skin lesion segmentation. | 2023 | Computers in biology and medicine | excluído na triagem |
| 83 | Transparency in Artificial Intelligence Reporting in Ophthalmology-A Scoping Review. | 2024 | Ophthalmology science | excluído na triagem |
| 84 | DEU-Net: Dual-Encoder U-Net for Automated Skin Lesion Segmentation | 2023 | IEEE Access | excluído na triagem |
| 85 | Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis. | 2019 | Medical image analysis | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 86 | Leprosy Skin Lesion Detection: An AI Approach Using Few Shot Learning in a Small Clinical Dataset | 2023 | Indian Journal of Leprosy | incluído (E17) |
| 87 | Skin Diseases Detection and Classification using Deep Learning Algorithm Convolutional Neural Network | 2017 | não informado na fonte | excluído na triagem |
| 88 | Heuristic Segmentation Assisted Deep-Spatial Feature Learning Model for Leprosy Detection | 2024 | SN Computer Science | incluído (E18) |
| 89 | Explainable deep inherent learning for multi-classes skin lesion classification | 2024 | Applied Soft Computing | excluído na triagem |
| 90 | Leprosy lesion recognition using convolutional neural networks | 2016 | 2016 International Conference on Machine Learning and Cybernetics (ICMLC) | excluído na triagem |
| 91 | Enhancing Diagnosis of Infectious Skin Disease: A Professional Approach using Deep Learning for Leprosy Detection | 2024 | 2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT) | incluído (E19) |
| 92 | Harnessing artificial intelligence for skin-related neglected tropical diseases (skin NTDs): opportunities, challenges and future directions | 2025 | International Health | incluído (E20) |
| 93 | Fusion of U-Net and CNN model for segmentation and classification of skin lesion from dermoscopy images | 2023 | Expert Systems with Applications | excluído na triagem |
| 94 | Skin Lesion Segmentation based on Integrating EfficientNet and Residual block into U-Net Neural Network | 2020 | 2020 5th International Conference on Green Technology and Sustainable Development (GTSD) | excluído na triagem |
| 95 | Automatic skin lesion segmentation using attention residual U-Net with improved encoder-decoder architecture | 2025 | Multimedia Tools and Applications | excluído na triagem |
| 96 | Detection of Acid-Fast Bacilli AFB in Slit-Skin Smear Microscopy using MASK R-CNN Algorithm | 2023 | não informado na fonte | excluído na triagem |
| 97 | Enhancing Medical Image Classification Using Self-Supervised Transfer Learning | 2024 | 2024 3rd International Conference for Innovation in Technology (INOCON) | excluído na triagem |
| 98 | Comparison of Different Supervised and Self-supervised Learning Techniques in Skin Disease Classification | 2022 | não informado na fonte | excluído na triagem |
| 99 | Fairness of Classifiers Across Skin Tones in Dermatology | 2020 | Lecture Notes in Computer Science | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 100 | Co2Wounds-V2: Extended Chronic Wounds Dataset from Leprosy Patients | 2024 | 2024 IEEE International Conference on Image Processing (ICIP) | incluído (E21) |
| 101 | Integrative Image Processing Framework for Enhanced Detection of Leprosy-Associated Chronic Wounds | 2026 | The International Journal of Lower Extremity Wounds | incluído (E22) |
| 102 | A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology | 2025 | Engineering Applications of Artificial Intelligence | incluído (E23) |
| 103 | AI Driven Edge Device for Screening Skin Lesion and Its Severity in Peripheral Communities | 2021 | 2021 IEEE 18th India Council International Conference (INDICON) | incluído (E24) |
| 104 | Skin Diseases Detection Using LBP and WLD: An Ensembling Approach | 2024 | SN Computer Science | incluído (E25) |
| 105 | A Review of Software and Mobile Apps to Support the Clinical Diagnosis of Hansen Disease | 2023 | JMIR Dermatology | excluído na triagem |
| 106 | Survey of Detection and Identification of Black Skin Diseases Based on Machine Learning | 2023 | Towards new e-Infrastructure and e-Services for Developing Countries | excluído na triagem |
| 107 | Characteristics of publicly available skin cancer image datasets: a systematic review | 2022 | The Lancet Digital Health | excluído na triagem |
| 108 | Skin Type Diversity in Skin Lesion Datasets: A Review | 2024 | Current Dermatology Reports | excluído na triagem |
| 109 | Evaluating Deep Neural Networks Trained on Clinical Images in Dermatology with the Fitzpatrick 17k Dataset | 2021 | 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW) | excluído na triagem |
| 110 | FairDisCo: Fairer AI in Dermatology via Disentanglement Contrastive Learning | 2023 | Computer Vision – ECCV 2022 Workshops | excluído na triagem |
| 111 | Fair and Accurate Skin Disease Image Classification by Alignment with Clinical Labels | 2024 | Medical Image Computing and Computer Assisted Intervention – MICCAI 2024 | excluído na triagem |
| 112 | PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones | 2020 | Data in Brief | excluído na triagem |
| 113 | Automated Identification of Cutaneous Leishmaniasis Lesions Using Deep-Learning-Based Artificial Intelligence | 2023 | Biomedicines | excluído na triagem |
| 114 | Harmonized Dual Deep Learning Architectures for Image-Based Diagnostics of Skin Neglected Tropical Diseases: Benchmark Study via Novel Funnel Framework | 2026 | JMIR Dermatology | excluído na triagem |

*continua na próxima página*

*Tabela 12 (continuação)*

| ID | Título | Ano | Fonte | Situação |
|---|---|---|---|---|
| 115 | Artificial intelligence for the diagnosis of erythematous-squamous dermatological diseases: technological contributions to primary care | 2025 | Anais Brasileiros de Dermatologia | excluído na triagem |
| 116 | The history of Teledermatology and its evolution, practical aspects, and prospects in Brazil | 2025 | Anais Brasileiros de Dermatologia | excluído na triagem |
| 117 | Desenvolvimento e validação de chatbot para abordagem de lesões da hanseníase | 2026 | Ciência & Saúde Coletiva | excluído na triagem |
| 118 | Avaliação Automatizada de Qualidade e Adesão ao Protocolo de Aquisição de Imagens em Exames de Teledermatologia | 2024 | Anais Estendidos do Simpósio Brasileiro de Computação Aplicada à Saúde | excluído na triagem |

Fonte: Autores.

# APÊNDICE B – Notas para revisão com os orientadores — fora do texto do capítulo

**TCC de Euller e Gabriel · 15/10/2026**

Versão de trabalho baseada nas leituras fornecidas. A revisão da literatura está em andamento. O texto abaixo é uma proposta de redação; o contexto definido é o apoio à triagem de hanseníase na rede pública de saúde do Brasil. O GQM e a questão de pesquisa foram atualizados conforme a definição fornecida pela dupla. As notas editoriais ao final não integram a introdução.

## B.1 Estrutura adotada e relação com os exemplos

Os três TCCs fornecidos organizam suas introduções em torno de contexto, problema, questão de pesquisa, objetivos, organização/estrutura do trabalho e cronograma. Esta versão desenvolve contexto, problema, GQM, questão de pesquisa, objetivos e métricas. As métricas podem ser deslocadas para o capítulo metodológico na organização final. A organização dos capítulos e o cronograma devem refletir o planejamento efetivamente aprovado, sem importar atividades experimentais dos exemplos.

Os exemplos foram utilizados como referência de organização, não como fontes científicas sobre hanseníase ou visão computacional. Não se reproduziu o conteúdo temático desses trabalhos.

## B.2 Pontos que precisam de decisão

- **Recorte territorial definido:** Brasil, no contexto da rede pública de saúde. Isso não implica que todos os estudos devam ser brasileiros ou que já exista validação local. Fundamentar posteriormente as particularidades do cenário brasileiro com fontes pertinentes.
- **Escopo da questão:** "como avaliar" pode orientar uma proposta de avaliação mais ampla; a revisão responde inicialmente "como os modelos têm sido avaliados". Alinhar com os professores se a RQ central pertence ao TCC completo e as oito perguntas orientam a extração da revisão.
- **Tons de pele:** o escopo passa a abranger imagens de pele em geral. A avaliação entre tons permanece em M6, quando houver evidências, sem restringir a questão central a pele negra. Fitzpatrick não equivale a identidade racial; origem geográfica não determina tom de pele.
- **Contribuição do TCC 1:** a versão propõe síntese da literatura e fundamentação de avaliação futura. Não promete execução experimental, validação clínica ou aplicativo concluído nesta etapa.
- **Fundamentação clínica:** para aprofundar definições, sinais diagnósticos ou epidemiologia, consultar fontes primárias/oficiais. Esta versão se limita ao contexto apresentado nos artigos e evita estatísticas epidemiológicas atuais não verificadas.
- **Lacuna provisória:** as leituras permitem apontar questões de avaliação e relato. Não escrever que "não existem estudos" ou que a revisão já demonstrou uma lacuna definitiva enquanto a seleção e a extração não terminarem.

## B.3 Mapa das afirmações e das fontes

| Parte da redação | Base consultada | Onde conferir | Limite da afirmação |
|---|---|---|---|
| Dificuldades de reconhecimento e panorama de IA | E01 | PDF pp. 1–2 | Contextualização da revisão, sem números atuais de prevalência |
| 21 estudos e predominância de classificação multiclasse | E01 | Resumo, p. 1 | Não significa 21 estudos elegíveis para o protocolo de vocês |
| MobileNetV2 e protótipo Android | E24 | Resumo/Introdução, p. 1 | Protótipo não equivale a validação clínica; não afirmar estadiamento validado da hanseníase |
| CNNs e população de pele escura | E05 | pp. 3–5 | Dados africanos não demonstram validação na rede pública brasileira |
| Resultados específicos de hanseníase | E05 | pp. 6–7, Task 2/Figura 1 | 12%/13% são leitura da matriz por classe; não misturar com Task 1 |
| Segmentação de feridas | E21 | pp. 1 e 4–5 do PDF | Não é diagnóstico da hanseníase |
| YOLO e explicabilidade | E23 | pp. 4–9 | Mapas de saliência não comprovam validade clínica |
| Diversidade limitada e validação prospectiva futura | E23 | p. 16, seções 6.4 e 7 | Não demonstra diferença quantitativa por tom de pele |

A classificação de E12 como revisão ou estudo experimental requer confirmação no texto completo. Pode apoiar o referencial e os trabalhos relacionados; nesta introdução, priorizaram-se a revisão sistemática E01 e os estudos primários fornecidos. Isso evita atribuir aos revisores resultados que pertencem aos estudos citados.

## B.4 Situação do repositório consultado

Consulta à branch `master` de `HansenSightAI/tcc`, em 14/10/2026. O arquivo `Monografia/editaveis/introd` ainda contém uma introdução sobre análise de shaders em dispositivos móveis. O arquivo `Monografia/bibliografia.b` contém referências do mesmo modelo de computação gráfica. Esta redação é um rascunho independente para revisão; não foi aplicada ao repositório.

Caminhos consultados:

- https://github.com/HansenSightAI/tcc/blob/master/Monografia/editaveis/introducao.tex
- https://github.com/HansenSightAI/tcc/blob/master/Monografia/bibliografia.bib

Na integração, substituir o texto do modelo pela versão aprovada e acrescentar as referências abaixo. Antes de remover referências antigas, verificar se ainda são citadas em outros capítulos do modelo.