Universidade de Brasília – UnB
Faculdade de Ciências e Tecnologias em Engenharia – FCTE
[Curso a preencher]

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens de pele [título provisório]

Autor: Euller e Gabriel [nomes completos a preencher]
Orientador: [Orientador a preencher]

Brasília, DF
2026

Folha de rosto

Euller e Gabriel [nomes completos a preencher]

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens de pele [título provisório]

Monografia submetida ao curso de graduação em [Curso a preencher] da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em [Curso a preencher].

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Orientador: [Orientador a preencher]

Coorientador: [Coorientador, se houver]

Brasília, DF

2026

Sumário

1 INTRODUÇÃO 3
1.1 Contexto 3
1.2 Problema 4
1.3 GQM adaptado e questão de pesquisa 5
1.4 Objetivos 6
1.4.1 Objetivo geral 6
1.4.2 Objetivos específicos 6
1.5 Métricas e dimensões de avaliação do GQM 7
1.5.1 Resultados de classificação 7
1.5.2 Métricas relacionadas à questão de pesquisa 8

Referências 12

APÊNDICES 13

APÊNDICE A – NOTAS PARA REVISÃO COM OS ORIENTADORES — FORA DO TEXTO DO CAPÍTULO . 14
A.1 Estrutura adotada e relação com os exemplos 14
A.2 Pontos que precisam de decisão 14
A.3 Mapa das afirmações e das fontes 15
A.4 Situação do repositório consultado 16

1 Introdução

Este capítulo apresenta o contexto da aplicação de modelos de visão computacional à identificação de manifestações dermatológicas associadas à hanseníase. São delimitados o problema de pesquisa, a questão norteadora e os objetivos do trabalho, considerando a avaliação de desempenho na identificação de padrões associados à hanseníase em imagens de pele, no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.1 Contexto

A hanseníase integra o grupo das doenças tropicais negligenciadas e constitui um desafio para a identificação oportuna de casos e o acompanhamento das pessoas afetadas. Em sua revisão da literatura, Fernandes et al. (2024) destacam que o diagnóstico se baseia principalmente na avaliação clínica e que a semelhança com outras condições dermatológicas pode dificultar o reconhecimento da doença. Nesse contexto, a investigação de recursos computacionais de apoio à análise de manifestações cutâneas pode contribuir para ampliar as possibilidades de suporte aos profissionais de saúde, desde que sua avaliação considere as características da tarefa e da população de interesse.

A análise automatizada de imagens dermatológicas tem sido investigada por meio de técnicas de aprendizado de máquina e aprendizado profundo. Fernandes et al. (2024) identificaram 21 estudos sobre inteligência artificial no apoio ao diagnóstico da hanseníase e observaram que a maior parte utilizava imagens de lesões cutâneas e tarefas de classificação multiclasse. A inclusão da hanseníase em sistemas voltados a diferentes doenças indica que os resultados dessas propostas devem ser interpretados tanto em relação ao conjunto de classes quanto ao reconhecimento específico da doença.

Entre os estudos experimentais, Jaikishore, Udutalapally e Das (2021) desenvolveram uma abordagem baseada em MobileNetV2 para classificar imagens de eczema, sarampo, hanseníase e pele saudável, incorporando o modelo a um protótipo Android. Yotsu et al. (2023), por sua vez, avaliaram ResNet-50 e VGG-16 na classificação de cinco doenças tropicais negligenciadas com manifestações cutâneas. Em outra linha de investigação, Eita e Rizk (2025) propuseram um sistema baseado em YOLOv8 para localizar e classificar lesões de diferentes condições, incluindo hanseníase, com uso de mapas de saliência para apoiar a interpretação das predições. Esses trabalhos ilustram abordagens distintas de análise de imagens, com diferentes requisitos de dados, saídas e procedimentos de avaliação.

O campo também compreende tarefas relacionadas ao acompanhamento de mani-

festações e complicações da doença. Sanchez et al. (2024) apresentaram o CO2Wounds-V2, um conjunto de fotografias de feridas crônicas de pacientes com hanseníase, acompanhado de experimentos de segmentação semântica. Nesse caso, a tarefa consiste em delimitar regiões de ferida nas imagens, e não em determinar se o paciente apresenta hanseníase. Essa distinção é necessária para organizar a literatura e evitar que medidas de segmentação sejam interpretadas como evidências de desempenho diagnóstico.

A caracterização das populações representadas nos dados também integra a avaliação dos modelos. Yotsu et al. (2023) utilizaram fotografias coletadas em Costa do Marfim e Gana, descrevendo a população como composta por pessoas de pele escura, com fototipos de Fitzpatrick IV ou superiores. O estudo oferece evidências diretamente relacionadas à análise de imagens de pele escura, mas não apresenta comparação de desempenho entre os diferentes fototipos. Eita e Rizk (2025) também reconhecem limitações na diversidade dos dados e apontam a ampliação da representação de pessoas com tons de pele mais escuros como uma direção de trabalho futuro.

Esses estudos motivam a investigação de como o desempenho dos modelos é definido, mensurado e interpretado. Para o presente trabalho, a avaliação compreende os resultados preditivos relativos à tarefa, os procedimentos empregados para obtê-los e as evidências disponíveis sobre sua aplicação a novos dados e a diferentes grupos de tom de pele. A utilização futura em apoio à triagem na rede pública de saúde do Brasil constitui o contexto de interesse da pesquisa, sem que os resultados computacionais sejam, por si só, considerados demonstração de efetividade clínica.

1.2 Problema

A existência de modelos capazes de reconhecer padrões em imagens não estabelece, isoladamente, sua adequação à identificação de manifestações de hanseníase em uma população específica. Os estudos analisados apresentam diferenças nas tarefas, nas classes de interesse, na composição dos conjuntos de dados e nas métricas utilizadas. Classificar uma imagem entre doenças, localizar uma lesão e segmentar uma ferida produzem resultados com significados distintos. Consequentemente, uma comparação baseada apenas nos maiores valores publicados pode desconsiderar diferenças essenciais entre os experimentos (YOTSU et al., 2023; SANCHEZ et al., 2024; EITA; RIZK, 2025).

Além disso, medidas agregadas podem não representar adequadamente o desempenho referente à hanseníase. No estudo de Yotsu et al. (2023), a Task 2 apresentou acurácias globais de 77% e 80% nos dois cenários avaliados. Entretanto, a leitura da diagonal correspondente à hanseníase nas matrizes de confusão indica proporções de classificação correta de 12% e 13%, respectivamente. Como as linhas representam a classe real, esses valores podem ser interpretados como sensibilidade por imagem para a classe hanseníase. O con-

traste evidencia a importância de examinar resultados específicos por doença, em vez de atribuir à hanseníase o desempenho global do sistema.

A relação entre os resultados obtidos e os tons de pele constitui outra dimensão do problema. A presença de imagens de pele escura em um conjunto de dados não demonstra que o modelo apresente comportamento equivalente entre diferentes tons. No estudo de Yotsu et al. (2023), a população é caracterizada por um intervalo de fototipos, mas não são fornecidos resultados separados por esses grupos. Já Eita e Rizk (2025) reconhecem limitações de representatividade e a necessidade de ampliar a diversidade dos dados. Essas observações sustentam a necessidade de examinar a caracterização populacional e a avaliação por grupos, sem permitir concluir, a partir dessas evidências isoladas, que todos os modelos tenham desempenho inferior em pele negra.

Também permanece necessário distinguir a avaliação computacional da avaliação em contexto assistencial. O desenvolvimento de um aplicativo ou a obtenção de resultados em conjuntos de imagens não comprova sua contribuição para o atendimento em serviços de saúde. Enquanto Jaikishore, Udutalapally e Das (2021) apresentam um protótipo de aplicação móvel, Eita e Rizk (2025) situam os estudos prospectivos com dermatologistas entre as atividades futuras. Assim, a relevância dessas propostas para a rede pública exige considerar o alcance e os limites dos procedimentos de validação relatados.

Diante desse cenário, o problema investigado consiste em compreender quais evidências e procedimentos permitem avaliar o desempenho de modelos de visão computacional na identificação de manifestações dermatológicas associadas à hanseníase, no contexto de apoio à triagem na rede pública de saúde do Brasil, considerando a tarefa realizada, as características dos dados e os limites de generalização dos resultados. A comparação entre tons de pele será examinada quando houver informações disponíveis, como uma dimensão complementar da avaliação. A revisão em andamento buscará sistematizar essas informações e identificar os aspectos que precisam ser considerados no planejamento de avaliações futuras.

1.3 GQM adaptado e questão de pesquisa

O objetivo de análise foi organizado por meio de um GQM adaptado, que explicita o objeto, o propósito, o foco, o ponto de vista e o contexto da investigação. O quadro orienta a definição da questão de pesquisa e das medidas a serem extraídas dos estudos.

Característica	Valor
Analisar	Modelos de visão computacional aplicados à identificação de manifestações dermatológicas.

Característica	Valor
Com o propósito de	Avaliar o desempenho dos modelos aplicados à identificação de padrões em imagens de pele.
Com foco em	Identificação de características patológicas de hanseníase.
Do ponto de vista de	Pesquisadores das áreas de Engenharia de Software e da área da saúde.
No contexto de	Apoio à triagem de hanseníase na rede pública de saúde do Brasil.

A investigação é orientada pela seguinte questão:

> Como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

Nesta etapa, a questão será abordada por meio da identificação e análise das evidências apresentadas na literatura. Serão examinadas as tarefas realizadas, os modelos empregados, as características dos conjuntos de dados, os procedimentos de avaliação, as métricas e os resultados, bem como as informações disponíveis sobre tons de pele e generalização. A ausência de avaliação por grupo será registrada como uma limitação das evidências disponíveis, sem ser tomada como demonstração de equidade ou de desigualdade de desempenho.

1.4 Objetivos

1.4.1 Objetivo geral

Analisar a avaliação de desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, a partir da síntese das evidências da literatura, visando fundamentar seu uso em apoio à triagem na rede pública de saúde do Brasil.

1.4.2 Objetivos específicos

1. Caracterizar as tarefas, os modelos e as abordagens de visão computacional empregados na análise de manifestações dermatológicas associadas à hanseníase.

2. Identificar os conjuntos de dados utilizados, suas formas de aquisição e anotação e as informações disponíveis sobre as populações e os tons de pele representados.
3. Sistematizar os procedimentos de avaliação, as métricas e os resultados reportados, distinguindo medidas globais, resultados específicos de hanseníase e unidades de análise.
4. Examinar as evidências de generalização e de avaliação do desempenho entre grupos de tom de pele, quando disponíveis.
5. Identificar limitações e lacunas que fundamentem o planejamento de uma avaliação futura de modelos no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.5 Métricas e dimensões de avaliação do GQM

As métricas serão extraídas conforme a tarefa e o protocolo de cada estudo. Não se exige que todos os artigos apresentem todas as medidas. Métricas ausentes serão registradas como não reportadas; cálculos adicionais somente serão realizados quando houver dados suficientes, com identificação explícita de que foram derivados nesta revisão.

1.5.1 Resultados de classificação

Para classificação binária, deve-se definir previamente o que constitui a classe positiva e o diagnóstico/rótulo de referência. Em modelos multiclasse, a hanseníase pode ser analisada como classe positiva frente às demais classes (um contra todos). As definições abaixo se referem à unidade avaliada — por exemplo, imagem — e não implicam automaticamente diagnóstico por paciente.

Resultado	Significado
TP — True Positive	A unidade pertence à classe positiva segundo a referência e o modelo a classifica como positiva.
TN — True Negative	A unidade pertence à classe negativa segundo a referência e o modelo a classifica como negativa.
FP — False Positive	A unidade pertence à classe negativa segundo a referência, mas o modelo a classifica como positiva.
FN — False Negative	A unidade pertence à classe positiva segundo a referência, mas o modelo a classifica como negativa.

A classe positiva pode representar hanseníase ou uma manifestação definida no protocolo do estudo. Essas tarefas devem ser distinguidas: reconhecer uma ferida em paciente com hanseníase não equivale a diagnosticar a doença.

1.5.2 Métricas relacionadas à questão de pesquisa

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M1	Classificação	**Sensibilidade — Sensitivity (SEN/Recall)**	Proporção de positivos corretamente identificados: **SEN = TP / (TP + FN)**.
M2	Classificação	**Especificidade — Specificity (SPE)**	Proporção de negativos corretamente identificados: **SPE = TN / (TN + FP)**.
M3	Classificação	**Precisão — Precision (PRE)**	Proporção de predições positivas que correspondem a positivos de referência: **PRE = TP / (TP + FP)**.
M4	Classificação	**F1-score**	Média harmônica entre precisão e sensibilidade, considerando o efeito de falsos positivos e falsos negativos: **F1 = 2 × PRE × SEN / (PRE + SEN)**, ou **2TP / (2TP + FP + FN)**.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M5	Classificação geral	**Acurácia — Accuracy (ACC)**	Proporção total de classificações corretas: **ACC = (TP + TN) / (TP + TN + FP + FN)**, na formulação binária. Para multiclasse, usar acertos totais / unidades totais.
M6	Equidade do desempenho	**Diferença de desempenho entre grupos**	Comparação da mesma métrica entre grupos de tons de pele, quando disponível. Para dois grupos A e B: **Δ = métrica(A) − métrica(B)**, com grupos e direção identificados. Registrar tamanhos dos grupos, condições de avaliação e incerteza, quando reportados.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M7	Generalização	**Variação de desempenho entre datasets**	Comparação da mesma métrica entre avaliações em dados de distribuição semelhante à de treinamento e dados de distribuição diferente: **gap = métrica(ID) − métrica(OOD)**, quando o desenho permitir. Registrar se houve adaptação ou retreinamento e se tarefa/classes são comparáveis.
M8	Segmentação / sobreposição espacial	**Intersection over Union (IoU)**	Interseção dividida pela união das regiões prevista P e de referência G: **IoU = área(P ∩ G) / área(P ∪ G)**. Em máscaras binárias: **IoU = TP_pixel / (TP_pixel + FP_pixel + FN_pixel)**. Registrar mIoU separadamente quando houver média entre classes.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M9	Detecção / segmentação por instância	**Mean Average Precision (mAP)**	Média dos valores de AP das classes consideradas; AP resume a curva precisão–recall segundo a convenção do benchmark. Registrar o critério de correspondência e o limiar de IoU: por exemplo, **mAP@0,50** ou **mAP@0,50:0,95**. Distinguir AP de caixas e AP de máscaras.

IoU e mAP não são métricas exclusivas de segmentação. Em detecção, IoU mede sobreposição de caixas e pode determinar a correspondência entre predição e referência; mAP resume o desempenho das detecções. Na segmentação semântica, IoU/mIoU mede sobreposição de máscaras por classe. Na segmentação por instância, também se utiliza AP/mAP calculada sobre máscaras. A documentação de avaliação COCO explicita essa distinção entre caixas e máscaras (COCO, s.d.).

Critérios de interpretação: registrar se a unidade é paciente, imagem, objeto ou pixel; separar resultados específicos de hanseníase de médias globais; identificar médias macro, micro ou ponderadas; registrar denominadores nulos como indefinidos ou conforme a convenção explicitada no estudo. Diferenças entre métricas expressas em porcentagem devem ser apresentadas em pontos percentuais. M6 e M7 são dimensões de comparação, não métricas únicas universalmente definidas. Desempenhos de modelos diferentes em bases diferentes não isolam o efeito da mudança de distribuição.

O conjunto de métricas funciona como orientação para extração, não como lista fechada. Medidas adicionais reportadas pelos artigos, como MCC, devem ser registradas com sua definição e contexto. A análise de equidade não será restrição de elegibilidade dos artigos e não será presumida quando não houver resultados por grupo.

Referências

FERNANDES, Jacks Renan Neves; TELES, Ariel Soares; FERNANDES, Thayaná Ribeiro Silva; LIMA, Lucas Daniel Batista; BALHARA, Surjeet; GUPTA, Nishu; TEIXEIRA, Silmar. Artificial Intelligence on Diagnostic Aid of Leprosy: A Systematic Literature Review. *Journal of Clinical Medicine*, v. 13, n. 1, artigo 180, 2024. DOI: https://doi.org/10.3390/j
Nota editorial: o PDF informa publicação online em 28/12/2023, mas sua referência e volume são de 2024; adotou-se o ano bibliográfico de 2024.

JAIKISHORE, Chathura N.; UDUTALAPALLY, Venkanna; DAS, Debanjan. AI Driven Edge Device for Screening Skin Lesion and Its Severity in Peripheral Communities. In: *2021 IEEE 18th India Council International Conference (INDICON)*. IEEE, 2021. p. 1–6. DOI: https://doi.org/10.1109/INDICON52576.2021.9691666.

YOTSU, Rie R.; DING, Zhengming; HAMM, Jihun; BLANTON, Ronald E. Deep learning for AI-based diagnosis of skin-related neglected tropical diseases: A pilot study. *PLOS Neglected Tropical Diseases*, v. 17, n. 8, e0011230, 2023. DOI: https://doi.org/10.1371/journal.p

SANCHEZ, Karen; HINOJOSA, Carlos; MIELES, Olinto; ZHAO, Chen; GHANEM, Bernard; ARGUELLO, Henry. CO2Wounds-V2: Extended Chronic Wounds Dataset from Leprosy Patients. In: *2024 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2024. p. 69–75. DOI: https://doi.org/10.1109/ICIP51287.2024.10647641.

EITA, Mohammad A.; RIZK, Hamada. A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology. *Engineering Applications of Artificial Intelligence*, v. 159, artigo 111594, 2025. DOI: https://doi.org/10.1016/j.engappai.2025.1115

COCO. *Detection Evaluation*. Documentação técnica do benchmark. Disponível em: https://cocodataset.org/dataset/detection-eval.htm. Acesso em: 15 out. 2026. Fonte complementar para interpretação de IoU e AP/mAP em caixas e máscaras; não é estudo incluído na revisão de hanseníase.

Apêndices

APÊNDICE A – Notas para revisão com os orientadores — fora do texto do capítulo

TCC de Euller e Gabriel · 15/10/2026

Versão de trabalho baseada nas leituras fornecidas. A revisão da literatura está em andamento. O texto abaixo é uma proposta de redação; o contexto definido é o apoio à triagem de hanseníase na rede pública de saúde do Brasil. O GQM e a questão de pesquisa foram atualizados conforme a definição fornecida pela dupla. As notas editoriais ao final não integram a introdução.

A.1 Estrutura adotada e relação com os exemplos

Os três TCCs fornecidos organizam suas introduções em torno de contexto, problema, questão de pesquisa, objetivos, organização/estrutura do trabalho e cronograma. Esta versão desenvolve contexto, problema, GQM, questão de pesquisa, objetivos e métricas. As métricas podem ser deslocadas para o capítulo metodológico na organização final. A organização dos capítulos e o cronograma devem refletir o planejamento efetivamente aprovado, sem importar atividades experimentais dos exemplos.

Os exemplos foram utilizados como referência de organização, não como fontes científicas sobre hanseníase ou visão computacional. Não se reproduziu o conteúdo temático desses trabalhos.

A.2 Pontos que precisam de decisão

- **Recorte territorial definido:** Brasil, no contexto da rede pública de saúde. Isso não implica que todos os estudos devam ser brasileiros ou que já exista validação local. Fundamentar posteriormente as particularidades do cenário brasileiro com fontes pertinentes.
- **Escopo da questão:** "como avaliar" pode orientar uma proposta de avaliação mais ampla; a revisão responde inicialmente "como os modelos têm sido avaliados". Alinhar com os professores se a RQ central pertence ao TCC completo e as oito perguntas orientam a extração da revisão.
- **Tons de pele:** o escopo passa a abranger imagens de pele em geral. A avaliação entre tons permanece em M6, quando houver evidências, sem restringir a questão central a pele negra. Fitzpatrick não equivale a identidade racial; origem geográfica

não determina tom de pele.

- **Contribuição do TCC 1:** a versão propõe síntese da literatura e fundamentação de avaliação futura. Não promete execução experimental, validação clínica ou aplicativo concluído nesta etapa.
- **Fundamentação clínica:** para aprofundar definições, sinais diagnósticos ou epidemiologia, consultar fontes primárias/oficiais. Esta versão se limita ao contexto apresentado nos artigos e evita estatísticas epidemiológicas atuais não verificadas.
- **Lacuna provisória:** as leituras permitem apontar questões de avaliação e relato. Não escrever que "não existem estudos" ou que a revisão já demonstrou uma lacuna definitiva enquanto a seleção e a extração não terminarem.

A.3 Mapa das afirmações e das fontes

Parte da redação	Base consultada	Onde conferir	Limite da afirmação
Dificuldades de reconhecimento e panorama de IA	Fernandes et al. (2024)	PDF pp. 1–2	Contextualização da revisão, sem números atuais de prevalência
21 estudos e predominância de classificação multiclasse	Fernandes et al. (2024)	Resumo, p. 1	Não significa 21 estudos elegíveis para o protocolo de vocês
MobileNetV2 e protótipo Android	Jaikishore et al. (2021)	Resumo/Introdução, p. 1	Protótipo não equivale a validação clínica; não afirmar estadiamento validado da hanseníase
CNNs e população de pele escura	Yotsu et al. (2023)	pp. 3–5	Dados africanos não demonstram validação na rede pública brasileira
Resultados específicos de hanseníase	Yotsu et al. (2023)	pp. 6–7, Task 2/Figura 1	12%/13% são leitura da matriz por classe; não misturar com Task 1

Parte da redação	Base consultada	Onde conferir	Limite da afirmação
Segmentação de feridas	Sanchez et al. (2024)	pp. 1 e 4–5 do PDF	Não é diagnóstico da hanseníase
YOLO e explicabilidade	Eita e Rizk (2025)	pp. 4–9	Mapas de saliência não comprovam validade clínica
Diversidade limitada e validação prospectiva futura	Eita e Rizk (2025)	p. 16, seções 6.4 e 7	Não demonstra diferença quantitativa por tom de pele

Ahikpa e Himabindu (2025) foi identificado como revisão, e não como experimento próprio. Pode apoiar o referencial e os trabalhos relacionados; nesta introdução, priorizaram-se a revisão sistemática de Fernandes e os estudos primários fornecidos. Isso evita atribuir aos revisores resultados que pertencem aos estudos citados.

A.4 Situação do repositório consultado

Consulta à branch `master` de `HansenSightAI/tcc`, em 14/10/2026. O arquivo `Monografia/editaveis/introducao.tex` ainda contém uma introdução sobre análise de shaders em dispositivos móveis. O arquivo `Monografia/bibliografia.bib` contém referências do mesmo modelo de computação gráfica. Esta redação é um rascunho independente para revisão; não foi aplicada ao repositório.

Caminhos consultados:

- https://github.com/HansenSightAI/tcc/blob/master/Monografia/editaveis/introducao.tex
- https://github.com/HansenSightAI/tcc/blob/master/Monografia/bibliografia.bib

Na integração, substituir o texto do modelo pela versão aprovada e acrescentar as referências abaixo. Antes de remover referências antigas, verificar se ainda são citadas em outros capítulos do modelo.