Universidade de Brasília – UnB
Faculdade de Ciências e Tecnologias em Engenharia – FCTE
Engenharia de Software

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Autor: Euller Júlio da Silva, Gabriel Henrique Castelo Costa
Orientador: Hilmer Rodrigues Neri

Brasília, DF
2026



Folha de rosto

Euller Júlio da Silva, Gabriel Henrique Castelo Costa

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Orientador: Hilmer Rodrigues Neri

Coorientador: Vinicius de Carvalho Rispoli

Brasília, DF

2026

Sumário

1 INTRODUÇÃO 3
1.1 Contexto 3
1.2 Problema 4
1.3 GQM adaptado e questão de pesquisa 5
1.4 Objetivos 6
1.4.1 Objetivo geral 6
1.4.2 Objetivos específicos 6
1.5 Métricas e dimensões de avaliação do GQM 7
1.5.1 Resultados de classificação 7
1.5.2 Métricas relacionadas à questão de pesquisa 8

2 REVISÃO SISTEMÁTICA DA LITERATURA 12
2.1 Condução da revisão sistemática 12
2.1.1 Planejamento e questões da revisão 12
2.1.2 Busca e identificação dos registros 13
2.1.3 Consultas apresentadas pelo Consensus 13
2.1.4 Critérios de seleção 15
2.1.5 Triagem e seleção para leitura integral 15
2.1.6 Extração e síntese das evidências 18

REFERÊNCIAS 19

APÊNDICES 21

APÊNDICE A – NOTAS PARA REVISÃO COM OS ORIENTADORES — FORA DO TEXTO DO CAPÍTULO . 22
A.1 Estrutura adotada e relação com os exemplos 22
A.2 Pontos que precisam de decisão 22
A.3 Mapa das afirmações e das fontes 23
A.4 Situação do repositório consultado 24

APÊNDICE B – SOLICITAÇÃO ENVIADA AO CONSENSUS . . . 25

1 Introdução

Este capítulo apresenta o contexto da aplicação de modelos de visão computacional à identificação de manifestações dermatológicas associadas à hanseníase. São delimitados o problema de pesquisa, a questão norteadora e os objetivos do trabalho, considerando a avaliação de desempenho na identificação de padrões associados à hanseníase em imagens de pele, no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.1 Contexto

A hanseníase integra o grupo das doenças tropicais negligenciadas e constitui um desafio para a identificação oportuna de casos e o acompanhamento das pessoas afetadas. Em sua revisão da literatura, Fernandes et al. (2024) destacam que o diagnóstico se baseia principalmente na avaliação clínica e que a semelhança com outras condições dermatológicas pode dificultar o reconhecimento da doença. Nesse contexto, a investigação de recursos computacionais de apoio à análise de manifestações cutâneas pode contribuir para ampliar as possibilidades de suporte aos profissionais de saúde, desde que sua avaliação considere as características da tarefa e da população de interesse.

A análise automatizada de imagens dermatológicas tem sido investigada por meio de técnicas de aprendizado de máquina e aprendizado profundo. Fernandes et al. (2024) identificaram 21 estudos sobre inteligência artificial no apoio ao diagnóstico da hanseníase e observaram que a maior parte utilizava imagens de lesões cutâneas e tarefas de classificação multiclasse. A inclusão da hanseníase em sistemas voltados a diferentes doenças indica que os resultados dessas propostas devem ser interpretados tanto em relação ao conjunto de classes quanto ao reconhecimento específico da doença.

Entre os estudos experimentais, Jaikishore, Udutalapally e Das (2021) desenvolveram uma abordagem baseada em MobileNetV2 para classificar imagens de eczema, sarampo, hanseníase e pele saudável, incorporando o modelo a um protótipo Android. Yotsu et al. (2023), por sua vez, avaliaram ResNet-50 e VGG-16 na classificação de cinco doenças tropicais negligenciadas com manifestações cutâneas. Em outra linha de investigação, Eita e Rizk (2025) propuseram um sistema baseado em YOLOv8 para localizar e classificar lesões de diferentes condições, incluindo hanseníase, com uso de mapas de saliência para apoiar a interpretação das predições. Esses trabalhos ilustram abordagens distintas de análise de imagens, com diferentes requisitos de dados, saídas e procedimentos de avaliação.

O campo também compreende tarefas relacionadas ao acompanhamento de mani-

festações e complicações da doença. Sanchez et al. (2024) apresentaram o CO2Wounds-V2, um conjunto de fotografias de feridas crônicas de pacientes com hanseníase, acompanhado de experimentos de segmentação semântica. Nesse caso, a tarefa consiste em delimitar regiões de ferida nas imagens, e não em determinar se o paciente apresenta hanseníase. Essa distinção é necessária para organizar a literatura e evitar que medidas de segmentação sejam interpretadas como evidências de desempenho diagnóstico.

A caracterização das populações representadas nos dados também integra a avaliação dos modelos. Yotsu et al. (2023) utilizaram fotografias coletadas em Costa do Marfim e Gana, descrevendo a população como composta por pessoas de pele escura, com fototipos de Fitzpatrick IV ou superiores. O estudo oferece evidências diretamente relacionadas à análise de imagens de pele escura, mas não apresenta comparação de desempenho entre os diferentes fototipos. Eita e Rizk (2025) também reconhecem limitações na diversidade dos dados e apontam a ampliação da representação de pessoas com tons de pele mais escuros como uma direção de trabalho futuro.

Esses estudos motivam a investigação de como o desempenho dos modelos é definido, mensurado e interpretado. Para o presente trabalho, a avaliação compreende os resultados preditivos relativos à tarefa, os procedimentos empregados para obtê-los e as evidências disponíveis sobre sua aplicação a novos dados e a diferentes grupos de tom de pele. A utilização futura em apoio à triagem na rede pública de saúde do Brasil constitui o contexto de interesse da pesquisa, sem que os resultados computacionais sejam, por si só, considerados demonstração de efetividade clínica.

1.2 Problema

A existência de modelos capazes de reconhecer padrões em imagens não estabelece, isoladamente, sua adequação à identificação de manifestações de hanseníase em uma população específica. Os estudos analisados apresentam diferenças nas tarefas, nas classes de interesse, na composição dos conjuntos de dados e nas métricas utilizadas. Classificar uma imagem entre doenças, localizar uma lesão e segmentar uma ferida produzem resultados com significados distintos. Consequentemente, uma comparação baseada apenas nos maiores valores publicados pode desconsiderar diferenças essenciais entre os experimentos (YOTSU et al., 2023; SANCHEZ et al., 2024; EITA; RIZK, 2025).

Além disso, medidas agregadas podem não representar adequadamente o desempenho referente à hanseníase. No estudo de Yotsu et al. (2023), a Task 2 apresentou acurácias globais de 77% e 80% nos dois cenários avaliados. Entretanto, a leitura da diagonal correspondente à hanseníase nas matrizes de confusão indica proporções de classificação correta de 12% e 13%, respectivamente. Como as linhas representam a classe real, esses valores podem ser interpretados como sensibilidade por imagem para a classe hanseníase. O con-

traste evidencia a importância de examinar resultados específicos por doença, em vez de atribuir à hanseníase o desempenho global do sistema.

A relação entre os resultados obtidos e os tons de pele constitui outra dimensão do problema. A presença de imagens de pele escura em um conjunto de dados não demonstra que o modelo apresente comportamento equivalente entre diferentes tons. No estudo de Yotsu et al. (2023), a população é caracterizada por um intervalo de fototipos, mas não são fornecidos resultados separados por esses grupos. Já Eita e Rizk (2025) reconhecem limitações de representatividade e a necessidade de ampliar a diversidade dos dados. Essas observações sustentam a necessidade de examinar a caracterização populacional e a avaliação por grupos, sem permitir concluir, a partir dessas evidências isoladas, que todos os modelos tenham desempenho inferior em pele negra.

Também permanece necessário distinguir a avaliação computacional da avaliação em contexto assistencial. O desenvolvimento de um aplicativo ou a obtenção de resultados em conjuntos de imagens não comprova sua contribuição para o atendimento em serviços de saúde. Enquanto Jaikishore, Udutalapally e Das (2021) apresentam um protótipo de aplicação móvel, Eita e Rizk (2025) situam os estudos prospectivos com dermatologistas entre as atividades futuras. Assim, a relevância dessas propostas para a rede pública exige considerar o alcance e os limites dos procedimentos de validação relatados.

Diante desse cenário, o problema investigado consiste em compreender quais evidências e procedimentos permitem avaliar o desempenho de modelos de visão computacional na identificação de manifestações dermatológicas associadas à hanseníase, no contexto de apoio à triagem na rede pública de saúde do Brasil, considerando a tarefa realizada, as características dos dados e os limites de generalização dos resultados. A comparação entre tons de pele será examinada quando houver informações disponíveis, como uma dimensão complementar da avaliação. A revisão em andamento buscará sistematizar essas informações e identificar os aspectos que precisam ser considerados no planejamento de avaliações futuras.

1.3 GQM adaptado e questão de pesquisa

O objetivo de análise foi organizado por meio de um GQM adaptado, que explicita o objeto, o propósito, o foco, o ponto de vista e o contexto da investigação. O quadro orienta a definição da questão de pesquisa e das medidas a serem extraídas dos estudos.

Característica	Valor
Analisar	Modelos de visão computacional aplicados à identificação de manifestações dermatológicas.

Característica	Valor
Com o propósito de	Avaliar o desempenho dos modelos aplicados à identificação de padrões em imagens de pele.
Com foco em	Identificação de características patológicas de hanseníase.
Do ponto de vista de	Pesquisadores das áreas de Engenharia de Software e da área da saúde.
No contexto de	Apoio à triagem de hanseníase na rede pública de saúde do Brasil.

A investigação é orientada pela seguinte questão:

> Como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

Nesta etapa, a questão será abordada por meio da identificação e análise das evidências apresentadas na literatura. Serão examinadas as tarefas realizadas, os modelos empregados, as características dos conjuntos de dados, os procedimentos de avaliação, as métricas e os resultados, bem como as informações disponíveis sobre tons de pele e generalização. A ausência de avaliação por grupo será registrada como uma limitação das evidências disponíveis, sem ser tomada como demonstração de equidade ou de desigualdade de desempenho.

1.4 Objetivos

1.4.1 Objetivo geral

Analisar a avaliação de desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, a partir da síntese das evidências da literatura, visando fundamentar seu uso em apoio à triagem na rede pública de saúde do Brasil.

1.4.2 Objetivos específicos

1. Caracterizar as tarefas, os modelos e as abordagens de visão computacional empregados na análise de manifestações dermatológicas associadas à hanseníase.

2. Identificar os conjuntos de dados utilizados, suas formas de aquisição e anotação e as informações disponíveis sobre as populações e os tons de pele representados.
3. Sistematizar os procedimentos de avaliação, as métricas e os resultados reportados, distinguindo medidas globais, resultados específicos de hanseníase e unidades de análise.
4. Examinar as evidências de generalização e de avaliação do desempenho entre grupos de tom de pele, quando disponíveis.
5. Identificar limitações e lacunas que fundamentem o planejamento de uma avaliação futura de modelos no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.5 Métricas e dimensões de avaliação do GQM

As métricas serão extraídas conforme a tarefa e o protocolo de cada estudo. Não se exige que todos os artigos apresentem todas as medidas. Métricas ausentes serão registradas como não reportadas; cálculos adicionais somente serão realizados quando houver dados suficientes, com identificação explícita de que foram derivados nesta revisão.

1.5.1 Resultados de classificação

Para classificação binária, deve-se definir previamente o que constitui a classe positiva e o diagnóstico/rótulo de referência. Em modelos multiclasse, a hanseníase pode ser analisada como classe positiva frente às demais classes (um contra todos). As definições abaixo se referem à unidade avaliada — por exemplo, imagem — e não implicam automaticamente diagnóstico por paciente.

Resultado	Significado
TP — True Positive	A unidade pertence à classe positiva segundo a referência e o modelo a classifica como positiva.
TN — True Negative	A unidade pertence à classe negativa segundo a referência e o modelo a classifica como negativa.
FP — False Positive	A unidade pertence à classe negativa segundo a referência, mas o modelo a classifica como positiva.
FN — False Negative	A unidade pertence à classe positiva segundo a referência, mas o modelo a classifica como negativa.

A classe positiva pode representar hanseníase ou uma manifestação definida no protocolo do estudo. Essas tarefas devem ser distinguidas: reconhecer uma ferida em paciente com hanseníase não equivale a diagnosticar a doença.

1.5.2 Métricas relacionadas à questão de pesquisa

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M1	Classificação	**Sensibilidade — Sensitivity (SEN/Recall)**	Proporção de positivos corretamente identificados: **SEN = TP / (TP + FN)**.
M2	Classificação	**Especificidade — Specificity (SPE)**	Proporção de negativos corretamente identificados: **SPE = TN / (TN + FP)**.
M3	Classificação	**Precisão — Precision (PRE)**	Proporção de predições positivas que correspondem a positivos de referência: **PRE = TP / (TP + FP)**.
M4	Classificação	**F1-score**	Média harmônica entre precisão e sensibilidade, considerando o efeito de falsos positivos e falsos negativos: **F1 = 2 × PRE × SEN / (PRE + SEN)**, ou **2TP / (2TP + FP + FN)**.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M5	Classificação geral	**Acurácia — Accuracy (ACC)**	Proporção total de classificações corretas: **ACC = (TP + TN) / (TP + TN + FP + FN)**, na formulação binária. Para multiclasse, usar acertos totais / unidades totais.
M6	Equidade do desempenho	**Diferença de desempenho entre grupos**	Comparação da mesma métrica entre grupos de tons de pele, quando disponível. Para dois grupos A e B: **Δ = métrica(A) − métrica(B)**, com grupos e direção identificados. Registrar tamanhos dos grupos, condições de avaliação e incerteza, quando reportados.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M7	Generalização	**Variação de desempenho entre datasets**	Comparação da mesma métrica entre avaliações em dados de distribuição semelhante à de treinamento e dados de distribuição diferente: **gap = métrica(ID) − métrica(OOD)**, quando o desenho permitir. Registrar se houve adaptação ou retreinamento e se tarefa/classes são comparáveis.
M8	Segmentação / sobreposição espacial	**Intersection over Union (IoU)**	Interseção dividida pela união das regiões prevista P e de referência G: **IoU = área(P ∩ G) / área(P ∪ G)**. Em máscaras binárias: **IoU = TP_pixel / (TP_pixel + FP_pixel + FN_pixel)**. Registrar mIoU separadamente quando houver média entre classes.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M9	Detecção / segmentação por instância	**Mean Average Precision (mAP)**	Média dos valores de AP das classes consideradas; AP resume a curva precisão–recall segundo a convenção do benchmark. Registrar o critério de correspondência e o limiar de IoU: por exemplo, **mAP@0,50** ou **mAP@0,50:0,95**. Distinguir AP de caixas e AP de máscaras.

IoU e mAP não são métricas exclusivas de segmentação. Em detecção, IoU mede sobreposição de caixas e pode determinar a correspondência entre predição e referência; mAP resume o desempenho das detecções. Na segmentação semântica, IoU/mIoU mede sobreposição de máscaras por classe. Na segmentação por instância, também se utiliza AP/mAP calculada sobre máscaras. A documentação de avaliação COCO explicita essa distinção entre caixas e máscaras (COCO,).

Critérios de interpretação: registrar se a unidade é paciente, imagem, objeto ou pixel; separar resultados específicos de hanseníase de médias globais; identificar médias macro, micro ou ponderadas; registrar denominadores nulos como indefinidos ou conforme a convenção explicitada no estudo. Diferenças entre métricas expressas em porcentagem devem ser apresentadas em pontos percentuais. M6 e M7 são dimensões de comparação, não métricas únicas universalmente definidas. Desempenhos de modelos diferentes em bases diferentes não isolam o efeito da mudança de distribuição.

O conjunto de métricas funciona como orientação para extração, não como lista fechada. Medidas adicionais reportadas pelos artigos, como MCC, devem ser registradas com sua definição e contexto. A análise de equidade não será restrição de elegibilidade dos artigos e não será presumida quando não houver resultados por grupo.

2 Revisão sistemática da literatura

2.1 Condução da revisão sistemática

A revisão de literatura foi planejada para identificar e analisar evidências sobre a avaliação de modelos de visão computacional aplicados a manifestações cutâneas associadas à hanseníase. A definição de uma questão, de um protocolo, de critérios de seleção e de procedimentos de extração e síntese é coerente com as orientações de Kitchenham e Charters (2007) para revisões sistemáticas em engenharia de software. O capítulo 4 de Wohlin et al. (2024, p. 51–56) apresenta a revisão sistemática como estudo secundário e organiza seu processo em planejamento, condução e relato. A obra fundamenta a definição de questões e critérios, a documentação da busca, a seleção e a extração orientada pelas questões de pesquisa. O procedimento adotado nesta revisão é descrito a seguir; suas etapas não devem ser interpretadas como a execução de um experimento controlado.

2.1.1 Planejamento e questões da revisão

O objetivo, o protocolo e os critérios foram organizados no Evidentia. A questão principal é: como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil? A investigação foi detalhada nas seguintes questões secundárias:

1. Quais técnicas de visão computacional são usadas para identificar manifestações dermatológicas associadas à hanseníase?
2. Quais conjuntos de dados e populações são utilizados no desenvolvimento e na avaliação dos modelos?
3. Quais métodos e procedimentos são usados para avaliar o desempenho e quais resultados são relatados?
4. Quais métricas são usadas na avaliação e quais resultados são relatados?
5. Como o desempenho varia entre diferentes grupos ou tons de pele?
6. Quais modelos e abordagens de inteligência artificial são utilizados para identificar as manifestações dermatológicas associadas à doença?
7. Como a capacidade de generalização é avaliada, especialmente em conjuntos diferentes dos usados no treinamento?

8. Em que tipo de veículo o artigo foi publicado, como periódico ou conferência?

Para estruturar a solicitação de busca, foram utilizados os componentes registrados como população, contexto, intervenção e resultado do PICOC. A população foi representada por termos de visão computacional, inteligência artificial, redes neurais e aprendizado de máquina e profundo; o contexto, por hanseníase e classificação ou segmentação de lesões cutâneas; a intervenção, por modelos e arquiteturas de aprendizado de máquina; e o resultado, por termos de avaliação, métricas e tarefas de identificação. O *prompt* preservado não apresenta um campo separado de comparação. As perguntas e a relação completa de termos, incluindo sinônimos e asteriscos, são reproduzidas no Apêndice B.

2.1.2 Busca e identificação dos registros

O protocolo da revisão foi organizado no Evidentia a partir da questão de pesquisa e dos componentes do PICOC. Esses elementos foram utilizados em uma solicitação em inglês ao Consensus, sem a inclusão dos critérios de seleção no texto do *prompt*. Em 25 de setembro de 2026, a ferramenta retornou uma lista de 100 referências, das quais 98 tinham DOI informado. A dupla também informou uma busca complementar por meio do Claude, da qual foram reunidas 30 referências. A data, o *prompt*, o modelo, a configuração e a lista completa dessa busca complementar ainda precisam ser confirmados. Embora o protocolo também registre a Scopus como fonte, não há comprovação de uma busca separada nessa base na etapa descrita.

As duas listas somaram 130 registros e, após a remoção de duplicatas, permaneceram 118 para triagem. A diferença entre esses totais corresponde a 12 registros removidos; entretanto, os pares considerados duplicados e o procedimento usado para identificá-los ainda não foram integralmente documentados. O conjunto bibliográfico disponível contém 129 entradas. Na comparação com os 118 registros triados, onze entradas não aparecem no conjunto de triagem e apresentam o mesmo DOI de outras entradas nele representadas. Essa comparação permite identificar 11 pares de registros com DOI coincidente, mas não identifica um eventual décimo segundo registro removido nem comprova, isoladamente, quando cada par foi deduplicado. A diferença entre as 129 entradas identificadas e os 130 registros informados no relato permanece a esclarecer. Os indicadores internos apresentados pelo Consensus não foram tratados como quantidades auditadas de estudos únicos examinados pelos pesquisadores.

2.1.3 Consultas apresentadas pelo Consensus

Na busca de 25 de setembro de 2026, o Consensus apresentou uma sequência de consultas em quatro rodadas. A Tabela 1 reproduz os textos e indicadores exibidos. Esses

indicadores são saídas internas da ferramenta, sem definição operacional disponível; não correspondem a contagens auditadas de estudos únicos triados pela dupla.

Tabela 1 – Consultas e indicadores apresentados pelo Consensus

Rodada	Consulta	Indicador
1	deep learning convolutional neural network leprosy Hansen disease skin lesion classification detection diagnosis	95,3 mil
1	U-Net ResNet EfficientNet Vision Transformer skin lesion segmentation leprosy hanseniasis dermatological pattern recognition	2,3 mil
1	machine learning model performance evaluation accuracy AUC F1 sensitivity specificity leprosy skin image diagnosis	63,5 mil
1	skin tone fairness demographic subgroup performance dermatology AI model external validation generalization cross-dataset	67,4 mil
2	leprosy skin image dataset Brazil public health AI diagnosis computer vision	26,2 mil
2	transfer learning self-supervised semi-supervised learning skin neglected tropical disease leprosy image classification	36,6 mil
2	WHO skin neglected tropical diseases mobile application telemedicine leprosy detection low-resource settings	63,4 mil
3	explainability XAI Grad-CAM interpretable AI leprosy neglected tropical disease skin lesion diagnosis	1,6 mil
3	histopathological image analysis acid-fast bacilli detection deep learning leprosy nerve biopsy microscopy	17,6 mil
4	leprosy skin image dataset multimodal clinical metadata paucibacillary multibacillary classification AI model	3 mil
4	reporting standards quality assessment QUADAS CONSORT-AI CLEAR dermatology AI model evaluation systematic review	47,8 mil

O painel informou ainda os indicadores *Retrieved* de 425,4 mil, *Eligible* de mil e *Included* de 100. Após a segunda rodada, a ferramenta apresentou uma expansão por grafo de citações com dez sementes e o indicador 662; após a terceira, indicou leitura de 12 resumos; antes da síntese, indicou leitura de resumos e PDFs de 100 itens. O significado operacional desses indicadores, a identificação completa das sementes e o acesso integral a cada PDF não foram comprovados. A busca também foi ampliada para temas relacionados, como dermatologia geral, equidade, saúde móvel, microscopia, histopatologia e diretrizes

de relato; nessas condições, a presença de uma referência na saída da ferramenta não significa que ela atende aos critérios da revisão.

2.1.4 Critérios de seleção

Os critérios de inclusão foram: disponibilidade do texto completo (CI01); uso de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar manifestações cutâneas humanas associadas à hanseníase (CI02); relato ou síntese de evidências de avaliação de métodos de inteligência artificial para hanseníase, incluindo experimentos, testes, validação ou comparação de desempenho (CI03); uso, análise ou revisão de fotografias clínicas ou imagens dermatoscópicas de lesões cutâneas humanas associadas à hanseníase (CI04); e inclusão da hanseníase entre as condições avaliadas em trabalhos que abordam múltiplas doenças (CI05). A formulação preservada do CI03 foi recebida truncada após "resultados de estu"; o trecho descrito acima resume apenas a parte legível e sua redação integral deve ser confirmada. Os critérios abrangem estudos primários e revisões, que devem ser distinguidos durante a extração.

Foram informados os seguintes critérios de exclusão: registro duplicado de artigo já considerado (CE01); publicação anterior a 2020 (CE02); texto completo em idioma diferente de inglês ou português (CE03); uso exclusivo de inteligência artificial generativa como intervenção (CE04); e ausência de abordagem da hanseníase (CE05). A verificação de disponibilidade e idioma do texto completo pode depender de consulta além do título e do resumo, enquanto data e duplicidade também dependem dos metadados.

2.1.5 Triagem e seleção para leitura integral

O Jev Reviewer foi utilizado como apoio à classificação preliminar dos 118 registros. Para cada registro, suas sugestões são acompanhadas de valores associados ao não atendimento de cinco critérios:

1. Abordar a hanseníase como condição investigada ou avaliada, isoladamente ou entre outras doenças; uma menção apenas introdutória não atende a esse critério.

2. Utilizar fotografias clínicas ou imagens dermatoscópicas de manifestações cutâneas humanas associadas à hanseníase, ou revisar estudos que utilizam essas imagens.

3. Aplicar ou analisar métodos de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar essas manifestações nas imagens, incluindo revisões dessas aplicações.

4. Relatar ou sintetizar evidências de avaliação desses métodos, como experimentos, testes, validação, comparação de desempenho ou resultados de estudos.

5. Não se limitar exclusivamente à inteligência artificial generativa como intervenção.

Esses cinco critérios descrevem o que foi avaliado pelo Jev; eles não substituem os critérios gerais de inclusão e exclusão da revisão. Os valores de `fails` acompanham a avaliação automatizada e não registram, por si sós, a justificativa da decisão dos pesquisadores. Após a classificação preliminar, a dupla relatou ter revisado os registros por título e resumo, com as decisões registradas no Evidentia. A documentação não esclarece se ambos avaliaram todos os registros de maneira independente. A avaliação por dois ou mais pesquisadores, ao menos para uma amostra, é recomendada por Wohlin et al. (2024, p. 55); essa recomendação não demonstra que ela foi executada neste trabalho.

As sugestões do Jev para os 118 registros foram: duas de inclusão, 15 incertas e 101 de exclusão. O cruzamento por título entre as sugestões e as decisões do Evidentia identificou correspondência para todos os registros. Entre os 26 com situação de inclusão no Evidentia, dois tinham sugestão de inclusão do Jev, 11 tinham sugestão incerta e 13 tinham sugestão de exclusão. Entre os 91 excluídos no Evidentia, 87 tinham sugestão de exclusão e quatro tinham sugestão incerta. O registro restante, classificado como intermediário no Evidentia, tinha sugestão de exclusão pelo Jev. Assim, as sugestões automáticas são distintas das decisões de triagem. A data de execução, o modelo, a configuração completa e a versão da ferramenta não foram identificados; os cinco critérios exibidos acima, por sua vez, estão registrados nas avaliações disponíveis. Houve também discussão de exemplos de títulos e resumos com o ChatGPT para apoiar a aplicação dos critérios; não é possível determinar quantas decisões foram influenciadas por esse apoio.

Os estados intermediários da triagem registram, em uma etapa, 12 inclusões, 32 exclusões, 15 decisões intermediárias e 59 registros sem decisão. Em outro estado foram observadas 19 inclusões, 40 exclusões e os mesmos 59 registros sem decisão; as 15 decisões intermediárias passaram a sete inclusões e oito exclusões. As datas das decisões preenchidas indicam 28 de setembro de 2026, mas não registram horário de cada decisão. Esses estados intermediários não devem ser confundidos com o resultado consolidado descrito a seguir.

No Evidentia, 91 registros apresentam decisão de exclusão, 26 de inclusão e uma decisão intermediária, totalizando 118 registros. Esse último registro, *Leprosy Screening Based on Artificial Intelligence: Development of a Cross-Platform App* (SOUZA et al., 2021), apresenta duas decisões individuais de exclusão, mas sua decisão consolidada foi registrada manualmente como intermediária. Em outro registro, *Leprosy lesion recognition using convolutional neural networks* (BAWEJA; PARHAR, 2016), houve uma decisão individual de inclusão e uma de exclusão; o conflito foi resolvido manualmente com decisão consolidada de exclusão. Os demais 116 registros possuem decisão consolidada automática, segundo o campo correspondente no Evidentia. Essa classificação descreve o mecanismo de consolidação registrado pelo sistema e não identifica uma revisão independente por

ambos os pesquisadores para cada artigo.

A decomposição 91 exclusões, 26 inclusões e uma decisão intermediária esclarece a diferença observada no registro anterior: 118 menos 26 é 92, mas esse resultado reúne os 91 excluídos e o registro intermediário. Assim, não se deve representar a diferença de 92 como 92 exclusões. Os 26 registros com situação de inclusão na triagem constituem o conjunto encaminhado à leitura integral, conforme o registro consolidado; esse estado não comprova a elegibilidade definitiva após a leitura completa.

Tabela 2 – Quantidades documentadas na identificação e na triagem dos estudos

Etapa ou registro	Quantidade
Referências informadas do Consensus	100
Referências informadas do Claude	30
Registros reunidos, segundo o registro consolidado	130
Diferença entre os registros reunidos e os 118 para triagem	12
Entradas no conjunto bibliográfico disponível	129
Entradas ausentes da triagem com DOI coincidente	11
Registros na triagem do Evidentia	118
Excluídos na triagem	91
Incluídos na triagem	26
Decisão intermediária na triagem	1
Títulos presentes no formulário de extração	25

Fonte: Elaboração própria a partir do registro da busca e das decisões de triagem.

O formulário de extração contém 25 títulos que correspondem a registros incluídos na triagem, enquanto os campos de extração estão vazios. Entre os 26 incluídos no Evidentia, o registro *AI-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study* (JOERG et al., 2025) não consta do formulário de extração. É necessário verificar a razão dessa diferença, aplicar os critérios ao texto completo e registrar o resultado antes de estabelecer o conjunto definitivo de estudos incluídos.

Os comentários do consenso e as notas disponíveis não registram o motivo individual dos 91 registros excluídos; essa informação ainda deve ser recuperada para permitir a verificação de cada decisão. As pontuações `fails` do Jev são associadas a critérios, mas não constituem, por si sós, justificativas registradas pelos revisores. Para completar a rastreabilidade do fluxo, ainda é necessário recuperar os motivos de exclusão, esclarecer a diferença entre as 129 entradas disponíveis e os 130 registros informados, identificar o eventual décimo segundo registro removido e resolver a situação intermediária. A quantidade incluída após a avaliação integral ainda não foi confirmada.

2.1.6 Extração e síntese das evidências

Conforme Wohlin et al. (2024, p. 55–56), o formulário de extração deve ser orientado pelas questões de pesquisa e permitir o registro das características dos estudos e dos dados necessários à síntese. Neste trabalho, o formulário foi organizado para registrar título, autores, ano, fonte, tipo de estudo e veículo, além das respostas às questões da revisão: técnicas, bases de dados, populações, manifestações, quantidade de imagens, métodos de avaliação, métricas, resultados, tons de pele, modelos, generalização, validação e limitações. A leitura integral deverá confirmar a elegibilidade e preencher esses campos com indicação da página, seção ou tabela de origem. Estudos primários e revisões devem ser identificados separadamente, para não atribuir aos revisores resultados de experimentos relatados por outros autores.

A síntese deverá distinguir classificação, detecção e segmentação, bem como resultados globais e específicos para hanseníase. Diferenças entre grupos de tom de pele e evidências de generalização serão registradas quando disponíveis; a ausência de resultados por grupo não será interpretada como demonstração de equidade. A análise da aplicabilidade ao contexto brasileiro não equivale a uma validação clínica. Até a conclusão da leitura completa e da extração, a seleção e os resultados permanecem provisórios.

Referências

AHIKPA, E. D.; HIMABINDU, K. A machine learning-based diagnosis of leprosy: Study. In: *2025 IEEE International Conference on Emerging Trends in Computing and Communication (ETCOM)*. IEEE, 2025. Disponível em: <https://doi.org/10.1109/ETCOM66606.2025.11436464>. Citado na página 24.

BAWEJA, H. S.; PARHAR, T. Leprosy lesion recognition using convolutional neural networks. In: *2016 International Conference on Machine Learning and Cybernetics (ICMLC)*. IEEE, 2016. p. 141–145. Disponível em: <https://doi.org/10.1109/ICMLC.2016.7860891>. Citado na página 16.

COCO. *Detection Evaluation*. Documentação técnica do benchmark. Disponível em: <https://cocodataset.org/dataset/detection-eval.htm>. Acesso em: 15 out. 2026. Citado na página 11.

EITA, M. A.; RIZK, H. A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology. *Engineering Applications of Artificial Intelligence*, v. 159, p. 111594, 2025. Disponível em: <https://doi.org/10.1016/j.engappai.2025.111594>. Citado 4 vezes nas páginas 3, 4, 5 e 24.

FERNANDES, J. R. N. et al. Artificial intelligence on diagnostic aid of leprosy: A systematic literature review. *Journal of Clinical Medicine*, v. 13, n. 1, p. 180, 2024. Disponível em: <https://doi.org/10.3390/jcm13010180>. Citado 2 vezes nas páginas 3 e 23.

JAIKISHORE, C. N.; UDUTALAPALLY, V.; DAS, D. Ai driven edge device for screening skin lesion and its severity in peripheral communities. In: *2021 IEEE 18th India Council International Conference (INDICON)*. IEEE, 2021. p. 1–6. Disponível em: <https://doi.org/10.1109/INDICON52576.2021.9691666>. Citado 3 vezes nas páginas 3, 5 e 23.

JOERG, L. et al. Ai-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study. *Journal of the European Academy of Dermatology and Venereology*, v. 39, p. 2134–2141, 2025. Disponível em: <https://doi.org/10.1111/jdv.20849>. Citado na página 17.

KITCHENHAM, B.; CHARTERS, S. *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. [S.l.], 2007. Version 2.3. Disponível em: <https://www.cse.chalmers.se/~feldt/advice/kitchenham_2007_systematic_reviews_report_updated.pdf>. Citado na página 12.

SANCHEZ, K. et al. CO2Wounds-V2: Extended chronic wounds dataset from leprosy patients. In: *2024 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2024. p. 69–75. Disponível em: <https://doi.org/10.1109/ICIP51287.2024.10647641>. Citado 2 vezes nas páginas 4 e 24.

SOUZA, M. L. M. d. et al. Leprosy screening based on artificial intelligence: Development of a cross-platform app. *JMIR mHealth and uHealth*, p. e23718, 2021. Disponível em: <https://doi.org/10.2196/23718>. Citado na página 16.

WOHLIN, C. et al. *Experimentation in Software Engineering*. 2. ed. Berlin, Heidelberg: Springer, 2024. Disponível em: <https://doi.org/10.1007/978-3-662-69306-3>. Citado 3 vezes nas páginas 12, 16 e 18.

YOTSU, R. R. et al. Deep learning for ai-based diagnosis of skin-related neglected tropical diseases: A pilot study. *PLOS Neglected Tropical Diseases*, v. 17, n. 8, p. e0011230, 2023. Disponível em: <https://doi.org/10.1371/journal.pntd.0011230>. Citado 4 vezes nas páginas 3, 4, 5 e 23.

Apêndices

APÊNDICE A – Notas para revisão com os orientadores — fora do texto do capítulo

TCC de Euller e Gabriel · 15/10/2026

Versão de trabalho baseada nas leituras fornecidas. A revisão da literatura está em andamento. O texto abaixo é uma proposta de redação; o contexto definido é o apoio à triagem de hanseníase na rede pública de saúde do Brasil. O GQM e a questão de pesquisa foram atualizados conforme a definição fornecida pela dupla. As notas editoriais ao final não integram a introdução.

A.1 Estrutura adotada e relação com os exemplos

Os três TCCs fornecidos organizam suas introduções em torno de contexto, problema, questão de pesquisa, objetivos, organização/estrutura do trabalho e cronograma. Esta versão desenvolve contexto, problema, GQM, questão de pesquisa, objetivos e métricas. As métricas podem ser deslocadas para o capítulo metodológico na organização final. A organização dos capítulos e o cronograma devem refletir o planejamento efetivamente aprovado, sem importar atividades experimentais dos exemplos.

Os exemplos foram utilizados como referência de organização, não como fontes científicas sobre hanseníase ou visão computacional. Não se reproduziu o conteúdo temático desses trabalhos.

A.2 Pontos que precisam de decisão

- **Recorte territorial definido:** Brasil, no contexto da rede pública de saúde. Isso não implica que todos os estudos devam ser brasileiros ou que já exista validação local. Fundamentar posteriormente as particularidades do cenário brasileiro com fontes pertinentes.
- **Escopo da questão:** "como avaliar" pode orientar uma proposta de avaliação mais ampla; a revisão responde inicialmente "como os modelos têm sido avaliados". Alinhar com os professores se a RQ central pertence ao TCC completo e as oito perguntas orientam a extração da revisão.
- **Tons de pele:** o escopo passa a abranger imagens de pele em geral. A avaliação entre tons permanece em M6, quando houver evidências, sem restringir a questão central a pele negra. Fitzpatrick não equivale a identidade racial; origem geográfica

não determina tom de pele.

- **Contribuição do TCC 1:** a versão propõe síntese da literatura e fundamentação de avaliação futura. Não promete execução experimental, validação clínica ou aplicativo concluído nesta etapa.
- **Fundamentação clínica:** para aprofundar definições, sinais diagnósticos ou epidemiologia, consultar fontes primárias/oficiais. Esta versão se limita ao contexto apresentado nos artigos e evita estatísticas epidemiológicas atuais não verificadas.
- **Lacuna provisória:** as leituras permitem apontar questões de avaliação e relato. Não escrever que "não existem estudos" ou que a revisão já demonstrou uma lacuna definitiva enquanto a seleção e a extração não terminarem.

A.3 Mapa das afirmações e das fontes

Parte da redação	Base consultada	Onde conferir	Limite da afirmação
Dificuldades de reconhecimento e panorama de IA	Fernandes et al. (2024)	PDF pp. 1–2	Contextualização da revisão, sem números atuais de prevalência
21 estudos e predominância de classificação multiclasse	Fernandes et al. (2024)	Resumo, p. 1	Não significa 21 estudos elegíveis para o protocolo de vocês
MobileNetV2 e protótipo Android	Jaikishore, Udutalapally e Das (2021)	Resumo/Introdução, p. 1	Protótipo não equivale a validação clínica; não afirmar estadiamento validado da hanseníase
CNNs e população de pele escura	Yotsu et al. (2023)	pp. 3–5	Dados africanos não demonstram validação na rede pública brasileira
Resultados específicos de hanseníase	Yotsu et al. (2023)	pp. 6–7, Task 2/Figura 1	12%/13% são leitura da matriz por classe; não misturar com Task 1

Parte da redação	Base consultada	Onde conferir	Limite da afirmação
Segmentação de feridas	Sanchez et al. (2024)	pp. 1 e 4–5 do PDF	Não é diagnóstico da hanseníase
YOLO e explicabilidade	Eita e Rizk (2025)	pp. 4–9	Mapas de saliência não comprovam validade clínica
Diversidade limitada e validação prospectiva futura	Eita e Rizk (2025)	p. 16, seções 6.4 e 7	Não demonstra diferença quantitativa por tom de pele

A classificação de Ahikpa e Himabindu (2025) como revisão ou estudo experimental requer confirmação no texto completo. Pode apoiar o referencial e os trabalhos relacionados; nesta introdução, priorizaram-se a revisão sistemática de Fernandes e os estudos primários fornecidos. Isso evita atribuir aos revisores resultados que pertencem aos estudos citados.

A.4 Situação do repositório consultado

Consulta à branch `master` de `HansenSightAI/tcc`, em 14/10/2026. O arquivo `Monografia/editaveis/introducao.tex` ainda contém uma introdução sobre análise de shaders em dispositivos móveis. O arquivo `Monografia/bibliografia.bib` contém referências do mesmo modelo de computação gráfica. Esta redação é um rascunho independente para revisão; não foi aplicada ao repositório.

Caminhos consultados:

- https://github.com/HansenSightAI/tcc/blob/master/Monografia/editaveis/introducao.tex
- https://github.com/HansenSightAI/tcc/blob/master/Monografia/bibliografia.bib

Na integração, substituir o texto do modelo pela versão aprovada e acrescentar as referências abaixo. Antes de remover referências antigas, verificar se ainda são citadas em outros capítulos do modelo.

APÊNDICE B – Solicitação enviada ao Consensus

O texto a seguir reproduz a solicitação enviada em inglês à ferramenta para orientar a busca. As quebras de linha foram ajustadas à apresentação; os termos e os asteriscos foram preservados.

```
find articles for the following components of my systematic research.
main research Question:
How can we evaluate the performance of computer vision models applied to
    identifying patterns associated with leprosy in skin images, within the
    context of the Brazilian public health system?
secondary questions:
What computer vision techniques are used to identify dermatological
    manifestations associated with leprosy?
What datasets and populations are used in the development and evaluation of
    these models?
What methods and procedures are used to evaluate the performance of these
    models, and what results are reported?
What metrics are used to evaluate the performance of these models, and what
    results are reported?
How does the performance of the models vary between different groups or skin
    tones?
What artificial intelligence models and approaches are used to identify
    dermatological manifestations associated with leprosy?
How is the generalization capacity of the models evaluated, especially when
    using datasets different from those used in training?
In what type of publication venue was the article published? (journal,
    conference)

PICOC:
Keyword and Synonyms
Population:
Computer Vision
artificial intelligence
CNN
convolutional neural network*
deep learning
machine learning
```

```
neural network*
Context:
leprosy
Hansen disease
hanseniasis
Hansen's disease
skin lesion classification
skin lesion segmentation

Intervention:
Machine Learning Models
Attention U-Net
capsule network*
ConvNeXt*
DenseNet*
EfficientNet*
MedSAM
multi-task learning
ResNet*
ResUNet
SAM3
Segment Anything Model
self-supervised learning
semi-supervised learning
supervised learning
Swin Transformer*
transfer learning
U-Net
UNet
unsupervised learning
Vision Transformer*
ViT

Outcome:
performance
accuracy
AUC
classification
detection
diagnosis
evaluation
F1 score
```

```
F1-score
identification
precision
recall
recognition
ROC-AUC
segmentation
sensitivity
specificity
```